

- **Introducción Analítica a la Ciencia de Datos: Descripción de las bases de datos**

● Introducción Analítica a la Ciencia de Datos: Descripción de las bases de datos

- **1.- Apple Quality.** La base *apple_quality.csv* contiene datos sobre diversos atributos de un conjunto de frutas, que proporciona información sobre sus características. Incluye tamaño (Size), peso (Weight), dulzor (Sweetness), textura crujiente (Crunchiness), jugosidad (Juiciness), madurez (Ripeness), acidez (Acidity) y calidad (Quality).

● Introducción Analítica a la Ciencia de Datos: Descripción de las bases de datos

- **1.- Apple Quality.** La base *apple_quality.csv* contiene datos sobre diversos atributos de un conjunto de frutas, que proporciona información sobre sus características. Incluye tamaño (Size), peso (Weight), dulzor (Sweetness), textura crujiente (Crunchiness), jugosidad (Juiciness), madurez (Ripeness), acidez (Acidity) y calidad (Quality).
- **2.- Heart Disease.** La base *heart.csv* corresponde a un conjunto de datos de 1988 y consta de cuatro bases de distintos lugares: Cleveland, Hungría, Suiza y Long Beach V. Contiene 76 atributos, incluida la variable de clasificación. No obstante, es común utilizar un subconjunto de 13 de estos atributos, además del de clasificación, para su análisis. La variable de clasificación: *target*, se refiere a la presencia de cardiopatía en el paciente. Con valores: 0 = sin cardiopatía y 1 = con cardiopatía.

- El resto de las variables en heart.csv son: Edad (*age*), Sexo (*sex*), Tipo de dolor torácico (4 valores) (*cp*), Presión arterial en reposo (*trestbps*), Colesterol sérico en mg/dl (*chol*), Glucemia en ayunas > 120 mg/dl (*fbs*. 1: Sí 0: No), Resultados electrocardiográficos en reposo (valores 0, 1 y 2) (*restecg*), Frecuencia cardíaca máxima alcanzada (*thalach*), Angina inducida por el ejercicio (*exang*. 1: Sí, 0: No), Depresión del segmento ST inducida por el ejercicio en relación con el reposo (*oldpeak*), Pendiente del segmento ST máximo en el ejercicio (*slope*), Número de vasos principales (0-3) coloreados por fluoroscopia (*ca*) y Taladro (*thal*. 0: normal, 1: defecto fijo, 2: defecto reversible).

- **3.- Loan-Approval-Prediction.** *loan_approval_dataset.csv* es una base de datos de aprobación de préstamos, que contiene una colección de registros financieros e información asociada que se utiliza para determinar la elegibilidad de personas u organizaciones para obtener préstamos de una entidad crediticia. Incluye diversos factores como la puntuación cibil (cibil_score), ingresos (income_annum), situación laboral (self_employed), plazo del préstamo (loan_term), importe del préstamo (loan_amount), valor de los activos (residential_assets_value), valor de los activos comerciales (commercial_assets_value), valor de los activos de lujo (luxury_assets_value), valor de los activos bancarios (bank_asset_value) y el estado del préstamo (loan_status).

- **4.- Obesity Prediction** Los datos en *Obesity.csv* corresponden a información que ayuda a estimar los niveles de obesidad según los hábitos alimentarios, los antecedentes familiares y la condición física. Incluye datos de personas en México, Perú y Colombia, que abarcan 16 características relacionadas con el estilo de vida y la salud, con 2111 registros. Las etiquetas clasifican los niveles de obesidad, desde bajo peso hasta diferentes tipos de obesidad. La mayoría de los datos se generaron mediante técnicas sintéticas, mientras que algunos se recopilaron directamente de los usuarios a través de una plataforma web. Las variables son:

- Género (Gender), Edad (Age), Altura (Height), Peso (Weight), Antecedentes familiares con sobrepeso: Si tiene antecedentes familiares de sobrepeso (sí/no) (Weight), FAVC: Si consume frecuentemente alimentos ricos en calorías (sí/no), FCVC: Frecuencia de consumo de verduras (escala del 1 al 3), NCP: Número de comidas principales al día. CAEC: Frecuencia de consumo de alimentos entre comidas (Nunca, A veces, Frecuentemente, Siempre), SMOKE: Si fuma (sí/no). CH2O: Ingesta diaria de agua (escala del 1 al 3). SCC: Si controla su ingesta calórica (sí/no). FAF: Frecuencia de actividad física (escala del 0 al 3). TUE: Tiempo dedicado al uso de tecnología (escala del 0 al 3). CALC: Frecuencia de consumo de alcohol (Nunca, A veces, Frecuentemente, Siempre). MTRANS: Principal medio de transporte (Automóvil, Bicicleta, Moto, Transporte público, Caminar), NObeyesdad: Nivel de obesidad (Peso insuficiente, Peso normal, Sobrepeso nivel I, Sobrepeso nivel II, Obesidad tipo I, Obesidad tipo II, Obesidad tipo III).

- **5.- Student Habits vs. Academic Performance.** El archivo *habits.csv* contiene datos simulados pero realistas titulado: "Hábitos Estudiantiles vs. Rendimiento Académico: Un Estudio Simulado", con 1000 registros estudiantiles. Cada renglón corresponde a los hábitos de vida diarios de un estudiante, tales como: horas de estudio (*study_hours_per_day*), horas de sueño (*sleep_hours*), uso de redes sociales (*social_media_hours*), calidad de dieta (*diet_quality*), calificación de salud mental (*mental_health_rating*), horas de Netflix (*netflix_hours*), trabajo a tiempo parcial (*part_time_job*), porcentaje de asistencia (*attendance_percentage*), frecuencia de ejercicio (*exercise_frequency*), nivel de educación parental (*parental_education_level*), calidad de internet (*internet_quality*), participación extracurricular (*extracurricular_participation*), todas ellas relacionadas con su calificación del examen final (*exam_score*).

- **6.- Graduates Admission Prediction.** La base Admission_Predict.csv contiene los siguientes importantes parámetros, que se consideran relevantes durante la solicitud de programas de maestría.

- **6.- Graduates Admission Prediction.** La base Admission_Predict.csv contiene los siguientes importantes parámetros, que se consideran relevantes durante la solicitud de programas de maestría.
- Descripción de los parámetros: Puntuación GRE (sobre 340) (GRE Scores), Puntuación TOEFL (sobre 120) (TOEFEL score), Calificación universitaria (sobre 5) (University Rating), Declaración de propósitos (Fortalecimiento (sobre 5)) (SOP), Carta de recomendación (Fortalecimiento (sobre 5)) (LOR), Promedio general de pregrado (sobre 10) (GPA), Experiencia en investigación (No: 0 ó Sí: 1) (Research Experience), Probabilidad de admisión (de 0 a 1) (Chance of Admit)

- **6.- Graduates Admission Prediction.** La base Admission_Predict.csv contiene los siguientes importantes parámetros, que se consideran relevantes durante la solicitud de programas de maestría.
- Descripción de los parámetros: Puntuación GRE (sobre 340) (GRE Scores), Puntuación TOEFL (sobre 120) (TOEFEL score), Calificación universitaria (sobre 5) (University Rating), Declaración de propósitos (Fortalecimiento (sobre 5)) (SOP), Carta de recomendación (Fortalecimiento (sobre 5)) (LOR), Promedio general de pregrado (sobre 10) (GPA), Experiencia en investigación (No: 0 ó Sí: 1) (Research Experience), Probabilidad de admisión (de 0 a 1) (Chance of Admit)
- Los resultados ayudarán a los estudiantes a preseleccionar universidades de acuerdo a sus perfiles. El rendimiento previsto puede darles una idea clara de sus posibilidades de ingresar a una universidad en particular.

- **7.- Global Air Quality**

- **7.- Global Air Quality**

- La contaminación atmosférica causa aproximadamente 7 millones de muertes prematuras al año (OMS). Este conjunto de datos permite a investigadores y científicos de datos:

- **7.- Global Air Quality**

- La contaminación atmosférica causa aproximadamente 7 millones de muertes prematuras al año (OMS). Este conjunto de datos permite a investigadores y científicos de datos:
 - Analizar las disparidades en la contaminación global

- **7.- Global Air Quality**

- La contaminación atmosférica causa aproximadamente 7 millones de muertes prematuras al año (OMS). Este conjunto de datos permite a investigadores y científicos de datos:
 - Analizar las disparidades en la contaminación global
 - Investigar los impactos de la calidad del aire en la salud

- **7.- Global Air Quality**

- La contaminación atmosférica causa aproximadamente 7 millones de muertes prematuras al año (OMS). Este conjunto de datos permite a investigadores y científicos de datos:
 - Analizar las disparidades en la contaminación global
 - Investigar los impactos de la calidad del aire en la salud
 - Desarrollar modelos predictivos para el monitoreo ambiental

● 7.- Global Air Quality

- La contaminación atmosférica causa aproximadamente 7 millones de muertes prematuras al año (OMS). Este conjunto de datos permite a investigadores y científicos de datos:
 - Analizar las disparidades en la contaminación global
 - Investigar los impactos de la calidad del aire en la salud
 - Desarrollar modelos predictivos para el monitoreo ambiental
- Las variables se encuentran en la base Air_Quality.csv, y son: Ciudad (City), Monóxido de carbono (CO), Dióxido de carbono (CO_2), Dióxido de nitrógeno (NO_2), Dióxido de azufre (SO_2), Concentración de ozono (O_3), ParticulasSuspendidas2.5 (PM2.5), ParticulasSuspendidas10 (PM10), Índice Europeo de Calidad del Aire (European Air Quality Index (IECA))

- Discretización del Índice

- **Discretización del Índice**
- El IECA se basa en la discretización de la calidad del aire en diferentes niveles, cada uno con su propia descripción y rango de valores:

- **Discretización del Índice**

- El IECA se basa en la discretización de la calidad del aire en diferentes niveles, cada uno con su propia descripción y rango de valores:
 - **Buena (Verde)**: La calidad del aire es satisfactoria y no presenta riesgos significativos para la salud. En general, se considera que valores de IECA inferiores a 50 corresponden a una buena calidad del aire

- **Discretización del Índice**

- El IECA se basa en la discretización de la calidad del aire en diferentes niveles, cada uno con su propia descripción y rango de valores:

- **Buena (Verde)**: La calidad del aire es satisfactoria y no presenta riesgos significativos para la salud. En general, se considera que valores de IECA inferiores a 50 corresponden a una buena calidad del aire
- **Razonablemente buena (Verde)**: La calidad del aire es aceptable, pero puede haber ciertos riesgos para grupos sensibles. Un IECA entre 51 y 100 se considera razonablemente bueno.

- **Discretización del Índice**

- El IECA se basa en la discretización de la calidad del aire en diferentes niveles, cada uno con su propia descripción y rango de valores:

- **Buena (Verde)**: La calidad del aire es satisfactoria y no presenta riesgos significativos para la salud. En general, se considera que valores de IECA inferiores a 50 corresponden a una buena calidad del aire
- **Razonablemente buena (Verde)**: La calidad del aire es aceptable, pero puede haber ciertos riesgos para grupos sensibles. Un IECA entre 51 y 100 se considera razonablemente bueno.
- **Regular (Amarillo)**: La calidad del aire es moderada, y puede haber riesgos para grupos sensibles. Un IECA entre 101 y 150 se considera regular.

- **Discretización del Índice**

- El IECA se basa en la discretización de la calidad del aire en diferentes niveles, cada uno con su propia descripción y rango de valores:

- **Buena (Verde)**: La calidad del aire es satisfactoria y no presenta riesgos significativos para la salud. En general, se considera que valores de IECA inferiores a 50 corresponden a una buena calidad del aire
- **Razonablemente buena (Verde)**: La calidad del aire es aceptable, pero puede haber ciertos riesgos para grupos sensibles. Un IECA entre 51 y 100 se considera razonablemente bueno.
- **Regular (Amarillo)**: La calidad del aire es moderada, y puede haber riesgos para grupos sensibles. Un IECA entre 101 y 150 se considera regular.
- **Desfavorable (Rojo)**: La calidad del aire es desfavorable para grupos sensibles, y puede haber riesgos para la salud de la población en general. Un IECA entre 151 y 200 se considera desfavorable.

- Continúa discretización del IECA

- Continúa discretización del IECA
 - **Muy desfavorable (Granate)**: La calidad del aire es muy desfavorable y presenta riesgos significativos para la salud de la población en general. Un IECA entre 201 y 300 se considera muy desfavorable.

- Continúa discretización del IECA
 - **Muy desfavorable (Granate)**: La calidad del aire es muy desfavorable y presenta riesgos significativos para la salud de la población en general. Un IECA entre 201 y 300 se considera muy desfavorable.
 - **Extremadamente desfavorable (Morado)**: La calidad del aire es extremadamente desfavorable y presenta un alto riesgo para la salud de la población. Un IECA superior a 300 se considera extremadamente desfavorable.

- Continúa discretización del IECA
 - **Muy desfavorable (Granate)**: La calidad del aire es muy desfavorable y presenta riesgos significativos para la salud de la población en general. Un IECA entre 201 y 300 se considera muy desfavorable.
 - **Extremadamente desfavorable (Morado)**: La calidad del aire es extremadamente desfavorable y presenta un alto riesgo para la salud de la población. Un IECA superior a 300 se considera extremadamente desfavorable.
- Esta discretización permite a los ciudadanos entender rápidamente la calidad del aire en su zona y tomar las medidas preventivas necesarias para proteger su salud, como evitar actividades al aire libre en áreas con mala calidad del aire o usar mascarillas

- **8.- Water Quality and Potability** El archivo *water_potability.csv* contiene mediciones y evaluaciones de la calidad del agua relacionadas con su potabilidad, es decir, la idoneidad para el consumo humano. Proporciona información sobre los parámetros de calidad del agua y ayudar a determinar si es potable. Cada renglón representa una muestra de agua con atributos específicos, y la columna *Potability* indica si el agua es o no apta para el consumo. Las variables medias son: ph: Nivel de ph, Dureza (Hardness): Dureza, medida del contenido mineral, Sólidos (Solids): Total de sólidos disueltos, Cloraminas (Chloramines): Concentración de cloraminas, Sulfato (Sulfate): Concentración de sulfato, Conductividad (Conductivity): Conductividad eléctrica, Carbono orgánico (Organic_carbon): Contenido de carbono orgánico, Trihalometanos (Trihalomethanes): Concentración de trihalometanos, Turbidez (Turbidity): Nivel de turbidez, medida de la claridad y Potabilidad (Potability): Indica la potabilidad con valores de 1 (potable) y 0 (no potable)

- **9.- Disease Risk from Daily Habits** El archivo *health_lifestyle_classification.csv* contiene información biométrica y de estilo de vida detallada de 100000 personas. Las variables corresponden a hábitos, métricas de salud, datos demográficos e indicadores psicológicos. Se cuenta, además, con una variable de clasificación: *target* que determina si el sujeto está sano o enfermo.

- **9.- Disease Risk from Daily Habits** El archivo *health_lifestyle_classification.csv* contiene información biométrica y de estilo de vida detallada de 100000 personas. Las variables corresponden a hábitos, métricas de salud, datos demográficos e indicadores psicológicos. Se cuenta, además, con una variable de clasificación: *target* que determina si el sujeto está sano o enfermo.
- Las variables numéricas son: age: Age of the individual, bmi: Body Mass Index, blood_pressure: Systolic blood pressure (mm Hg), cholesterol: Cholesterol level (mg/dL), heart_rate: Resting heart rate (bpm), glucose: Blood glucose level, insulin: Blood insulin level, calorie_intake: Daily average calorie consumption, sugar_intake: Daily sugar intake (grams), screen_time: Daily screen time (hours), stress_level: Self-reported stress level (0-10 scale), mental_health_score: Self-reported mental well-being score (0-10 scale), training_hours: Weekly training/exercise hours

- Las variables discretas son: gender: Male / Female, marital_status: Single, Married, Divorced, Widowed, diet_type: Vegan, Vegetarian, Omnivore, Keto, Paleo, occupation: Job type or employment status, sleep_quality: Subjective sleep quality, mental_health_support: Access to mental health resources, exercise_type: None, Cardio, Strength, Mixed, device_usage: Device usage level, healthcare_access: Ease of access to healthcare, insurance: Has health insurance or not, family_history: Family history of disease, sunlight_exposure: Daily sunlight exposure (Low/Med/High)

- **10.- Sleep Health and Lifestyle** La base *Sleep_health_and_lifestyle.csv* consta de 400 sujetos y 13 columnas, que abarcan una amplia gama de variables relacionadas con el sueño y los hábitos diarios. Incluye información sobre: género (gender), edad (age), ocupación (occupation), duración del sueño (sleep duration), calidad del sueño (quality of sleep), nivel de actividad física (physical activity level), niveles de estrés (stress levels), categoría de IMC (BMI category), presión arterial (blood pressure), frecuencia cardíaca (heart rate), pasos diarios (daily steps) y presencia o ausencia de trastornos del sueño (Sleep Disorder) (ninguno, insomnio, apnea del sueño).

- **11.- Student Alcohol Consumption** Los datos en la base *Student Alcohol Consumption.csv* se obtuvieron mediante una encuesta a estudiantes de matemáticas y portugués de secundaria. Contienen mucha información interesante sobre aspectos sociales, de género y académicos de los estudiantes. Las variables son
 - school:** student's school (binary: 'GP' - Gabriel Pereira or 'MS' - Mousinho da Silveira)
 - sex:** student's sex (binary: 'F' - female or 'M' - male)
 - age:** student's age (numeric: from 15 to 22)
 - address:** student's home address type (binary: 'U' - urban or 'R' - rural)
 - famsize:** family size (binary: 'LE3' - less or equal to 3 or 'GT3' - greater than 3)
 - Pstatus:** parent's cohabitation status (binary: 'T' - living together or 'A' - apart)

- Sigue...

Medu: mother's education (numeric: 0 - none, 1 - primary education (4th grade), 2 - 5th to 9th grade, 3 - secondary education or 4 - higher education)

Fedu: father's education (numeric: 0 - none, 1 - primary education (4th grade), 2 - 5th to 9th grade, 3 - secondary education or 4 - higher education)

Mjob: mother's job (nominal: 'teacher', 'health' care related, civil 'services' (e.g. administrative or police), 'at_home' or 'other')

Fjob: father's job (nominal: 'teacher', 'health' care related, civil 'services' (e.g. administrative or police), 'at_home' or 'other')

reason: reason to choose this school (nominal: close to 'home', school 'reputation', 'course' preference or 'other')

guardian: student's guardian (nominal: 'mother', 'father' or 'other')

- Sigue...

traveltime: home to school travel time (numeric:

1.- $< 15min.$, 2.- 15 to 30 min., 3.- 30 min. to 1 hour, or 4.- > 1 hour)

studytime: weekly study time (numeric: 1.- $< 2hours$, 2.- 2 to 5 hours, 3.- 5 to 10 hours, or 4.- > 10 hours)

failures: number of past class failures (numeric: n if $1 \leq n < 3$, else 4)

schoolsup: extra educational support (binary: yes or no)

famsup: family educational support (binary: yes or no)

paid: extra paid classes within the course subject (Math or Portuguese) (binary: yes or no) **activities:** extra-curricular activities (binary: yes or no)

nursery: attended nursery school (binary: yes or no)

higher: wants to take higher education (binary: yes or no)

internet: Internet access at home (binary: yes or no)

romantic: with a romantic relationship (binary: yes or no)

- Sigue...

famrel: quality of family relationships (numeric: from 1 - very bad to 5 - excellent)

freetime: free time after school (numeric: from 1 - very low to 5 - very high)

goout: going out with friends (numeric: from 1 - very low to 5 - very high)

Dalc: workday alcohol consumption (numeric: from 1 - very low to 5 - very high)

Walc: weekend alcohol consumption (numeric: from 1 - very low to 5 - very high)

health: current health status (numeric: from 1 - very bad to 5 - very good)

absences: number of school absences (numeric: from 0 to 93)

- Sigue...

These grades are related with the course subject, Math or Portuguese:

G1: first period grade (numeric: from 0 to 20)

G2: second period grade (numeric: from 0 to 20)

G3: final grade (numeric: from 0 to 20, output target)