

• Introducción Analítica a la Ciencia de Datos

• Introducción Analítica a la Ciencia de Datos

• Módulo VI: Aprendizaje no Supervisado

• Introducción Analítica a la Ciencia de Datos

• Módulo VI: Aprendizaje no Supervisado

• Fecha: 24 Julio 2025 - 30 Agosto 2025

• Introducción Analítica a la Ciencia de Datos

• Módulo VI: Aprendizaje no Supervisado

• Fecha: 24 Julio 2025 - 30 Agosto 2025

• Duración: 30 horas

- **Ciencia de Datos**

- Ciencia de Datos
- Introducción

- **Ciencia de Datos**

- **Introducción**

- **Ciencia de Datos:** La *ciencia de datos* es una disciplina que mediante la combinación de modelos matemáticos y estadísticos, la programación computacional y las técnicas de visualización de datos, permite obtener el mayor beneficio del análisis de datos (información) para apoyar los procesos de toma de decisiones.

● Ciencia de Datos

● Introducción


- **Ciencia de Datos:** La *ciencia de datos* es una disciplina que mediante la combinación de modelos matemáticos y estadísticos, la programación computacional y las técnicas de visualización de datos, permite obtener el mayor beneficio del análisis de datos (información) para apoyar los procesos de toma de decisiones.
- La ciencia de datos consiste en desarrollar modelos que nos permitan procesar grandes volúmenes de información, para realizar procesos de análisis complejos, que nos permitan extraer conocimiento útil de estos datos, que nos auxilien en la toma de decisiones.

● Ciencia de Datos

● Introducción

- **Ciencia de Datos:** La *ciencia de datos* es una disciplina que mediante la combinación de modelos matemáticos y estadísticos, la programación computacional y las técnicas de visualización de datos, permite obtener el mayor beneficio del análisis de datos (información) para apoyar los procesos de toma de decisiones.
- La ciencia de datos consiste en desarrollar modelos que nos permitan procesar grandes volúmenes de información, para realizar procesos de análisis complejos, que nos permitan extraer conocimiento útil de estos datos, que nos auxilien en la toma de decisiones.
- En este sentido, podemos decir que la ciencia de datos se encarga de potenciar el valor y utilidad de los datos.

Conjunto de datos



Aprendizaje Supervisado

Conjunto de datos

Etiquetas



Cuadrado azul

Triángulo azul

Cuadrado rojo

Triángulo rojo

Aprendizaje no Supervisado

Conjunto de datos



Cuadrado azul

Cuadrado rojo

Triángulo azul

Triángulo rojo

- **Aprendizaje Supervisado y Aprendizaje no Supervizado**

- **Aprendizaje Supervisado y Aprendizaje no Supervizado**
- **Aprendizaje supervisado:** En un problema de aprendizaje supervisado, el análisis inicia con un conjunto de datos que contiene ejemplos de entrenamiento con etiquetas correctas asociadas.

- **Aprendizaje Supervisado y Aprendizaje no Supervizado**
- **Aprendizaje supervisado:** En un problema de aprendizaje supervisado, el análisis inicia con un conjunto de datos que contiene ejemplos de entrenamiento con etiquetas correctas asociadas.
- El algoritmo aprenderá la relación entre los datos y sus etiquetas y aplicará esa relación aprendida para clasificar datos completamente nuevos que la máquina no haya visto antes

- **Aprendizaje Supervisado y Aprendizaje no Supervisado**
- **Aprendizaje supervisado:** En un problema de aprendizaje supervisado, el análisis inicia con un conjunto de datos que contiene ejemplos de entrenamiento con etiquetas correctas asociadas.
- El algoritmo aprenderá la relación entre los datos y sus etiquetas y aplicará esa relación aprendida para clasificar datos completamente nuevos que la máquina no haya visto antes
- El aprendizaje supervisado recibe este nombre porque el desarrollador actúa como una guía para enseñar al algoritmo las conclusiones a las que debe llegar, es decir, la salida del algoritmo ya es conocida

- **Aprendizaje Supervisado y Aprendizaje no Supervisado**
- **Aprendizaje supervisado:** En un problema de aprendizaje supervisado, el análisis inicia con un conjunto de datos que contiene ejemplos de entrenamiento con etiquetas correctas asociadas.
- El algoritmo aprenderá la relación entre los datos y sus etiquetas y aplicará esa relación aprendida para clasificar datos completamente nuevos que la máquina no haya visto antes
- El aprendizaje supervisado recibe este nombre porque el desarrollador actúa como una guía para enseñar al algoritmo las conclusiones a las que debe llegar, es decir, la salida del algoritmo ya es conocida
- Requiere que los posibles resultados del algoritmo ya sean conocidos y que los datos utilizados para entrenar el algoritmo ya estén etiquetados con las respuestas correctas

- El aprendizaje supervisado es un enfoque de **IA**, donde un algoritmo de computadora está capacitado en datos de entrada que han sido etiquetados para una salida particular

- El aprendizaje supervisado es un enfoque de **IA**, donde un algoritmo de computadora está capacitado en datos de entrada que han sido etiquetados para una salida particular
- El modelo será entrenado hasta que pueda detectar los patrones y relaciones subyacentes entre los datos de entrada y las etiquetas de salida, lo que le permite producir resultados de etiquetado precisos cuando se le presenten datos nunca antes vistos



Es un gato



Es un gato

- Por ejemplo, un algoritmo de clasificación aprenderá a identificar animales después de haber sido entrenados en un conjunto de datos de imágenes que están apropiadamente etiquetados con las especies del animal y algunas características de identificación

- Por ejemplo, un algoritmo de clasificación aprenderá a identificar animales después de haber sido entrenados en un conjunto de datos de imágenes que están apropiadamente etiquetados con las especies del animal y algunas características de identificación
- En este ejemplo, cuando se aprende a clasificar imágenes de gatos, el algoritmo toma miles de imágenes de gatos junto con la etiqueta "*gato*"

- Por ejemplo, un algoritmo de clasificación aprenderá a identificar animales después de haber sido entrenados en un conjunto de datos de imágenes que están apropiadamente etiquetados con las especies del animal y algunas características de identificación
- En este ejemplo, cuando se aprende a clasificar imágenes de gatos, el algoritmo toma miles de imágenes de gatos junto con la etiqueta "*gato*"
- El algoritmo aprenderá esta relación y cuando se le muestre una nueva imagen, esta vez sin etiquetas, podrá aplicar esa relación aprendida y determinar si es un gato o no

- Por ejemplo, un algoritmo de clasificación aprenderá a identificar animales después de haber sido entrenados en un conjunto de datos de imágenes que están apropiadamente etiquetados con las especies del animal y algunas características de identificación
- En este ejemplo, cuando se aprende a clasificar imágenes de gatos, el algoritmo toma miles de imágenes de gatos junto con la etiqueta "*gato*"
- El algoritmo aprenderá esta relación y cuando se le muestre una nueva imagen, esta vez sin etiquetas, podrá aplicar esa relación aprendida y determinar si es un gato o no
- Es necesario que la clasificación se haya realizado *a priori* antes de introducir los datos en el algoritmo

- Dependiendo del tipo de salida, suele darse una subcategoría que diferencia entre algoritmos o modelos de:

- Dependiendo del tipo de salida, suele darse una subcategoría que diferencia entre algoritmos o modelos de:
 - **Clasificación:** Si la salida es un valor categórico, una clase o una etiqueta. Por ejemplo, para determinar la clasificación de un animal, un paciente enfermo o no enfermo, una solicitud de crédito como aceptada o rechazada, clasificación de bonos, detección de fraude bancario por parte de entidades financieras, etc

- Dependiendo del tipo de salida, suele darse una subcategoría que diferencia entre algoritmos o modelos de:
 - **Clasificación:** Si la salida es un valor categórico, una clase o una etiqueta. Por ejemplo, para determinar la clasificación de un animal, un paciente enfermo o no enfermo, una solicitud de crédito como aceptada o rechazada, clasificación de bonos, detección de fraude bancario por parte de entidades financieras, etc
 - Los algoritmos o modelos más usuales para esta tarea son: Regresión logística, Support vector machine (SVM), Redes neuronales, Clasificador Naive Bayes, Árboles de decisión, Análisis discriminante, K vecinos más cercanos (kNN), Clasificación a través de ensembles

- Dependiendo del tipo de salida, suele darse una subcategoría que diferencia entre algoritmos o modelos de:
 - **Clasificación:** Si la salida es un valor categórico, una clase o una etiqueta. Por ejemplo, para determinar la clasificación de un animal, un paciente enfermo o no enfermo, una solicitud de crédito como aceptada o rechazada, clasificación de bonos, detección de fraude bancario por parte de entidades financieras, etc
 - Los algoritmos o modelos más usuales para esta tarea son: Regresión logística, Support vector machine (SVM), Redes neuronales, Clasificador Naive Bayes, Árboles de decisión, Análisis discriminante, K vecinos más cercanos (kNN), Clasificación a través de ensembles
 - **Regresión:** Si la salida es un valor continuo o numérico. Como ejemplo podría ser el precio de compra de una casa, precio de alguna opción financiera, demanda de algún servicio, credit scoring, estimar la vida útil de un aparato electrónico, estimar la generación y consumo de energía y precios de la misma, etc

- Que se modela a través de Regresión lineal, Regresión no lineal, Modelos Lineales Generalizados (GLM), Árboles de decisión, Redes neuronales, Regresión con Support Vector Machines, Regresión a través de ensembles

- **Aprendizaje no supervisado:** En este tipo de algoritmos no se tiene etiquetas para los datos de salida, es decir, se trabaja con datos no etiquetados, de ahí que se consideren algoritmos no supervisados o sin supervisión

- **Aprendizaje no supervisado:** En este tipo de algoritmos no se tiene etiquetas para los datos de salida, es decir, se trabaja con datos no etiquetados, de ahí que se consideren algoritmos no supervisados o sin supervisión
- En estos modelos de aprendizaje no supervisado no estamos interesados en ajustar pares (entrada, salida)

- **Aprendizaje no supervisado:** En este tipo de algoritmos no se tiene etiquetas para los datos de salida, es decir, se trabaja con datos no etiquetados, de ahí que se consideren algoritmos no supervisados o sin supervisión
- En estos modelos de aprendizaje no supervisado no estamos interesados en ajustar pares (entrada, salida)
- El objetivo es aumentar el conocimiento estructural de los datos disponibles (y posibles datos futuros), por ejemplo, dando una agrupación según su similaridad (clustering o clusters)

- **Aprendizaje no supervisado:** En este tipo de algoritmos no se tiene etiquetas para los datos de salida, es decir, se trabaja con datos no etiquetados, de ahí que se consideren algoritmos no supervisados o sin supervisión
- En estos modelos de aprendizaje no supervisado no estamos interesados en ajustar pares (entrada, salida)
- El objetivo es aumentar el conocimiento estructural de los datos disponibles (y posibles datos futuros), por ejemplo, dando una agrupación según su similaridad (clustering o clusters)
- Simplificar su estructura manteniendo sus características fundamentales (procesos de reducción de dimensión)

- **Aprendizaje no supervisado:** En este tipo de algoritmos no se tiene etiquetas para los datos de salida, es decir, se trabaja con datos no etiquetados, de ahí que se consideren algoritmos no supervisados o sin supervisión
- En estos modelos de aprendizaje no supervisado no estamos interesados en ajustar pares (entrada, salida)
- El objetivo es aumentar el conocimiento estructural de los datos disponibles (y posibles datos futuros), por ejemplo, dando una agrupación según su similaridad (clustering o clusters)
- Simplificar su estructura manteniendo sus características fundamentales (procesos de reducción de dimensión)
- Extraer la estructura interna con la que se distribuyen los datos en su espacio original (aprendizaje topológico)

- Con este tipo de algoritmos no supervisados, intentamos dar respuesta a preguntas como

- Con este tipo de algoritmos no supervisados, intentamos dar respuesta a preguntas como
 - ¿ Cómo se encuentra o cómo es la estructura subyacente de un conjunto de datos?

- Con este tipo de algoritmos no supervisados, intentamos dar respuesta a preguntas como
 - ¿Cómo se encuentra o cómo es la estructura subyacente de un conjunto de datos?
 - ¿Cómo se resumen y agrupan los datos, para que sean lo más útiles posibles para dar respuesta a los objetivos planteados?

- Con este tipo de algoritmos no supervisados, intentamos dar respuesta a preguntas como
 - ¿Cómo se encuentra o cómo es la estructura subyacente de un conjunto de datos?
 - ¿Cómo se resumen y agrupan los datos, para que sean lo más útiles posibles para dar respuesta a los objetivos planteados?
- En contraste con el aprendizaje supervisado, no siempre es fácil obtener métricas sobre qué tan bien está funcionando un algoritmo de aprendizaje sin supervisión

- Con este tipo de algoritmos no supervisados, intentamos dar respuesta a preguntas como
 - ¿Cómo se encuentra o cómo es la estructura subyacente de un conjunto de datos?
 - ¿Cómo se resumen y agrupan los datos, para que sean lo más útiles posibles para dar respuesta a los objetivos planteados?
- En contraste con el aprendizaje supervisado, no siempre es fácil obtener métricas sobre qué tan bien está funcionando un algoritmo de aprendizaje sin supervisión
- El *rendimiento* usualmente es subjetivo y específico del dominio de aplicación

- Un ejemplo de este tipo de algoritmos es cuando tenemos un conjunto de imágenes de distintos animales

- Un ejemplo de este tipo de algoritmos es cuando tenemos un conjunto de imágenes de distintos animales
- El algoritmo no supervisado simplemente va a agrupar cada uno de los tipos de animales de acuerdo a las características y similitudes que poseen

- Un ejemplo de este tipo de algoritmos es cuando tenemos un conjunto de imágenes de distintos animales
- El algoritmo no supervisado simplemente va a agrupar cada uno de los tipos de animales de acuerdo a las características y similitudes que poseen
- Este agrupamiento será el resultado final o solución del algoritmo

- Un ejemplo de este tipo de algoritmos es cuando tenemos un conjunto de imágenes de distintos animales
- El algoritmo no supervisado simplemente va a agrupar cada uno de los tipos de animales de acuerdo a las características y similitudes que poseen
- Este agrupamiento será el resultado final o solución del algoritmo
- A diferencia con el aprendizaje supervisado, no se sabe exactamente qué animal es

- Un ejemplo de este tipo de algoritmos es cuando tenemos un conjunto de imágenes de distintos animales
- El algoritmo no supervisado simplemente va a agrupar cada uno de los tipos de animales de acuerdo a las características y similitudes que poseen
- Este agrupamiento será el resultado final o solución del algoritmo
- A diferencia con el aprendizaje supervisado, no se sabe exactamente qué animal es
- El algoritmo aprenderá a agrupar los tipos de animales, por ende, cuando se le introduzca un nuevo animal, podrá aplicar esa relación aprendida y determinar a qué grupo pertenece



- Algunos de los algoritmos o modelos más utilizados para esta tarea no supervisada son Cluster, K-means, modelos para mezclas, modelos de reducción de dimensión, algoritmo DBSCAN, entre otros

- **Aprendizaje no supervisado**

- **Aprendizaje no supervisado**
- Contrario al *Aprendizaje Supervisado* donde tenemos un conjunto de variables que usamos para predecir una determinada clase de salida (aprueba/no aprueba, enfermo/sano, reclama/no reclama), en el *Aprendizaje no Supervisado* no tenemos clases de salida esperadas.

- **Aprendizaje no supervisado**

- Contrario al *Aprendizaje Supervisado* donde tenemos un conjunto de variables que usamos para predecir una determinada clase de salida (aprueba/no aprueba, enfermo/sano, reclama/no reclama), en el *Aprendizaje no Supervisado* no tenemos clases de salida esperadas.
- El Aprendizaje no Supervisado (en inglés unsupervised learning o unsupervised machine learning) es un método de análisis de datos que pertenece al campo de la Inteligencia Artificial (IA). Es una rama del Aprendizaje Automático (Machine Learning) en la cual un modelo se entrena para encontrar patrones o estructuras subyacentes en los datos sin la presencia de etiquetas o información de salida predefinida.

- El Aprendizaje no Supervisado consiste en los procesos encargados de encontrar estructuras desconocidas a priori, que se encuentran en un conjunto de datos. Se desconocen las estructuras intrínsecas del conjunto de datos debido a la ausencia de un atributo que, de alguna manera, guíe (supervise) la formación de dichas estructuras

- El Aprendizaje no Supervisado consiste en los procesos encargados de encontrar estructuras desconocidas a priori, que se encuentran en un conjunto de datos. Se desconocen las estructuras intrínsecas del conjunto de datos debido a la ausencia de un atributo que, de alguna manera, guíe (supervise) la formación de dichas estructuras
- A diferencia del Aprendizaje Supervisado, donde se proporcionan ejemplos etiquetados, en el Aprendizaje no Supervisado el modelo debe aprender por sí mismo a partir de la estructura inherente de los datos.

- El Aprendizaje no Supervisado consiste en los procesos encargados de encontrar estructuras desconocidas a priori, que se encuentran en un conjunto de datos. Se desconocen las estructuras intrínsecas del conjunto de datos debido a la ausencia de un atributo que, de alguna manera, guíe (supervise) la formación de dichas estructuras
- A diferencia del Aprendizaje Supervisado, donde se proporcionan ejemplos etiquetados, en el Aprendizaje no Supervisado el modelo debe aprender por sí mismo a partir de la estructura inherente de los datos.
- Los algoritmos de Aprendizaje no Supervisado se centran en la exploración de los datos para encontrar patrones, relaciones o regularidades, y así obtener una comprensión más profunda de los mismos.

- Tipos de aprendizaje no supervisado

- **Tipos de aprendizaje no supervisado**
- Esencialmente existen dos tipos o técnicas de aprendizaje no supervisado. A saber

- **Tipos de aprendizaje no supervisado**
- Esencialmente existen dos tipos o técnicas de aprendizaje no supervisado. A saber
 - **Agrupamiento o cluster:** En este caso se trata de métodos para agrupar observaciones, entre las que destacan los algoritmos de **K-means**, **DBSCAN**, **cluster jerárquico**, **modelos de mezclas**, entre otros.

- **Tipos de aprendizaje no supervisado**
- Esencialmente existen dos tipos o técnicas de aprendizaje no supervisado. A saber
 - **Agrupamiento o cluster:** En este caso se trata de métodos para agrupar observaciones, entre las que destacan los algoritmos de **K-means**, **DBSCAN**, **cluster jerárquico**, **modelos de mezclas**, entre otros.
 - **Reducción de dimensión:** Técnicas como **t-SNE**, **UMAP** , **PCA** (Análisis de Componentes Principales), **Análisis de factores** que permiten visualizar datos de gran dimensionalidad, en espacios de baja dimensión, lo que es crucial para el análisis de grandes volúmenes de datos.

- **Cluster o agrupamiento**

• Cluster o agrupamiento

- El problema de agrupamiento o clustering consiste en la tarea de dividir un conjunto de datos en grupos o clusteres, en la que se *minimice la variación dentro del grupo* y se *maximice la variación entre los grupos*. Tarea importante que ayuda a descubrir patrones ocultos en los datos.

● Cluster o agrupamiento

- El problema de agrupamiento o clustering consiste en la tarea de dividir un conjunto de datos en grupos o clusteres, en la que se *minimice la variación dentro del grupo* y se *maximice la variación entre los grupos*. Tarea importante que ayuda a descubrir patrones ocultos en los datos.
- Las divisiones o particiones se hacen de forma que las observaciones que están dentro de un mismo grupo sean similares entre ellas, y distintas a las de otros grupos

● Cluster o agrupamiento

- El problema de agrupamiento o clustering consiste en la tarea de dividir un conjunto de datos en grupos o clusteres, en la que se *minimice la variación dentro del grupo* y se *maximice la variación entre los grupos*. Tarea importante que ayuda a descubrir patrones ocultos en los datos.
- Las divisiones o particiones se hacen de forma que las observaciones que están dentro de un mismo grupo sean similares entre ellas, y distintas a las de otros grupos
- Realizar agrupaciones en conjuntos multivariados de datos, es una de las actividades más comunes en muchos ámbitos del quehacer humano; una de las más conocidas es la segmentación de un mercado de consumidores, clientes o usuarios que se hace cotidianamente en las áreas de marketing de muchas empresas

- Algoritmos de agrupamiento

- **Algoritmos de agrupamiento**
- Existen varios algoritmos de agrupamiento, cada uno con sus propias fortalezas y debilidades. Como mencionamos anteriormente, algunos de ellos son el *algoritmo K-means*, *DBSCAN*, *cluster jerárquico*, *modelos de mezclas*, entre otros.

- **Algoritmos de agrupamiento**
- Existen varios algoritmos de agrupamiento, cada uno con sus propias fortalezas y debilidades. Como mencionamos anteriormente, algunos de ellos son el *algoritmo K-means*, *DBSCAN*, *cluster jerárquico*, *modelos de mezclas*, entre otros.
- La selección adecuada del algoritmo depende de la naturaleza de los datos y del objetivo que se quiera alcanzar.

- **Algoritmos de agrupamiento**

- Existen varios algoritmos de agrupamiento, cada uno con sus propias fortalezas y debilidades. Como mencionamos anteriormente, algunos de ellos son el *algoritmo K-means*, *DBSCAN*, *cluster jerárquico*, *modelos de mezclas*, entre otros.
- La selección adecuada del algoritmo depende de la naturaleza de los datos y del objetivo que se quiera alcanzar.
- El proceso de agrupamiento es iterativo e interactivo. Se deben identificar los atributos principales (variables) que describen los datos para lograr un mejor proceso de agrupamiento.

- **Algoritmos de agrupamiento**

- Existen varios algoritmos de agrupamiento, cada uno con sus propias fortalezas y debilidades. Como mencionamos anteriormente, algunos de ellos son el *algoritmo K-means*, *DBSCAN*, *cluster jerárquico*, *modelos de mezclas*, entre otros.
- La selección adecuada del algoritmo depende de la naturaleza de los datos y del objetivo que se quiera alcanzar.
- El proceso de agrupamiento es iterativo e interactivo. Se deben identificar los atributos principales (variables) que describen los datos para lograr un mejor proceso de agrupamiento.
- Es importante que las variables que van a determinar los grupos, sean potencialmente distintas en ellos, ya que, de lo contrario, los datos terminarían agrupados en un solo grupo o cluster

- Algoritmo de K-means

- **Algoritmo de K-means**
- Este algoritmo requiere que el número de grupos, **K**, se fije o decida de antemano.

- **Algoritmo de K-means**
- Este algoritmo requiere que el número de grupos, **K**, se fije o decida de antemano.
- Utiliza la *variación intra-cluster* como una medida para formar grupos homogéneos.

- **Algoritmo de K-means**
- Este algoritmo requiere que el número de grupos, **K**, se fije o decida de antemano.
- Utiliza la *variación intra-cluster* como una medida para formar grupos homogéneos.
- El procedimiento tiene como objetivo la segmentación de los datos de tal manera que la variación dentro del grupo se reduzca al mínimo.

- **Algoritmo de K-means**

- Este algoritmo requiere que el número de grupos, **K**, se fije o decida de antemano.
- Utiliza la *variación intra-cluster* como una medida para formar grupos homogéneos.
- El procedimiento tiene como objetivo la segmentación de los datos de tal manera que la variación dentro del grupo se reduzca al mínimo.
- Este procedimiento para formar clusteres, inicia con la asignación aleatoria de los sujetos al número de clusteres definido inicialmente. Este paso inicial puede requerir:

- **Algoritmo de K-means**

- Este algoritmo requiere que el número de grupos, **K**, se fije o decida de antemano.
- Utiliza la *variación intra-cluster* como una medida para formar grupos homogéneos.
- El procedimiento tiene como objetivo la segmentación de los datos de tal manera que la variación dentro del grupo se reduzca al mínimo.
- Este procedimiento para formar clusteres, inicia con la asignación aleatoria de los sujetos al número de clusteres definido inicialmente. Este paso inicial puede requerir:
 - Seleccionar **K** puntos arbitrariamente como centros de los grupos iniciales y, posteriormente, asignar los sujetos más cercanos a dichos puntos.

● Algoritmo de K-means

- Este algoritmo requiere que el número de grupos, **K**, se fije o decida de antemano.
- Utiliza la *variación intra-cluster* como una medida para formar grupos homogéneos.
- El procedimiento tiene como objetivo la segmentación de los datos de tal manera que la variación dentro del grupo se reduzca al mínimo.
- Este procedimiento para formar clusteres, inicia con la asignación aleatoria de los sujetos al número de clusteres definido inicialmente. Este paso inicial puede requerir:
 - Seleccionar **K** puntos arbitrariamente como centros de los grupos iniciales y, posteriormente, asignar los sujetos más cercanos a dichos puntos.
 - Tomar como centros los **K** puntos más alejados entre sí.

- **Algoritmo de K-means**

- Este algoritmo requiere que el número de grupos, **K**, se fije o decida de antemano.
- Utiliza la *variación intra-cluster* como una medida para formar grupos homogéneos.
- El procedimiento tiene como objetivo la segmentación de los datos de tal manera que la variación dentro del grupo se reduzca al mínimo.
- Este procedimiento para formar clusteres, inicia con la asignación aleatoria de los sujetos al número de clusteres definido inicialmente. Este paso inicial puede requerir:
 - Seleccionar **K** puntos arbitrariamente como centros de los grupos iniciales y, posteriormente, asignar los sujetos más cercanos a dichos puntos.
 - Tomar como centros los **K** puntos más alejados entre sí.
 - Determinar los grupos con información a priori, o bien seleccionar los centros a priori

- Una vez realizado este paso inicial, los sujetos son reasignados sucesivamente a otros cluster para minimizar la variación dentro de clusters que, básicamente, es el cuadrado de la distancia de cada observación al centro de su cluster asociado.

- Una vez realizado este paso inicial, los sujetos son reasignados sucesivamente a otros cluster para minimizar la variación dentro de clusters que, básicamente, es el cuadrado de la distancia de cada observación al centro de su cluster asociado.
- Si la asignación de un sujeto a otro cluster decrece la variación intra clusters, esta observación es reasignada a dicho cluster, y se recalculan las medias de los grupos. Este proceso genera clusters internamente homogéneos y externamente heterogéneos

- Una vez realizado este paso inicial, los sujetos son reasignados sucesivamente a otros cluster para minimizar la variación dentro de clusters que, básicamente, es el cuadrado de la distancia de cada observación al centro de su cluster asociado.
- Si la asignación de un sujeto a otro cluster decrece la variación intra clusters, esta observación es reasignada a dicho cluster, y se recalculan las medias de los grupos. Este proceso genera clusters internamente homogéneos y externamente heterogéneos
- En este caso, el criterio de homogeneidad consiste en minimizar las distancias al cuadrado entre los centros de los grupos y los puntos que pertenecen a ese grupo. Las distancias se calculan utilizando la norma o distancia euclídeana entre las observaciones.

- Métodos jerárquicos

- **Métodos jerárquicos**

- Los métodos jerárquicos para construir clusters no requiere que se pre-especifique el número de clusters. Utilizan las distancias entre los sujetos para irlos agrupando de acuerdo a la similitud entre ellos.

- **Métodos jerárquicos**

- Los métodos jerárquicos para construir clusters no requiere que se pre-especifique el número de clusters. Utilizan las distancias entre los sujetos para irlos agrupando de acuerdo a la similitud entre ellos.
- Los métodos jerárquicos se subdividen en dos tipos dependiendo de la estrategia seguida para crear los grupos

- **Métodos jerárquicos**

- Los métodos jerárquicos para construir clusters no requiere que se pre-especifique el número de clusters. Utilizan las distancias entre los sujetos para irlos agrupando de acuerdo a la similitud entre ellos.
- Los métodos jerárquicos se subdividen en dos tipos dependiendo de la estrategia seguida para crear los grupos
- **Aglomerativos**: el agrupamiento se inicia considerando que cada observación forma un cluster individual. Los clusters se van uniendo hasta formar uno solo.

- **Métodos jerárquicos**

- Los métodos jerárquicos para construir clusters no requiere que se pre-especifique el número de clusters. Utilizan las distancias entre los sujetos para irlos agrupando de acuerdo a la similitud entre ellos.
- Los métodos jerárquicos se subdividen en dos tipos dependiendo de la estrategia seguida para crear los grupos
- **Aglomerativos**: el agrupamiento se inicia considerando que cada observación forma un cluster individual. Los clusters se van uniendo hasta formar uno solo.
- **Divisivos**: Estrategia opuesta al método aglomerativo, que inicia suponiendo que todas las observaciones forman un único cluster y se suceden divisiones hasta que cada observación forma un cluster individual.

- **Algoritmo método aglomerativo**

- **Algoritmo método aglomerativo**
- El proceso se inicia considerando cada una de las observaciones como un cluster individual.

- **Algoritmo método aglomerativo**
- El proceso se inicia considerando cada una de las observaciones como un cluster individual.
- Se inicia un proceso iterativo hasta que todas las observaciones pertenecen a un único cluster:

- **Algoritmo método aglomerativo**
- El proceso se inicia considerando cada una de las observaciones como un cluster individual.
- Se inicia un proceso iterativo hasta que todas las observaciones pertenecen a un único cluster:
 - Se calcula la distancia entre cada posible par de los n clusters. El investigador debe determinar el tipo de medida emplea para cuantificar la similitud entre observaciones o grupos (distancia y liga).

- **Algoritmo método aglomerativo**

- El proceso se inicia considerando cada una de las observaciones como un cluster individual.
- Se inicia un proceso iterativo hasta que todas las observaciones pertenecen a un único cluster:
 - Se calcula la distancia entre cada posible par de los n clusters. El investigador debe determinar el tipo de medida emplea para cuantificar la similitud entre observaciones o grupos (distancia y liga).
 - Los dos clusters más similares se fusionan, de forma que quedan $n-1$ clusters.

- **Algoritmo método aglomerativo**
- El proceso se inicia considerando cada una de las observaciones como un cluster individual.
- Se inicia un proceso iterativo hasta que todas las observaciones pertenecen a un único cluster:
 - Se calcula la distancia entre cada posible par de los n clusters. El investigador debe determinar el tipo de medida emplea para cuantificar la similitud entre observaciones o grupos (distancia y liga).
 - Los dos clusters más similares se fusionan, de forma que quedan $n-1$ clusters.
 - Se continúa el proceso hasta obtener un único cluster. En estos pasos subsecuentes al primer agrupamiento, las distancias requeridas son entre observaciones, entre clusters y entre observaciones y clusters

- **Algoritmo método aglomerativo**
- El proceso se inicia considerando cada una de las observaciones como un cluster individual.
- Se inicia un proceso iterativo hasta que todas las observaciones pertenecen a un único cluster:
 - Se calcula la distancia entre cada posible par de los n clusters. El investigador debe determinar el tipo de medida emplea para cuantificar la similitud entre observaciones o grupos (distancia y liga).
 - Los dos clusters más similares se fusionan, de forma que quedan $n-1$ clusters.
 - Se continúa el proceso hasta obtener un único cluster. En estos pasos subsecuentes al primer agrupamiento, las distancias requeridas son entre observaciones, entre clusters y entre observaciones y clusters
- Determinar dónde cortar la estructura generada (dendrograma)

- **Métodos divisivos**

- **Métodos divisivos**
- El algoritmo más conocido de los métodos divisivos es **DIANA** (**DI**visive **ANA**lysis Clustering).

- **Métodos divisivos**

- El algoritmo más conocido de los métodos divisivos es **DIANA** (**DI**visive **ANA**lysis Clustering).
- Este algoritmo inicia con un único cluster que contiene todas las observaciones, a continuación, se van sucediendo divisiones hasta que cada observación forma un cluster independiente.

- **Métodos divisivos**

- El algoritmo más conocido de los métodos divisivos es **DIANA** (**DI**visive **ANA**lysis Clustering).
- Este algoritmo inicia con un único cluster que contiene todas las observaciones, a continuación, se van sucediendo divisiones hasta que cada observación forma un cluster independiente.
- En cada iteración se selecciona el cluster con mayor diámetro, entendiendo por diámetro de un cluster la mayor de las diferencias entre dos de sus observaciones.

- **Métodos divisivos**

- El algoritmo más conocido de los métodos divisivos es **DIANA** (**D**ivisive **A**NAlysis Clustering).
- Este algoritmo inicia con un único cluster que contiene todas las observaciones, a continuación, se van sucediendo divisiones hasta que cada observación forma un cluster independiente.
- En cada iteración se selecciona el cluster con mayor diámetro, entendiendo por diámetro de un cluster la mayor de las diferencias entre dos de sus observaciones.
- Una vez seleccionado el cluster, se identifica la observación más dispar, que es aquella con mayor distancia promedio respecto al resto de observaciones que forman el cluster, esta observación inicia el nuevo cluster.

- **Métodos divisivos**

- El algoritmo más conocido de los métodos divisivos es **DIANA** (**D**ivisive **A**NALysis Clustering).
- Este algoritmo inicia con un único cluster que contiene todas las observaciones, a continuación, se van sucediendo divisiones hasta que cada observación forma un cluster independiente.
- En cada iteración se selecciona el cluster con mayor diámetro, entendiendo por diámetro de un cluster la mayor de las diferencias entre dos de sus observaciones.
- Una vez seleccionado el cluster, se identifica la observación más dispar, que es aquella con mayor distancia promedio respecto al resto de observaciones que forman el cluster, esta observación inicia el nuevo cluster.
- Se reasignan las observaciones en función de si están más próximas al nuevo cluster o al resto de la partición, dividiendo así el cluster seleccionado en dos nuevos clusters

- **Algoritmo método divisivo**

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.
 - Calcular la distancia media de cada observación respecto a las demás.

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.
 - Calcular la distancia media de cada observación respecto a las demás.
 - La observación más distante inicia un nuevo cluster

- **Algoritmo método divisivo**

- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.
 - Calcular la distancia media de cada observación respecto a las demás.
 - La observación más distante inicia un nuevo cluster
 - Se reasignan las observaciones restantes al nuevo cluster o al viejo dependiendo de cual está más próximo.

- **Algoritmo método divisivo**

- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.
 - Calcular la distancia media de cada observación respecto a las demás.
 - La observación más distante inicia un nuevo cluster
 - Se reasignan las observaciones restantes al nuevo cluster o al viejo dependiendo de cual está más próximo.
- A diferencia del proceso aglomerativo, en el que hay que elegir un tipo de distancia y la liga, en el proceso divisivo sólo hay que elegir la distancia, no hay liga

- **Algoritmo DBSCAN: Density-Based Spatial Clustering of Applications with Noise**

- **Algoritmo DBSCAN: Density-Based Spatial Clustering of Applications with Noise**
- DBSCAN es, hoy en día, un algoritmo tan popular como K-means.

- **Algoritmo DBSCAN: Density-Based Spatial Clustering of Applications with Noise**
- DBSCAN es, hoy en día, un algoritmo tan popular como K-means.
- Es un algoritmo de agrupamiento basado en densidades que puede utilizarse para identificar clusteres de cualquier forma en un conjunto de datos, además de identificar datos atípicos que no forman parte de ningún grupo.

- **Algoritmo DBSCAN: Density-Based Spatial Clustering of Applications with Noise**
- DBSCAN es, hoy en día, un algoritmo tan popular como K-means.
- Es un algoritmo de agrupamiento basado en densidades que puede utilizarse para identificar clusteres de cualquier forma en un conjunto de datos, además de identificar datos atípicos que no forman parte de ningún grupo.
- DBSCAN se basa en la idea intuitiva de que para que una observación forme parte de un cluster, tiene que haber un mínimo de observaciones vecinas dentro de un radio de proximidad, y de que los clusteres están separados por regiones vacías o con pocas observaciones

- **Algoritmo DBSCAN: Density-Based Spatial Clustering of Applications with Noise**
- DBSCAN es, hoy en día, un algoritmo tan popular como K-means.
- Es un algoritmo de agrupamiento basado en densidades que puede utilizarse para identificar clusteres de cualquier forma en un conjunto de datos, además de identificar datos atípicos que no forman parte de ningún grupo.
- DBSCAN se basa en la idea intuitiva de que para que una observación forme parte de un cluster, tiene que haber un mínimo de observaciones vecinas dentro de un radio de proximidad, y de que los clusteres están separados por regiones vacías o con pocas observaciones
- Este algoritmo agrupa los puntos que están más cercanos respecto a alguna métrica, comúnmente se utiliza la distancia euclidiana. Además, para este algoritmo se tiene que cada cluster debe contener un mínimo de puntos.

- **Diferencias con otros métodos para formar clusteres**

- **Diferencias con otros métodos para formar clusteres**
- Este método tiene sus ventajas y desventajas respecto a otros métodos de agrupación (por ejemplo, K-means) y, dependiendo del problema que se quiera analizar, se debe elegir el método más adecuado. Aún así hay varios aspectos que deben considerarse

- **Diferencias con otros métodos para formar clusteres**
- Este método tiene sus ventajas y desventajas respecto a otros métodos de agrupación (por ejemplo, K-means) y, dependiendo del problema que se quiera analizar, se debe elegir el método más adecuado. Aún así hay varios aspectos que deben considerarse
- **Ventajas**

- **Diferencias con otros métodos para formar clusteres**
- Este método tiene sus ventajas y desventajas respecto a otros métodos de agrupación (por ejemplo, K-means) y, dependiendo del problema que se quiera analizar, se debe elegir el método más adecuado. Aún así hay varios aspectos que deben considerarse
- **Ventajas**
 - DBSCAN no necesita que se especifique el número de clusteres

- **Diferencias con otros métodos para formar clusteres**
- Este método tiene sus ventajas y desventajas respecto a otros métodos de agrupación (por ejemplo, K-means) y, dependiendo del problema que se quiera analizar, se debe elegir el método más adecuado. Aún así hay varios aspectos que deben considerarse
- **Ventajas**
 - DBSCAN no necesita que se especifique el número de clusteres
 - Es más fácil de implementar y de entender

- **Diferencias con otros métodos para formar clusteres**
- Este método tiene sus ventajas y desventajas respecto a otros métodos de agrupación (por ejemplo, K-means) y, dependiendo del problema que se quiera analizar, se debe elegir el método más adecuado. Aún así hay varios aspectos que deben considerarse
- **Ventajas**
 - DBSCAN no necesita que se especifique el número de clusteres
 - Es más fácil de implementar y de entender
 - Garantiza que cada cluster tendrá un mínimo número de puntos

- **Diferencias con otros métodos para formar clusteres**

- Este método tiene sus ventajas y desventajas respecto a otros métodos de agrupación (por ejemplo, K-means) y, dependiendo del problema que se quiera analizar, se debe elegir el método más adecuado. Aún así hay varios aspectos que deben considerarse

- **Ventajas**

- DBSCAN no necesita que se especifique el número de clusteres
- Es más fácil de implementar y de entender
- Garantiza que cada cluster tendrá un mínimo número de puntos
- Puede encontrar cualquier forma de cluster. El cluster no tiene que ser circular

- **Diferencias con otros métodos para formar clusteres**

- Este método tiene sus ventajas y desventajas respecto a otros métodos de agrupación (por ejemplo, K-means) y, dependiendo del problema que se quiera analizar, se debe elegir el método más adecuado. Aún así hay varios aspectos que deben considerarse

- **Ventajas**

- DBSCAN no necesita que se especifique el número de clusteres
- Es más fácil de implementar y de entender
- Garantiza que cada cluster tendrá un mínimo número de puntos
- Puede encontrar cualquier forma de cluster. El cluster no tiene que ser circular
- Puede manejar muy bien el ruido en las observaciones y valores atípicos

- **Diferencias con otros métodos para formar clusteres**

- Este método tiene sus ventajas y desventajas respecto a otros métodos de agrupación (por ejemplo, K-means) y, dependiendo del problema que se quiera analizar, se debe elegir el método más adecuado. Aún así hay varios aspectos que deben considerarse

- **Ventajas**

- DBSCAN no necesita que se especifique el número de clusteres
- Es más fácil de implementar y de entender
- Garantiza que cada cluster tendrá un mínimo número de puntos
- Puede encontrar cualquier forma de cluster. El cluster no tiene que ser circular
- Puede manejar muy bien el ruido en las observaciones y valores atípicos
- Es excelente para separar clusteres de alta densidad frente a clusteres de baja densidad dentro de un conjunto de datos determinado

- **Desventajas**

- **Desventajas**

- DBSCAN es menos rápido (o más lento) que K-means

● Desventajas

- DBSCAN es menos rápido (o más lento) que K-means
- No funciona bien en clusteres de diferentes densidades. Si la base de datos tiene puntos de datos que forman clusteres de densidad variable, entonces DBSCAN no puede agrupar bien los puntos, ya que el agrupamiento depende de los parámetros ϵ y $minPts$, que no se pueden seleccionar por separado para todos los clusteres

● Desventajas

- DBSCAN es menos rápido (o más lento) que K-means
- No funciona bien en clusteres de diferentes densidades. Si la base de datos tiene puntos de datos que forman clusteres de densidad variable, entonces DBSCAN no puede agrupar bien los puntos, ya que el agrupamiento depende de los parámetros ϵ y $minPts$, que no se pueden seleccionar por separado para todos los clusteres
- Si los datos y características no son bien propuestos y analizados por un sujeto experto del área de aplicación, entonces configurar ϵ y $minPts$ puede ser complicado y podría necesitar comparaciones para varias iteraciones con diferentes valores de estos dos parámetros

● Desventajas

- DBSCAN es menos rápido (o más lento) que K-means
- No funciona bien en clusteres de diferentes densidades. Si la base de datos tiene puntos de datos que forman clusteres de densidad variable, entonces DBSCAN no puede agrupar bien los puntos, ya que el agrupamiento depende de los parámetros ϵ y $minPts$, que no se pueden seleccionar por separado para todos los clusteres
- Si los datos y características no son bien propuestos y analizados por un sujeto experto del área de aplicación, entonces configurar ϵ y $minPts$ puede ser complicado y podría necesitar comparaciones para varias iteraciones con diferentes valores de estos dos parámetros
- Los parámetros deben elegirse con mucho cuidado o precisión. Es extremadamente sensible a la elección de estos parámetros. Un ligero cambio en ellos puede llevar a un cambio drástico en el resultado

- **Parámetros**

- **Parámetros**
- El algoritmo DBSCAN requiere básicamente 2 parámetros:

- **Parámetros**

- El algoritmo DBSCAN requiere básicamente 2 parámetros:
 - ϵ (**eps**): especifica lo cercanos que deben estar los puntos entre sí para ser considerados parte de un cluster. Esto significa que, si la distancia entre dos puntos es menor o igual a este valor de ϵ , estos puntos se consideran vecinos

- **Parámetros**

- El algoritmo DBSCAN requiere básicamente 2 parámetros:
 - ϵ (**eps**): especifica lo cercanos que deben estar los puntos entre sí para ser considerados parte de un cluster. Esto significa que, si la distancia entre dos puntos es menor o igual a este valor de ϵ , estos puntos se consideran vecinos
 - Mínimo de puntos (**minPts**): el número mínimo de puntos para formar una región densa. Por ejemplo, si establecemos minPts igual a 5, entonces necesitamos al menos 5 puntos para formar una región densa

- Otros algoritmos de agrupamiento basados en densidad

- Otros algoritmos de agrupamiento basados en densidad
- **HDBSCAN: Hierarchical Density-Based Spatial Clustering**. Es una versión mejorada de DBSCAN, permite detectar clusteres de diferentes densidades, y tiene la capacidad de construir una jerarquía de clusteres.

- Otros algoritmos de agrupamiento basados en densidad
- **HDBSCAN: Hierarchical Density-Based Spatial Clustering.** Es una versión mejorada de DBSCAN, permite detectar clusteres de diferentes densidades, y tiene la capacidad de construir una jerarquía de clusteres.
- **OPTICS: Ordering Points To Identify the Clustering Structure.** Es un algoritmo que permite la identificación de clusteres de diferentes densidades sin tener que evaluar diferentes parámetros, y es capaz de detectar clusteres que no son separables espacialmente por no cumplir una densidad mínima.

- **Clusteres con mezclas de distribuciones gaussianas:
Distribution-based clustering**

- **Clusteres con mezclas de distribuciones gaussianas:**
Distribution-based clustering

- Los algoritmos de agrupamiento tradicionales, como K-means y los métodos de agrupamiento jerárquico, son algoritmos basados en heurísticas que derivan los clusteres directamente en función de los datos en lugar de incorporar una medida de probabilidad o de incertidumbre a las observaciones asignadas en estos clusteres.

- **Clusteres con mezclas de distribuciones gaussianas:
Distribution-based clustering**
- Los algoritmos de agrupamiento tradicionales, como K-means y los métodos de agrupamiento jerárquico, son algoritmos basados en heurísticas que derivan los clusteres directamente en función de los datos en lugar de incorporar una medida de probabilidad o de incertidumbre a las observaciones asignadas en estos clusteres.
- El agrupamiento basado en modelos (Model-based clustering) salva esta situación al proporcionar una asignación flexible en la que las observaciones tienen una probabilidad de pertenecer a cada cluster. Además, el agrupamiento basado en modelos proporciona el beneficio adicional de identificar automáticamente el número óptimo de clusteres.

- **Clusteres con mezclas de distribuciones gaussianas:**
Distribution-based clustering

- Los algoritmos de agrupamiento tradicionales, como K-means y los métodos de agrupamiento jerárquico, son algoritmos basados en heurísticas que derivan los clusteres directamente en función de los datos en lugar de incorporar una medida de probabilidad o de incertidumbre a las observaciones asignadas en estos clusteres.
- El agrupamiento basado en modelos (Model-based clustering) salva esta situación al proporcionar una asignación flexible en la que las observaciones tienen una probabilidad de pertenecer a cada cluster. Además, el agrupamiento basado en modelos proporciona el beneficio adicional de identificar automáticamente el número óptimo de clusteres.
- Los *modelos de mezclas gaussianas* son modelos probabilísticos para representar subpoblaciones (grupos) *distribuidas normalmente* dentro de una población general.

- Un modelo de mezclas gaussianas está determinado por dos parámetros: los pesos de los componentes de la mezcla y las matrices de varianza-covarianza de los componentes (para el caso multivariado).

- Un modelo de mezclas gaussianas está determinado por dos parámetros: los pesos de los componentes de la mezcla y las matrices de varianza-covarianza de los componentes (para el caso multivariado).
- Si se conoce el número de componentes, el **algoritmo EM** es la técnica que se utiliza con mayor frecuencia para estimar los parámetros del modelo.

- Un modelo de mezclas gaussianas está determinado por dos parámetros: los pesos de los componentes de la mezcla y las matrices de varianza-covarianza de los componentes (para el caso multivariado).
- Si se conoce el número de componentes, el **algoritmo EM** es la técnica que se utiliza con mayor frecuencia para estimar los parámetros del modelo.
- En un proceso estándar de agrupamiento, el objetivo final es asignar cada una de las observaciones a su correspondiente cluster, por medio de una etiqueta. Esta asignación es clara cuando los clusters muestran una buena separación entre ellos.

- Un modelo de mezclas gaussianas está determinado por dos parámetros: los pesos de los componentes de la mezcla y las matrices de varianza-covarianza de los componentes (para el caso multivariado).
- Si se conoce el número de componentes, el **algoritmo EM** es la técnica que se utiliza con mayor frecuencia para estimar los parámetros del modelo.
- En un proceso estándar de agrupamiento, el objetivo final es asignar cada una de las observaciones a su correspondiente cluster, por medio de una etiqueta. Esta asignación es clara cuando los clusters muestran una buena separación entre ellos.
- Sin embargo, en situaciones donde existe menos separación entre los grupos, muchas veces resulta más útil asignar probabilidades de pertenencia a cada cluster, en vez de directamente asignar una etiqueta. Esta tarea la podemos realizar mediante modelos de mezclas Gaussianas.

- Aplicaciones de clusters

- **Aplicaciones de clusters**

- **Segmentación del mercado:** las empresas deben segmentar su mercado en grupos más pequeños para comprender el público objetivo.

- **Aplicaciones de clusters**

- **Segmentación del mercado:** las empresas deben segmentar su mercado en grupos más pequeños para comprender el público objetivo.
- **Marketing y ventas minoristas:** el marketing utiliza la agrupación para comprender el comportamiento de compra de los clientes para regular la cadena de suministro y las recomendaciones.

- **Aplicaciones de clusters**

- **Segmentación del mercado:** las empresas deben segmentar su mercado en grupos más pequeños para comprender el público objetivo.
- **Marketing y ventas minoristas:** el marketing utiliza la agrupación para comprender el comportamiento de compra de los clientes para regular la cadena de suministro y las recomendaciones.
- **Análisis de redes sociales:** examinar los arreglos sociales cualitativos y cuantitativos utilizando la teoría de la red y los gráficos.

- **Aplicaciones de clusters**

- **Segmentación del mercado:** las empresas deben segmentar su mercado en grupos más pequeños para comprender el público objetivo.
- **Marketing y ventas minoristas:** el marketing utiliza la agrupación para comprender el comportamiento de compra de los clientes para regular la cadena de suministro y las recomendaciones.
- **Análisis de redes sociales:** examinar los arreglos sociales cualitativos y cuantitativos utilizando la teoría de la red y los gráficos.
- **Análisis de red inalámbrica o clasificación de tráfico de red:** agrupaciones de las características de las fuentes de tráfico de red.

- Siguen aplicaciones...

- Siguen aplicaciones...
 - **Compresión de imagen:** la agrupación ayuda a almacenar las imágenes en forma comprimida reduciendo el tamaño de la imagen sin ningún compromiso de calidad.

- Siguen aplicaciones...
 - **Compresión de imagen:** la agrupación ayuda a almacenar las imágenes en forma comprimida reduciendo el tamaño de la imagen sin ningún compromiso de calidad.
 - **Regulación de servicios de transmisión:** identificar a los espectadores que tienen comportamientos e intereses similares. Netflix y otras plataformas agrupan a los usuarios en función de parámetros como el género, los minutos observados por día y las sesiones de visualización totales, entre otras características

- Siguen aplicaciones...
 - **Compresión de imagen:** la agrupación ayuda a almacenar las imágenes en forma comprimida reduciendo el tamaño de la imagen sin ningún compromiso de calidad.
 - **Regulación de servicios de transmisión:** identificar a los espectadores que tienen comportamientos e intereses similares. Netflix y otras plataformas agrupan a los usuarios en función de parámetros como el género, los minutos observados por día y las sesiones de visualización totales, entre otras características
 - **Ciencias de la vida y atención médica:** la agrupación crea taxonomías de plantas y animales para organizar genes con funciones análogas.

- **Técnicas de reducción de dimensión**

- Técnicas de reducción de dimensión
- Componentes principales

- Técnicas de reducción de dimensión
- Componentes principales
- Introducción

- **Técnicas de reducción de dimensión**
- **Componentes principales**
- **Introducción**
- El objetivo principal de la mayoría de las técnicas numéricas de análisis multivariado, es reducir la dimensión de nuestros datos. Si esta reducción se puede hacer a 2 ó 3 dimensiones, se tiene la posibilidad de una visión gráfica de los mismos.

- **Técnicas de reducción de dimensión**
- **Componentes principales**
- **Introducción**
- El objetivo principal de la mayoría de las técnicas numéricas de análisis multivariado, es reducir la dimensión de nuestros datos. Si esta reducción se puede hacer a 2 ó 3 dimensiones, se tiene la posibilidad de una visión gráfica de los mismos.
- Obvio, *siempre* es posible hacer la reducción a este número de dimensiones, pero es importante juzgar si estas pocas dimensiones son suficientes para resumir la información contenida en todas las variables.

● Técnicas de reducción de dimensión

● Componentes principales

● Introducción

- El objetivo principal de la mayoría de las técnicas numéricas de análisis multivariado, es reducir la dimensión de nuestros datos. Si esta reducción se puede hacer a 2 ó 3 dimensiones, se tiene la posibilidad de una visión gráfica de los mismos.
- Obvio, *siempre* es posible hacer la reducción a este número de dimensiones, pero es importante juzgar si estas pocas dimensiones son suficientes para resumir la información contenida en todas las variables.
- El *análisis de componentes principales* es parte de las técnicas de *Aprendizaje no Supervisado*, porque, como en la mayoría de las técnicas de análisis multivariado, no tenemos una variable de respuesta.

- En esta situación sólo contamos con un número, usualmente muy grande, de variables que nos interesa analizar o estudiar, y de las que queremos extraer información, por ejemplo, sobre la existencia de subgrupos entre las variables u observaciones, valores atípicos, estructura de asociación entre variables, etc.

- En esta situación sólo contamos con un número, usualmente muy grande, de variables que nos interesa analizar o estudiar, y de las que queremos extraer información, por ejemplo, sobre la existencia de subgrupos entre las variables u observaciones, valores atípicos, estructura de asociación entre variables, etc.
- El *análisis de componentes principales* tiene como objetivo: dadas n observaciones de p variables, se analiza si es posible representar adecuadamente esta información con un número menor, $q \ll p$ (reducción de dimensión), de *variables construidas como combinaciones lineales de las originales*, llamadas *componentes principales*.

- En concreto, los objetivos del análisis de componentes principales son:

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados
 - Encontrar agrupaciones

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados
 - Encontrar agrupaciones
 - Encontrar datos atípicos

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados
 - Encontrar agrupaciones
 - Encontrar datos atípicos
 - Como auxiliar para combatir la multicolinealidad en los modelos de regresión

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados
 - Encontrar agrupaciones
 - Encontrar datos atípicos
 - Como auxiliar para combatir la multicolinealidad en los modelos de regresión
 - Reducir el número de variables a utilizar en la aplicación de alguna técnica de Aprendizaje Supervisado

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados
 - Encontrar agrupaciones
 - Encontrar datos atípicos
 - Como auxiliar para combatir la multicolinealidad en los modelos de regresión
 - Reducir el número de variables a utilizar en la aplicación de alguna técnica de Aprendizaje Supervisado
 - Este último objetivo, puede ayudar a disminuir el tiempo y esfuerzo computacional al realizar una tarea de Aprendizaje Supervisado

- ¿Qué hace?

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible
 - Cada componente subsecuente explica la mayor cantidad de la variabilidad restante de los datos, que sea posible

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible
 - Cada componente subsecuente explica la mayor cantidad de la variabilidad restante de los datos, que sea posible
- Las componentes son de la forma:

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible
 - Cada componente subsecuente explica la mayor cantidad de la variabilidad restante de los datos, que sea posible
- Las componentes son de la forma:
-

$$Z_i = a_i'X = a_{i1}X_1 + a_{i2}X_2 + \cdots + a_{ip}X_p \quad i = 1, 2, \dots, p \quad \text{ó}$$

$$Z_i = a_i'(X - \mu) \text{ (centradas)}$$

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible
 - Cada componente subsecuente explica la mayor cantidad de la variabilidad restante de los datos, que sea posible
- Las componentes son de la forma:
-

$$Z_i = a_i'X = a_{i1}X_1 + a_{i2}X_2 + \cdots + a_{ip}X_p \quad i = 1, 2, \dots, p \quad \text{ó}$$

$$Z_i = a_i'(X - \mu) \text{ (centradas)}$$

- Es decir, son combinaciones lineales de las p variables.

- **t-Distributed Stochastic Neighbor Embedding (t-SNE)**

- **t-Distributed Stochastic Neighbor Embedding (t-SNE)**
- *t-SNE* es un algoritmo que se utiliza para visualizar datos de alta dimensión. Debido a que no podemos visualizar nada que tenga más de dos (o quizás tres) dimensiones, t-SNE lo hace reduciendo la dimensión de los datos, mientras preserva la estructura de los mismos tanto como sea posible.

- **t-Distributed Stochastic Neighbor Embedding (t-SNE)**
- *t-SNE* es un algoritmo que se utiliza para visualizar datos de alta dimensión. Debido a que no podemos visualizar nada que tenga más de dos (o quizás tres) dimensiones, t-SNE lo hace reduciendo la dimensión de los datos, mientras preserva la estructura de los mismos tanto como sea posible.
- Si comparamos t-SNE con PCA, vemos que PCA intenta preservar la información en los datos (a través de la varianza), mientras que t-SNE intentaría preservar las distancias relativas y la estructura de agrupamiento en los datos, dando menor importancia a la información total preservada.

- **t-Distributed Stochastic Neighbor Embedding (t-SNE)**
- *t-SNE* es un algoritmo que se utiliza para visualizar datos de alta dimensión. Debido a que no podemos visualizar nada que tenga más de dos (o quizás tres) dimensiones, t-SNE lo hace reduciendo la dimensión de los datos, mientras preserva la estructura de los mismos tanto como sea posible.
- Si comparamos t-SNE con PCA, vemos que PCA intenta preservar la información en los datos (a través de la varianza), mientras que t-SNE intentaría preservar las distancias relativas y la estructura de agrupamiento en los datos, dando menor importancia a la información total preservada.
- t-SNE es un algoritmo *no lineal* de reducción de dimensión, que representa cada objeto de alta dimensión por un punto bidimensional o tridimensional, de tal manera que los objetos similares se plasman en puntos cercanos y los objetos diferentes en puntos distantes.

- La idea central detrás de t-SNE es mapear puntos de datos de alta dimensión a un espacio de menor dimensión, típicamente dos o tres dimensiones, de una manera que preserve las relaciones locales entre los puntos.

- La idea central detrás de t-SNE es mapear puntos de datos de alta dimensión a un espacio de menor dimensión, típicamente dos o tres dimensiones, de una manera que preserve las relaciones locales entre los puntos.
- Matemáticamente, busca minimizar la divergencia entre dos distribuciones: una distribución que mide similitudes por pares de los objetos de entrada (datos en la dimensión original) y una distribución que mide similitudes por pares de los correspondientes puntos en baja dimensión.

- La idea central detrás de t-SNE es mapear puntos de datos de alta dimensión a un espacio de menor dimensión, típicamente dos o tres dimensiones, de una manera que preserve las relaciones locales entre los puntos.
- Matemáticamente, busca minimizar la divergencia entre dos distribuciones: una distribución que mide similitudes por pares de los objetos de entrada (datos en la dimensión original) y una distribución que mide similitudes por pares de los correspondientes puntos en baja dimensión.
- Entonces, minimiza la diferencia entre estas dos distribuciones utilizando una técnica llamada descenso de gradiente (minimiza la divergencia Kullback-Leibler entre las distribuciones).

- La idea central detrás de t-SNE es mapear puntos de datos de alta dimensión a un espacio de menor dimensión, típicamente dos o tres dimensiones, de una manera que preserve las relaciones locales entre los puntos.
- Matemáticamente, busca minimizar la divergencia entre dos distribuciones: una distribución que mide similitudes por pares de los objetos de entrada (datos en la dimensión original) y una distribución que mide similitudes por pares de los correspondientes puntos en baja dimensión.
- Entonces, minimiza la diferencia entre estas dos distribuciones utilizando una técnica llamada descenso de gradiente (minimiza la divergencia Kullback-Leibler entre las distribuciones).
- Este proceso permite que t-SNE capture eficazmente la estructura local de los datos, lo que lo hace particularmente útil para visualizar conjuntos de datos complejos y descubrir patrones interesantes.

- Los pasos del algoritmo son:

- Los pasos del algoritmo son:
 - Calcular similitudes por pares

- Los pasos del algoritmo son:
 - Calcular similitudes por pares
 - Construir distribuciones de probabilidad a partir de las similitudes anteriores

- Los pasos del algoritmo son:
 - Calcular similitudes por pares
 - Construir distribuciones de probabilidad a partir de las similitudes anteriores
 - Minimizar la divergencia de Kullback-Leibler: utilizar la técnica de el descenso de gradiente para encontrar una representación de baja dimensión que minimice la divergencia entre las dos distribuciones.

- **UMAP: Uniform Manifold Approximation and Projection**

- **UMAP: Uniform Manifold Approximation and Projection**
- Uniform Manifold Approximation and Projection (UMAP) es una potente técnica de reducción de dimensión que ha ganado una gran aceptación en los campos del aprendizaje automático y la visualización de datos.

- **UMAP: Uniform Manifold Approximation and Projection**
- Uniform Manifold Approximation and Projection (UMAP) es una potente técnica de reducción de dimensión que ha ganado una gran aceptación en los campos del aprendizaje automático y la visualización de datos.
- UMAP, está basada en sólidos fundamentos matemáticos, como la geometría de Riemann y la topología algebraica.

- **UMAP: Uniform Manifold Approximation and Projection**
- Uniform Manifold Approximation and Projection (UMAP) es una potente técnica de reducción de dimensión que ha ganado una gran aceptación en los campos del aprendizaje automático y la visualización de datos.
- UMAP, está basada en sólidos fundamentos matemáticos, como la geometría de Riemann y la topología algebraica.
- Es una técnica de aprendizaje no supervisado que tiene como objetivo reducir la dimensionalidad de los datos y, al mismo tiempo, preservar su estructura topológica.

- **UMAP: Uniform Manifold Approximation and Projection**
- Uniform Manifold Approximation and Projection (UMAP) es una potente técnica de reducción de dimensión que ha ganado una gran aceptación en los campos del aprendizaje automático y la visualización de datos.
- UMAP, está basada en sólidos fundamentos matemáticos, como la geometría de Riemann y la topología algebraica.
- Es una técnica de aprendizaje no supervisado que tiene como objetivo reducir la dimensionalidad de los datos y, al mismo tiempo, preservar su estructura topológica.
- Es particularmente útil para visualizar conjuntos de datos de alta dimensión en un espacio de baja dimensión, generalmente de dos o tres dimensiones.

- UMAP se compara a menudo con t-SNE (t-distributed Stochastic Neighbor Embedding) debido a su aplicación similar en la visualización de datos, pero ofrece varias ventajas, incluida una mejor preservación de la estructura global de los datos y tiempos de cálculo más rápidos.

- UMAP se compara a menudo con t-SNE (t-distributed Stochastic Neighbor Embedding) debido a su aplicación similar en la visualización de datos, pero ofrece varias ventajas, incluida una mejor preservación de la estructura global de los datos y tiempos de cálculo más rápidos.
- A pesar de las intimidantes matemáticas de sus fundamentos, la intuición detrás de los principios básicos de UMAP, son en realidad bastante simples.

- UMAP se compara a menudo con t-SNE (t-distributed Stochastic Neighbor Embedding) debido a su aplicación similar en la visualización de datos, pero ofrece varias ventajas, incluida una mejor preservación de la estructura global de los datos y tiempos de cálculo más rápidos.
- A pesar de las intimidantes matemáticas de sus fundamentos, la intuición detrás de los principios básicos de UMAP, son en realidad bastante simples.
- Esencialmente, construye un gráfico ponderado a partir de los datos de alta dimensión, donde la fuerza de los bordes representa qué tan “cerca” está un punto dado de otro. Posteriormente, proyecta este gráfico hacia una dimensionalidad menor.

- El algoritmo UMAP

- El algoritmo UMAP

- El algoritmo UMAP se puede dividir en dos fases principales: construcción de una representación topológica difusa y optimización de la proyección de baja dimensión.

- **El algoritmo UMAP**
- El algoritmo UMAP se puede dividir en dos fases principales: construcción de una representación topológica difusa y optimización de la proyección de baja dimensión.
- **Construcción de la representación topológica difusa**

- **El algoritmo UMAP**

- El algoritmo UMAP se puede dividir en dos fases principales: construcción de una representación topológica difusa y optimización de la proyección de baja dimensión.

- **Construcción de la representación topológica difusa**

- **Búsqueda del vecino más cercano:** UMAP comienza por encontrar los vecinos más cercanos para cada punto en los datos. Esto se hace normalmente utilizando algoritmos de vecino más cercano aproximado para acelerar el proceso.

- **El algoritmo UMAP**

- El algoritmo UMAP se puede dividir en dos fases principales: construcción de una representación topológica difusa y optimización de la proyección de baja dimensión.

- **Construcción de la representación topológica difusa**

- **Búsqueda del vecino más cercano:** UMAP comienza por encontrar los vecinos más cercanos para cada punto en los datos. Esto se hace normalmente utilizando algoritmos de vecino más cercano aproximado para acelerar el proceso.
- **Conjunto simple difuso:** se construye un conjunto simple difuso a partir de los vecinos más cercanos. Este conjunto captura la conectividad local de los puntos de datos.

- **El algoritmo UMAP**

- El algoritmo UMAP se puede dividir en dos fases principales: construcción de una representación topológica difusa y optimización de la proyección de baja dimensión.

- **Construcción de la representación topológica difusa**

- **Búsqueda del vecino más cercano:** UMAP comienza por encontrar los vecinos más cercanos para cada punto en los datos. Esto se hace normalmente utilizando algoritmos de vecino más cercano aproximado para acelerar el proceso.
- **Conjunto simple difuso:** se construye un conjunto simple difuso a partir de los vecinos más cercanos. Este conjunto captura la conectividad local de los puntos de datos.
- **Intensidades de pertenencia difusa:** las intensidades de pertenencia se asignan a los bordes del conjunto simple, lo que representa la probabilidad de que dos puntos estén conectados.