

- ML: Aprendizaje no supervisado

- **ML: Aprendizaje no supervisado**
- **Introducción**

- **ML: Aprendizaje no supervisado**
- **Introducción**
- Contrario al *Aprendizaje Supervisado* donde tenemos un conjunto de variables que usamos para predecir una determinada clase de salida (aprueba/no aprueba, enfermo/sano, reclama/no reclama), en el *Aprendizaje no Supervisado* no tenemos clases de salida esperadas.

- **ML: Aprendizaje no supervisado**

- **Introducción**

- Contrario al *Aprendizaje Supervisado* donde tenemos un conjunto de variables que usamos para predecir una determinada clase de salida (aprueba/no aprueba, enfermo/sano, reclama/no reclama), en el *Aprendizaje no Supervisado* no tenemos clases de salida esperadas.
- El Aprendizaje no Supervisado (en inglés unsupervised learning o unsupervised machine learning) es un método de análisis de datos que pertenece al campo de la Inteligencia Artificial (IA), es una rama del Aprendizaje Automático (Machine Learning) en la cual un modelo se entrena para encontrar patrones o estructuras subyacentes en los datos sin la presencia de etiquetas o información de salida predefinida.

- El Aprendizaje no Supervisado consiste en los procesos encargados de encontrar estructuras desconocidas a priori, que se encuentran en un conjunto de datos. Se desconocen las estructuras intrínsecas del conjunto de datos debido a la ausencia de un atributo que, de alguna manera, guíe (supervise) la formación de dichas estructuras

- El Aprendizaje no Supervisado consiste en los procesos encargados de encontrar estructuras desconocidas a priori, que se encuentran en un conjunto de datos. Se desconocen las estructuras intrínsecas del conjunto de datos debido a la ausencia de un atributo que, de alguna manera, guíe (supervise) la formación de dichas estructuras
- A diferencia del Aprendizaje Supervisado, donde se proporcionan ejemplos etiquetados, en el Aprendizaje no Supervisado el modelo debe aprender por sí mismo a partir de la estructura inherente de los datos.

- El Aprendizaje no Supervisado consiste en los procesos encargados de encontrar estructuras desconocidas a priori, que se encuentran en un conjunto de datos. Se desconocen las estructuras intrínsecas del conjunto de datos debido a la ausencia de un atributo que, de alguna manera, guíe (supervise) la formación de dichas estructuras
- A diferencia del Aprendizaje Supervisado, donde se proporcionan ejemplos etiquetados, en el Aprendizaje no Supervisado el modelo debe aprender por sí mismo a partir de la estructura inherente de los datos.
- Los algoritmos de Aprendizaje no Supervisado se centran en la exploración de los datos para encontrar patrones, relaciones o regularidades, y así obtener una comprensión más profunda de los mismos.

- Mencionamos en la introducción del curso que las técnicas de Aprendizaje no Supervisado más importantes son: Cluster, Componentes principales, Análisis de factores y los Modelos de mezclas, pero existen algunos más cuyo uso no es tan relevante.

- Clusters (Conglomerados)

- **Clusters (Conglomerados)**
- El término *clustering* hace referencia a un amplio grupo de técnicas no supervisadas cuya finalidad es encontrar patrones o grupos (clusters) dentro de un conjunto de observaciones.

- **Clusters (Conglomerados)**

- El término *clustering* hace referencia a un amplio grupo de técnicas no supervisadas cuya finalidad es encontrar patrones o grupos (clusters) dentro de un conjunto de observaciones.
- Las particiones se hacen de forma que las observaciones que están dentro de un mismo grupo, sean similares entre ellas y distintas a las observaciones de otros grupos (Principio totalmente análogo al del muestreo estratificado).

● Clusters (Conglomerados)

- El término *clustering* hace referencia a un amplio grupo de técnicas no supervisadas cuya finalidad es encontrar patrones o grupos (clusters) dentro de un conjunto de observaciones.
- Las particiones se hacen de forma que las observaciones que están dentro de un mismo grupo, sean similares entre ellas y distintas a las observaciones de otros grupos (Principio totalmente análogo al del muestreo estratificado).
- Se trata de un método no supervisado, ya que no se dispone de una variable respuesta que indique a qué grupo pertenece realmente cada observación.

● Clusters (Conglomerados)

- El término *clustering* hace referencia a un amplio grupo de técnicas no supervisadas cuya finalidad es encontrar patrones o grupos (clusters) dentro de un conjunto de observaciones.
- Las particiones se hacen de forma que las observaciones que están dentro de un mismo grupo, sean similares entre ellas y distintas a las observaciones de otros grupos (Principio totalmente análogo al del muestreo estratificado).
- Se trata de un método no supervisado, ya que no se dispone de una variable respuesta que indique a qué grupo pertenece realmente cada observación.
- Realizar agrupaciones en conjuntos multivariados de datos, es una de las actividades más comunes en muchos ámbitos del quehacer humano; una de las más conocidas es la segmentación de un mercado de consumidores, clientes o usuarios que se hace cotidianamente en las áreas de *marketing* de muchas empresas

- En el ejemplo de mercadotecnia, puede ocurrir que una muestra de consumidores con distintas características, esté formada por un pequeño número de grupos dentro de cada uno de los cuales dichas características sean similares. Esto podría tener implicaciones importantes para determinar una estrategia de mercado apropiada o para investigar la tipología del consumidor.

- En el ejemplo de mercadotecnia, puede ocurrir que una muestra de consumidores con distintas características, esté formada por un pequeño número de grupos dentro de cada uno de los cuales dichas características sean similares. Esto podría tener implicaciones importantes para determinar una estrategia de mercado apropiada o para investigar la tipología del consumidor.
- En un contexto educativo, los grupos pueden ser conjuntos de individuos con distintas capacidades (grupos de excelencia, estándar o de bajo rendimiento) o con diversos intereses, que los pueden ubicar en distintas áreas de estudio (orientación vocacional).

- En el ejemplo de mercadotecnia, puede ocurrir que una muestra de consumidores con distintas características, esté formada por un pequeño número de grupos dentro de cada uno de los cuales dichas características sean similares. Esto podría tener implicaciones importantes para determinar una estrategia de mercado apropiada o para investigar la tipología del consumidor.
- En un contexto educativo, los grupos pueden ser conjuntos de individuos con distintas capacidades (grupos de excelencia, estándar o de bajo rendimiento) o con diversos intereses, que los pueden ubicar en distintas áreas de estudio (orientación vocacional).
- En Biología podría tratarse de diversos tipos de individuos que pertenecen a una misma especie. En ecología podrían referirse a distintos tipos de plantas. En seguros, podemos agrupar a los sujetos que representan riesgos diferentes en alguna cobertura sobre, por ejemplo, automóviles.

- En fin, existe un sinnúmero de situaciones reales donde, en algún sentido, se tiene que trabajar con grupos de observaciones o individuos.

- En fin, existe un sinnúmero de situaciones reales donde, en algún sentido, se tiene que trabajar con grupos de observaciones o individuos.
- **Objetivos:**

- En fin, existe un sinnúmero de situaciones reales donde, en algún sentido, se tiene que trabajar con grupos de observaciones o individuos.
- **Objetivos:**
 - Identificar los grupos que de manera natural se forman con los datos. Estos grupos se forman con base a las similitudes o disimilitudes entre los sujetos, no entre las variables. En este sentido, esta es una técnica de análisis multivariado determinada por los sujetos (casos) y no por las variables como, por ejemplo, en el análisis de componentes principales o en el análisis de factores.

- En fin, existe un sinnúmero de situaciones reales donde, en algún sentido, se tiene que trabajar con grupos de observaciones o individuos.
- **Objetivos:**
 - Identificar los grupos que de manera natural se forman con los datos. Estos grupos se forman con base a las similaridades o disimilaridades entre los sujetos, no entre las variables. En este sentido, esta es una técnica de análisis multivariado determinada por los sujetos (casos) y no por las variables como, por ejemplo, en el análisis de componentes principales o en el análisis de factores.
 - Podemos decir que esta técnica tiene más fundamento computacional que estadístico

- En fin, existe un sinnúmero de situaciones reales donde, en algún sentido, se tiene que trabajar con grupos de observaciones o individuos.
- **Objetivos:**
 - Identificar los grupos que de manera natural se forman con los datos. Estos grupos se forman con base a las similaridades o disimilaridades entre los sujetos, no entre las variables. En este sentido, esta es una técnica de análisis multivariado determinada por los sujetos (casos) y no por las variables como, por ejemplo, en el análisis de componentes principales o en el análisis de factores.
 - Podemos decir que esta técnica tiene más fundamento computacional que estadístico
 - Es una técnica descriptiva

- En fin, existe un sinnúmero de situaciones reales donde, en algún sentido, se tiene que trabajar con grupos de observaciones o individuos.
- **Objetivos:**
 - Identificar los grupos que de manera natural se forman con los datos. Estos grupos se forman con base a las similitudes o disimilitudes entre los sujetos, no entre las variables. En este sentido, esta es una técnica de análisis multivariado determinada por los sujetos (casos) y no por las variables como, por ejemplo, en el análisis de componentes principales o en el análisis de factores.
 - Podemos decir que esta técnica tiene más fundamento computacional que estadístico
 - Es una técnica descriptiva
 - Aunque el objetivo común es agrupar a los sujetos, el análisis de conglomerados también se puede utilizar para agrupar variables, de una forma similar al análisis de factores.

- **Consideraciones antes de realizar el análisis de conglomerados**

- **Consideraciones antes de realizar el análisis de conglomerados**
- Al hacer un análisis de conglomerados con un conjunto de datos, nos enfrentamos a una serie de cuestionamientos que debemos dar respuesta para llevar a cabo nuestro objetivo. A saber

- **Consideraciones antes de realizar el análisis de conglomerados**
- Al hacer un análisis de conglomerados con un conjunto de datos, nos enfrentamos a una serie de cuestionamientos que debemos dar respuesta para llevar a cabo nuestro objetivo. A saber
 - Una primer pregunta es ¿qué variables debemos elegir para realizar los clusters? Aunque esta es una elección muy importante, raras veces es considerada como tal, y, en la práctica, involucra una mezcla de intuición y disponibilidad de los datos.

- **Consideraciones antes de realizar el análisis de conglomerados**
- Al hacer un análisis de conglomerados con un conjunto de datos, nos enfrentamos a una serie de cuestionamientos que debemos dar respuesta para llevar a cabo nuestro objetivo. A saber
 - Una primer pregunta es ¿qué variables debemos elegir para realizar los clusters? Aunque esta es una elección muy importante, raras veces es considerada como tal, y, en la práctica, involucra una mezcla de intuición y disponibilidad de los datos.
 - ¿Qué medida de distancia utilizar entre los casos?

- **Consideraciones antes de realizar el análisis de conglomerados**
- Al hacer un análisis de conglomerados con un conjunto de datos, nos enfrentamos a una serie de cuestionamientos que debemos dar respuesta para llevar a cabo nuestro objetivo. A saber
 - Una primer pregunta es ¿qué variables debemos elegir para realizar los clusters? Aunque esta es una elección muy importante, raras veces es considerada como tal, y, en la práctica, involucra una mezcla de intuición y disponibilidad de los datos.
 - ¿Qué medida de distancia utilizar entre los casos?
 - ¿Qué tipo de liga utilizar para los grupos?

- **Consideraciones antes de realizar el análisis de conglomerados**
- Al hacer un análisis de conglomerados con un conjunto de datos, nos enfrentamos a una serie de cuestionamientos que debemos dar respuesta para llevar a cabo nuestro objetivo. A saber
 - Una primer pregunta es ¿qué variables debemos elegir para realizar los clusters? Aunque esta es una elección muy importante, raras veces es considerada como tal, y, en la práctica, involucra una mezcla de intuición y disponibilidad de los datos.
 - ¿Qué medida de distancia utilizar entre los casos?
 - ¿Qué tipo de liga utilizar para los grupos?
 - ¿Qué tipo de técnica de construcción de los conglomerados usar?

- Pasos en el análisis de conglomerados

- **Pasos en el análisis de conglomerados**
- Si las variables no están medidas en la misma escala, es conveniente hacer el análisis con las variables estandarizadas. El objetivo es que las variables con mayores magnitudes no dominen el análisis (similar a Componentes Principales).

- **Pasos en el análisis de conglomerados**
- Si las variables no están medidas en la misma escala, es conveniente hacer el análisis con las variables estandarizadas. El objetivo es que las variables con mayores magnitudes no dominen el análisis (similar a Componentes Principales).
- Selección de variables. Como este proceso no proporciona ninguna medida acerca de la importancia de una variable en el análisis, ésta es una decisión que el usuario debe hacer *CUIDADOSAMENTE*.

- **Pasos en el análisis de conglomerados**
- Si las variables no están medidas en la misma escala, es conveniente hacer el análisis con las variables estandarizadas. El objetivo es que las variables con mayores magnitudes no dominen el análisis (similar a Componentes Principales).
- Selección de variables. Como este proceso no proporciona ninguna medida acerca de la importancia de una variable en el análisis, ésta es una decisión que el usuario debe hacer *CUIDADOSAMENTE*.
- Construir y evaluar el modelo de conglomerados.

- **Pasos en el análisis de conglomerados**
- Si las variables no están medidas en la misma escala, es conveniente hacer el análisis con las variables estandarizadas. El objetivo es que las variables con mayores magnitudes no dominen el análisis (similar a Componentes Principales).
- Selección de variables. Como este proceso no proporciona ninguna medida acerca de la importancia de una variable en el análisis, ésta es una decisión que el usuario debe hacer *CUIDADOSAMENTE*.
- Construir y evaluar el modelo de conglomerados.
- Identificar la pertenencia (membresía) de los casos a su correspondiente cluster.

- **Medidas de distancia**

- **Medidas de distancia**

- Todos los métodos de *clustering* tienen una cosa en común, para poder llevar a cabo las agrupaciones necesitan definir y cuantificar la similitud entre las observaciones.

- **Medidas de distancia**

- Todos los métodos de *clustering* tienen una cosa en común, para poder llevar a cabo las agrupaciones necesitan definir y cuantificar la similitud entre las observaciones.
- El término distancia se emplea dentro del contexto del clustering como cuantificación de la similitud o diferencia entre observaciones.

- **Medidas de distancia**

- Todos los métodos de *clustering* tienen una cosa en común, para poder llevar a cabo las agrupaciones necesitan definir y cuantificar la similitud entre las observaciones.
- El término distancia se emplea dentro del contexto del clustering como cuantificación de la similitud o diferencia entre observaciones.
- Si se representan las observaciones en un espacio p dimensional, con p el número de variables asociadas a cada observación, cuando más se asemejen dos observaciones más próximas estarán, de ahí que se emplee el término distancia.

● Medidas de distancia

- Todos los métodos de *clustering* tienen una cosa en común, para poder llevar a cabo las agrupaciones necesitan definir y cuantificar la similitud entre las observaciones.
- El término distancia se emplea dentro del contexto del clustering como cuantificación de la similitud o diferencia entre observaciones.
- Si se representan las observaciones en un espacio p dimensional, con p el número de variables asociadas a cada observación, cuando más se asemejen dos observaciones más próximas estarán, de ahí que se emplee el término distancia.
- La característica que hace del clustering un método adaptable a escenarios muy diversos es que puede emplear cualquier tipo de distancia, lo que permite al investigador escoger la más adecuada para el estudio en cuestión. A continuación, se describen algunas de las más utilizadas.

- Tipos de distancias para los casos, de acuerdo a su escala de medición

- **Tipos de distancias para los casos, de acuerdo a su escala de medición**
- La primera decisión importante que se debe tomar es sobre cómo calcular la distancia entre dos observaciones. Es claro que esta elección dependerá de la escala de medición de las variables involucradas en la misma.

- **Tipos de distancias para los casos, de acuerdo a su escala de medición**
- La primera decisión importante que se debe tomar es sobre cómo calcular la distancia entre dos observaciones. Es claro que esta elección dependerá de la escala de medición de las variables involucradas en la misma.
- En realidad, es bastante subjetivo el hecho de elegir una medida de similitud ya que depende de las escalas de medida. Para variables nominales, generalmente se utilizan medidas de similaridad, mientras que para variables medidas en escala de intervalo o de razón usualmente se consideran matrices de distancias.

- **Tipos de distancias para los casos, de acuerdo a su escala de medición**
- La primera decisión importante que se debe tomar es sobre cómo calcular la distancia entre dos observaciones. Es claro que esta elección dependerá de la escala de medición de las variables involucradas en la misma.
- En realidad, es bastante subjetivo el hecho de elegir una medida de similitud ya que depende de las escalas de medida. Para variables nominales, generalmente se utilizan medidas de similaridad, mientras que para variables medidas en escala de intervalo o de razón usualmente se consideran matrices de distancias.
- Se pueden agrupar observaciones (sujetos) según la similitud expresada en términos de una distancia.

- **Tipos de distancias para los casos, de acuerdo a su escala de medición**
- La primera decisión importante que se debe tomar es sobre cómo calcular la distancia entre dos observaciones. Es claro que esta elección dependerá de la escala de medición de las variables involucradas en la misma.
- En realidad, es bastante subjetivo el hecho de elegir una medida de similitud ya que depende de las escalas de medida. Para variables nominales, generalmente se utilizan medidas de similaridad, mientras que para variables medidas en escala de intervalo o de razón usualmente se consideran matrices de distancias.
- Se pueden agrupar observaciones (sujetos) según la similitud expresada en términos de una distancia.
- Si el objetivo es agrupar variables (tipo análisis de factores), es habitual utilizar como medida de similitud los coeficientes de correlación en valor absoluto.

- **Medidas de distancia**

- **Medidas de distancia**
- **Distancia Euclideana.** Supongamos que tenemos dos sujetos con p variables, i.e., $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^p$. Entonces, su distancia euclideana es

- **Medidas de distancia**

- **Distancia Euclideana.** Supongamos que tenemos dos sujetos con p variables, i.e., $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^p$. Entonces, su distancia euclideana es

- $$d(\mathbf{x}_1, \mathbf{x}_2) = \left[\sum_{i=1}^p (x_{1i} - x_{2i})^2 \right]^{1/2}$$

- **Medidas de distancia**

- **Distancia Euclideana.** Supongamos que tenemos dos sujetos con p variables, i.e., $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^p$. Entonces, su distancia euclideana es

- $$d(\mathbf{x}_1, \mathbf{x}_2) = \left[\sum_{i=1}^p (x_{1i} - x_{2i})^2 \right]^{1/2}$$

- **Distancia de Minkowski**

- **Medidas de distancia**

- **Distancia Euclideana.** Supongamos que tenemos dos sujetos con p variables, i.e., $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^p$. Entonces, su distancia euclideana es

- $$d(\mathbf{x}_1, \mathbf{x}_2) = \left[\sum_{i=1}^p (x_{1i} - x_{2i})^2 \right]^{1/2}$$

- **Distancia de Minkowski**

- $$d(\mathbf{x}_1, \mathbf{x}_2) = \left[\sum_{i=1}^p (x_{1i} - x_{2i})^p \right]^{1/p}$$

- **Medidas de distancia**

- **Distancia Euclideana.** Supongamos que tenemos dos sujetos con p variables, i.e., $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^p$. Entonces, su distancia euclideana es

- $$d(\mathbf{x}_1, \mathbf{x}_2) = \left[\sum_{i=1}^p (x_{1i} - x_{2i})^2 \right]^{1/2}$$

- **Distancia de Minkowski**

- $$d(\mathbf{x}_1, \mathbf{x}_2) = \left[\sum_{i=1}^p (x_{1i} - x_{2i})^p \right]^{1/p}$$

- **Distancia de Manhattan**

- **Medidas de distancia**

- **Distancia Euclideana.** Supongamos que tenemos dos sujetos con p variables, i.e., $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^p$. Entonces, su distancia euclideana es

- $$d(\mathbf{x}_1, \mathbf{x}_2) = \left[\sum_{i=1}^p (x_{1i} - x_{2i})^2 \right]^{1/2}$$

- **Distancia de Minkowski**

- $$d(\mathbf{x}_1, \mathbf{x}_2) = \left[\sum_{i=1}^p (x_{1i} - x_{2i})^p \right]^{1/p}$$

- **Distancia de Manhattan**

- $$d(\mathbf{x}_1, \mathbf{x}_2) = \sum_{i=1}^p |x_{1i} - x_{2i}|$$

- Distancia de Jaccard

- Distancia de Jaccard

- $$J(\mathbf{x}_1, \mathbf{x}_2) = \frac{|\mathbf{x}_1 \cap \mathbf{x}_2|}{|\mathbf{x}_1 \cup \mathbf{x}_2|}$$

- Distancia de Jaccard

- $J(\mathbf{x}_1, \mathbf{x}_2) = \frac{|\mathbf{x}_1 \cap \mathbf{x}_2|}{|\mathbf{x}_1 \cup \mathbf{x}_2|}$

- Distancia Coseno

- Distancia de Jaccard

- $J(\mathbf{x}_1, \mathbf{x}_2) = \frac{|\mathbf{x}_1 \cap \mathbf{x}_2|}{|\mathbf{x}_1 \cup \mathbf{x}_2|}$

- Distancia Coseno

- $\cos(\theta) = \frac{\mathbf{x}_1 \mathbf{x}_2}{\|\mathbf{x}_1\| \|\mathbf{x}_2\|} = \frac{\sum_{i=1}^p x_{1i} x_{2i}}{\sqrt{\sum_{i=1}^p x_{1i}^2} \sqrt{\sum_{i=1}^p x_{2i}^2}}$

- Distancia de Jaccard

- $J(\mathbf{x}_1, \mathbf{x}_2) = \frac{|\mathbf{x}_1 \cap \mathbf{x}_2|}{|\mathbf{x}_1 \cup \mathbf{x}_2|}$

- Distancia Coseno

- $\cos(\theta) = \frac{\mathbf{x}_1 \mathbf{x}_2}{\|\mathbf{x}_1\| \|\mathbf{x}_2\|} = \frac{\sum_{i=1}^p x_{1i} x_{2i}}{\sqrt{\sum_{i=1}^p x_{1i}^2} \sqrt{\sum_{i=1}^p x_{2i}^2}}$

- **Nota:** Esta distancia es realmente una medida de similitud o similaridad, y será 1 cuando los dos vectores tengan un ángulo de 0^0 (sean colineales), pero en ese caso la distancia es 0 .
Por tanto, para obtener la distancia con base a la similitud del coseno, simplemente deberemos restar la similitud a 1

- Distancia de Mahalanobis

- Distancia de Mahalanobis



$$d^2(\mathbf{x}_1, \mathbf{x}_2) = (\mathbf{x}_1 - \mathbf{x}_2)^t \mathbf{S}^{-1} (\mathbf{x}_1 - \mathbf{x}_2)$$

- Distancia de Mahalanobis



$$d^2(\mathbf{x}_1, \mathbf{x}_2) = (\mathbf{x}_1 - \mathbf{x}_2)^t \mathbf{S}^{-1} (\mathbf{x}_1 - \mathbf{x}_2)$$

- Donde **S** es la matriz de covarianzas entre las variables. De este modo, las distancias se ponderan según el grado de relación que exista entre las variables, es decir, si están más o menos correlacionadas. Si la correlación es nula, se obtiene la distancia euclídeana.

- **Distancia de Mahalanobis**



$$d^2(\mathbf{x}_1, \mathbf{x}_2) = (\mathbf{x}_1 - \mathbf{x}_2)^t \mathbf{S}^{-1} (\mathbf{x}_1 - \mathbf{x}_2)$$

- Donde **S** es la matriz de covarianzas entre las variables. De este modo, las distancias se ponderan según el grado de relación que exista entre las variables, es decir, si están más o menos correlacionadas. Si la correlación es nula, se obtiene la distancia euclídeana.

- **Distancia City block**

- **Distancia de Mahalanobis**



$$d^2(\mathbf{x}_1, \mathbf{x}_2) = (\mathbf{x}_1 - \mathbf{x}_2)^t \mathbf{S}^{-1} (\mathbf{x}_1 - \mathbf{x}_2)$$

- Donde **S** es la matriz de covarianzas entre las variables. De este modo, las distancias se ponderan según el grado de relación que exista entre las variables, es decir, si están más o menos correlacionadas. Si la correlación es nula, se obtiene la distancia euclídeana.

- **Distancia City block**



$$d(\mathbf{x}_1, \mathbf{x}_2) = \sum_{i=1}^p |x_{1i} - x_{2i}|$$

- **Distancia de Mahalanobis**



$$d^2(\mathbf{x}_1, \mathbf{x}_2) = (\mathbf{x}_1 - \mathbf{x}_2)^t \mathbf{S}^{-1} (\mathbf{x}_1 - \mathbf{x}_2)$$

- Donde **S** es la matriz de covarianzas entre las variables. De este modo, las distancias se ponderan según el grado de relación que exista entre las variables, es decir, si están más o menos correlacionadas. Si la correlación es nula, se obtiene la distancia euclídeana.

- **Distancia City block**



$$d(\mathbf{x}_1, \mathbf{x}_2) = \sum_{i=1}^p |x_{1i} - x_{2i}|$$

- De hecho, la distancia City block es un caso particular de la distancia de Minkowski con $p=1$. También lo es la distancia Euclídeana con $p=2$.

- Distancia de Canberra

- Distancia de Canberra



$$d_{Can}(\mathbf{x}_1, \mathbf{x}_2) = \sum_{i=1}^p \frac{|x_{1i} - x_{2i}|}{|x_{1i} + x_{2i}|}$$

- Distancia de Canberra



$$d_{Can}(\mathbf{x}_1, \mathbf{x}_2) = \sum_{i=1}^p \frac{|x_{1i} - x_{2i}|}{|x_{1i} + x_{2i}|}$$

- Definida como *cero* si $x_{1i} = x_{2i}$.

- Distancia de Canberra



$$d_{Can}(\mathbf{x}_1, \mathbf{x}_2) = \sum_{i=1}^p \frac{|x_{1i} - x_{2i}|}{|x_{1i} + x_{2i}|}$$

- Definida como *cero* si $x_{1i} = x_{2i}$.
- Estas distancias se recomiendan cuando las variables involucradas son continuas

- **Distancia de Canberra**



$$d_{Can}(\mathbf{x}_1, \mathbf{x}_2) = \sum_{i=1}^p \frac{|x_{1i} - x_{2i}|}{|x_{1i} + x_{2i}|}$$

- Definida como *cero* si $x_{1i} = x_{2i}$.
- Estas distancias se recomiendan cuando las variables involucradas son continuas
- **Variables de conteo** (numéricas discretas)

- **Distancia de Canberra**



$$d_{Can}(\mathbf{x}_1, \mathbf{x}_2) = \sum_{i=1}^p \frac{|x_{1i} - x_{2i}|}{|x_{1i} + x_{2i}|}$$

- Definida como *cero* si $x_{1i} = x_{2i}$.
- Estas distancias se recomiendan cuando las variables involucradas son continuas
- **Variables de conteo** (numéricas discretas)
- **Distancia Ji-cuadrada**

- **Distancia de Canberra**



$$d_{Can}(\mathbf{x}_1, \mathbf{x}_2) = \sum_{i=1}^p \frac{|x_{1i} - x_{2i}|}{|x_{1i} + x_{2i}|}$$

- Definida como *cero* si $x_{1i} = x_{2i}$.
- Estas distancias se recomiendan cuando las variables involucradas son continuas

- **Variables de conteo** (numéricas discretas)

- **Distancia Ji-cuadrada**



$$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\frac{\sum_{i=1}^p (x_{1i} - \mathbb{E}(x_{1i}))^2}{\mathbb{E}(x_{1i})} + \frac{\sum_{i=1}^p (x_{2i} - \mathbb{E}(x_{2i}))^2}{\mathbb{E}(x_{2i})}}$$

- phi-cuadrada

- phi-cuadrada



$$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\frac{\sum_{i=1}^p (x_{1i} - \mathbb{E}(x_{1i}))^2}{\mathbb{E}(x_{1i})} + \frac{\sum_{i=1}^p (x_{2i} - \mathbb{E}(x_{2i}))^2}{\mathbb{E}(x_{2i})}}$$

- **phi-cuadrada**



$$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\frac{\sum_{i=1}^p (x_{1i} - \mathbb{E}(x_{1i}))^2}{\mathbb{E}(x_{1i})} + \frac{\sum_{i=1}^p (x_{2i} - \mathbb{E}(x_{2i}))^2}{\mathbb{E}(x_{2i})}}$$

- **Variables dicotómicas**

- **phi-cuadrada**



$$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\frac{\sum_{i=1}^p (x_{1i} - \mathbb{E}(x_{1i}))^2}{\mathbb{E}(x_{1i})} + \frac{\sum_{i=1}^p (x_{2i} - \mathbb{E}(x_{2i}))^2}{\mathbb{E}(x_{2i})}}$$

- **Variables dicotómicas**

- **Distancia euclidiana**

- **phi-cuadrada**



$$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\frac{\sum_{i=1}^p (x_{1i} - \mathbb{E}(x_{1i}))^2}{\mathbb{E}(x_{1i})} + \frac{\sum_{i=1}^p (x_{2i} - \mathbb{E}(x_{2i}))^2}{\mathbb{E}(x_{2i})}}$$

- **Variables dicotómicas**
- **Distancia euclidiana**
- **Distancia euclidiana al cuadrado**

- **phi-cuadrada**



$$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\frac{\sum_{i=1}^p (x_{1i} - \mathbb{E}(x_{1i}))^2}{\mathbb{E}(x_{1i})} + \frac{\sum_{i=1}^p (x_{2i} - \mathbb{E}(x_{2i}))^2}{\mathbb{E}(x_{2i})}}$$

- **Variables dicotómicas**
- **Distancia euclidiana**
- **Distancia euclidiana al cuadrado**
- **Datos binarios (medidas de similaridad)**

- **phi-cuadrada**



$$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\frac{\sum_{i=1}^p (x_{1i} - \mathbb{E}(x_{1i}))^2}{\mathbb{E}(x_{1i})} + \frac{\sum_{i=1}^p (x_{2i} - \mathbb{E}(x_{2i}))^2}{\mathbb{E}(x_{2i})}}$$

- **Variables dicotómicas**

- **Distancia euclidiana**

- **Distancia euclidiana al cuadrado**

- **Datos binarios (medidas de similaridad)**

- En este caso se desea medir la similaridad entre los vectores $x_i = (x_{i1}, \dots, x_{ip})'$ y $x_j = (x_{j1}, \dots, x_{jp})'$, con la característica particular de que $x_{ik}, x_{jk} \in \{0, 1\}$, $\forall k = 1, 2, \dots, p$. Que generan los siguientes casos



$$x_{ik} = x_{jk} = 1,$$

$$x_{ik} = x_{jk} = 0,$$

$$x_{ik} = 1, x_{jk} = 0,$$

$$x_{ik} = 0, x_{jk} = 0$$



$$x_{ik} = x_{jk} = 1,$$

$$x_{ik} = x_{jk} = 0,$$

$$x_{ik} = 1, x_{jk} = 0,$$

$$x_{ik} = 0, x_{jk} = 0$$

- Si definimos ahora



$$\begin{aligned}x_{ik} &= x_{jk} = 1, \\x_{ik} &= x_{jk} = 0, \\x_{ik} &= 1, x_{jk} = 0, \\x_{ik} &= 0, x_{jk} = 0\end{aligned}$$

● Si definimos ahora



$$\begin{aligned}a_1 &= \sum_{k=1}^p \mathbf{I}(x_{ik} = x_{jk} = 1) \\a_2 &= \sum_{k=1}^p \mathbf{I}(x_{ik} = 0, x_{jk} = 1) \\a_3 &= \sum_{k=1}^p \mathbf{I}(x_{ik} = 1, x_{jk} = 0) \\a_4 &= \sum_{k=1}^p \mathbf{I}(x_{ik} = x_{jk} = 0)\end{aligned}$$

- En la práctica, es frecuente el uso de la siguiente medida de similaridad para este tipo de datos

- En la práctica, es frecuente el uso de la siguiente medida de similaridad para este tipo de datos

- $$s_{ij} = \frac{a_1 + \delta a_4}{a_1 + \delta a_4 + \lambda (a_2 + a_3)}$$

- En la práctica, es frecuente el uso de la siguiente medida de similaridad para este tipo de datos

- $$s_{ij} = \frac{a_1 + \delta a_4}{a_1 + \delta a_4 + \lambda (a_2 + a_3)}$$

- Donde los valores de δ y λ representan pesos que definen distintas medidas de similaridad. Obsérvese que $a + b + c + d = p$.

- En la práctica, es frecuente el uso de la siguiente medida de similaridad para este tipo de datos

- $$s_{ij} = \frac{a_1 + \delta a_4}{a_1 + \delta a_4 + \lambda (a_2 + a_3)}$$

- Donde los valores de δ y λ representan pesos que definen distintas medidas de similaridad. Obsérvese que $a + b + c + d = p$.
- Las más comunes de estas medidas, se presentan en la tabla siguiente

Nombre de la medida de similaridad	δ	λ	Definición
Jaccard	0	1	$\frac{a_1}{a_1 + a_2 + a_3}$
Tanimoto	1	2	$\frac{a_1 + a_4}{a_1 + 2(a_2 + a_3) + a_4}$
Simple Matching (M)	1	1	$\frac{a_1 + a_4}{p}$
Russel and Rao (RR)	—	—	$\frac{a_1}{p}$
Dice	0	1/2	$\frac{2a_1}{2a_1 + (a_2 + a_3)}$
Kulczynski	—	—	$\frac{a_1}{a_2 + a_3}$

Nombre de la medida de similaridad	δ	λ	Definición
Jaccard	0	1	$\frac{a_1}{a_1 + a_2 + a_3}$
Tanimoto	1	2	$\frac{a_1 + a_4}{a_1 + 2(a_2 + a_3) + a_4}$
Simple Matching (M)	1	1	$\frac{a_1 + a_4}{p}$
Russel and Rao (RR)	—	—	$\frac{a_1}{p}$
Dice	0	1/2	$\frac{2a_1}{2a_1 + (a_2 + a_3)}$
Kulczynski	—	—	$\frac{a_1}{a_2 + a_3}$

- El rango de estas medidas de similaridad está entre cero (mínima similaridad) y uno (máxima similaridad). La idea es ponderar de manera distinta el número de *acuerdos* y *desacuerdos* entre los valores de los vectores binarios observados

- Existen muchas más medidas de similaridad para datos binarios, éstas son las principales, pero, por ejemplo, en los manuales de *el innumerable* aparecen también las siguientes: Sokal and Sneath similarity measure 1, Sokal and Sneath similarity measure 2, Sokal and Sneath similarity measure 3, Ochiai similarity measure, Sokal and Sneath similarity measure 5, Fourfold point correlation (similarity), etc.

- Existen muchas más medidas de similaridad para datos binarios, éstas son las principales, pero, por ejemplo, en los manuales de *el innombrable* aparecen también las siguientes: Sokal and Sneath similarity measure 1, Sokal and Sneath similarity measure 2, Sokal and Sneath similarity measure 3, Ochiai similarity measure, Sokal and Sneath similarity measure 5, Fourfold point correlation (similarity), etc.
- **Variables continuas (medidas de similaridad)**

- Existen muchas más medidas de similaridad para datos binarios, éstas son las principales, pero, por ejemplo, en los manuales de *el innombrable* aparecen también las siguientes: Sokal and Sneath similarity measure 1, Sokal and Sneath similarity measure 2, Sokal and Sneath similarity measure 3, Ochiai similarity measure, Sokal and Sneath similarity measure 5, Fourfold point correlation (similarity), etc.
- **Variables continuas (medidas de similaridad)**
- **Correlación de Pearson**

- Existen muchas más medidas de similaridad para datos binarios, éstas son las principales, pero, por ejemplo, en los manuales de *el innombrable* aparecen también las siguientes: Sokal and Sneath similarity measure 1, Sokal and Sneath similarity measure 2, Sokal and Sneath similarity measure 3, Ochiai similarity measure, Sokal and Sneath similarity measure 5, Fourfold point correlation (similarity), etc.
- Variables continuas (medidas de similaridad)**
- Correlación de Pearson**
-

$$r(\mathbf{x}_1, \mathbf{x}_2) = \frac{\sum_{i=1}^p (x_{1i} - \bar{x}_{1i})(x_{2i} - \bar{x}_{2i})}{\sqrt{\sum_{i=1}^p (x_{1i} - \bar{x}_{1i})^2 \sum_{i=1}^p (x_{2i} - \bar{x}_{2i})^2}}$$

- Existen muchas más medidas de similaridad para datos binarios, éstas son las principales, pero, por ejemplo, en los manuales de *el innombrable* aparecen también las siguientes: Sokal and Sneath similarity measure 1, Sokal and Sneath similarity measure 2, Sokal and Sneath similarity measure 3, Ochiai similarity measure, Sokal and Sneath similarity measure 5, Fourfold point correlation (similarity), etc.
- Variables continuas (medidas de similaridad)**
- Correlación de Pearson**
-

$$r(\mathbf{x}_1, \mathbf{x}_2) = \frac{\sum_{i=1}^p (x_{1i} - \bar{x}_{1i})(x_{2i} - \bar{x}_{2i})}{\sqrt{\sum_{i=1}^p (x_{1i} - \bar{x}_{1i})^2 \sum_{i=1}^p (x_{2i} - \bar{x}_{2i})^2}}$$

- Otra medida de similaridad en este caso, es la *distancia coseno* que ya definimos anteriormente

- Coeficiente de similaridad de Gower

- **Coeficiente de similaridad de Gower**
- Es común que las variables involucradas en la construcción de los clusters sean de diversas escalas: continuas, nominales, ordinales, numéricas de conteo y binarias

- **Coeficiente de similitud de Gower**
- Es común que las variables involucradas en la construcción de los clusters sean de diversas escalas: continuas, nominales, ordinales, numéricas de conteo y binarias
- Del mismo modo que como se calcula la matriz polycórica para componentes principales y análisis de factores, requeriríamos construir una matriz de distancias que tomara en cuenta la escala de medición de cada variable

- **Coeficiente de similaridad de Gower**
- Es común que las variables involucradas en la construcción de los clusters sean de diversas escalas: continuas, nominales, ordinales, numéricas de conteo y binarias
- Del mismo modo que como se calcula la matriz polycórica para componentes principales y análisis de factores, requeriríamos construir una matriz de distancias que tomara en cuenta la escala de medición de cada variable
- El Coeficiente general de similaridad de Gower (1971) es la medida de similaridad más popular para datos mixtos. Entonces, este coeficiente, S_{ij} , compara dos sujetos (casos) i y j de la siguiente manera:

- **Coeficiente de similaridad de Gower**

- Es común que las variables involucradas en la construcción de los clusters sean de diversas escalas: continuas, nominales, ordinales, numéricas de conteo y binarias
- Del mismo modo que como se calcula la matriz polycórica para componentes principales y análisis de factores, requeriríamos construir una matriz de distancias que tomara en cuenta la escala de medición de cada variable
- El Coeficiente general de similaridad de Gower (1971) es la medida de similaridad más popular para datos mixtos. Entonces, este coeficiente, S_{ij} , compara dos sujetos (casos) i y j de la siguiente manera:

- $$S_{ij} = \frac{\sum_{k=1}^p w_{ijk} S_{ijk}}{\sum_{k=1}^p w_{ijk}}$$

- S_{ijk} denota la contribución a la distancia entre estos sujetos, proporcionada por la k -ésima variable, $k = 1, 2, \dots, p$

- S_{ijk} denota la contribución a la distancia entre estos sujetos, proporcionada por la k -ésima variable, $k = 1, 2, \dots, p$
- Algunas veces la comparación entre estos individuos no es posible, debido a pérdida de información (datos faltantes) o, en el caso de variables dicotómicas, a que la característica no está presente en ninguno de los dos sujetos i y j . Por lo tanto, w_{ijk} sólo puede tomar los valores 1 ó 0

- S_{ijk} denota la contribución a la distancia entre estos sujetos, proporcionada por la k -ésima variable, $k = 1, 2, \dots, p$
- Algunas veces la comparación entre estos individuos no es posible, debido a pérdida de información (datos faltantes) o, en el caso de variables dicotómicas, a que la característica no está presente en ninguno de los dos sujetos i y j . Por lo tanto, w_{ijk} sólo puede tomar los valores 1 ó 0
- La medida de similitud, S_{ijk} , en el índice de Gower para variables ordinales y continuas, se calcula de la siguiente manera:

- S_{ijk} denota la contribución a la distancia entre estos sujetos, proporcionada por la k -ésima variable, $k = 1, 2, \dots, p$
- Algunas veces la comparación entre estos individuos no es posible, debido a pérdida de información (datos faltantes) o, en el caso de variables dicotómicas, a que la característica no está presente en ninguno de los dos sujetos i y j . Por lo tanto, w_{ijk} sólo puede tomar los valores 1 ó 0
- La medida de similitud, S_{ijk} , en el índice de Gower para variables ordinales y continuas, se calcula de la siguiente manera:

$$S_{ijk} = 1 - \frac{x_{ik} - x_{ij}}{r_k}$$

- S_{ijk} denota la contribución a la distancia entre estos sujetos, proporcionada por la k -ésima variable, $k = 1, 2, \dots, p$
- Algunas veces la comparación entre estos individuos no es posible, debido a pérdida de información (datos faltantes) o, en el caso de variables dicotómicas, a que la característica no está presente en ninguno de los dos sujetos i y j . Por lo tanto, w_{ijk} sólo puede tomar los valores 1 ó 0
- La medida de similitud, S_{ijk} , en el índice de Gower para variables ordinales y continuas, se calcula de la siguiente manera:

$$S_{ijk} = 1 - \frac{x_{ik} - x_{ij}}{r_k}$$

- Con r_k el rango de la k -ésima variable

- En caso de que las variables sean nominales, S_{ijk} es 1 si $x_{ik} = x_{jk}$ ó 0 si $x_{ik} \neq x_{jk}$. Entonces, $S_{ijk} = 1$ si los sujetos i y j , tienen la misma categoría en la variable k , ó 0 si tienen diferente categoría. Y $w_{ijk} = 1$ si ambos casos tienen observaciones (alguna categoría) de la variable k

- En caso de que las variables sean nominales, S_{ijk} es 1 si $x_{ik} = x_{jk}$ ó 0 si $x_{ik} \neq x_{jk}$. Entonces, $S_{ijk} = 1$ si los sujetos i y j , tienen la misma categoría en la variable k , ó 0 si tienen diferente categoría. Y $w_{ijk} = 1$ si ambos casos tienen observaciones (alguna categoría) de la variable k
- Para variables dicotómicas, la medida de similitud, S_{ijk} , de este índice y los pesos w_{ijk} , se definen de acuerdo a la siguiente tabla:

- En caso de que las variables sean nominales, S_{ijk} es 1 si $x_{ik} = x_{jk}$ ó 0 si $x_{ik} \neq x_{jk}$. Entonces, $S_{ijk} = 1$ si los sujetos i y j , tienen la misma categoría en la variable k , ó 0 si tienen diferente categoría. Y $w_{ijk} = 1$ si ambos casos tienen observaciones (alguna categoría) de la variable k
- Para variables dicotómicas, la medida de similitud, S_{ijk} , de este índice y los pesos w_{ijk} , se definen de acuerdo a la siguiente tabla:

	● valor del atributo			
Sujeto i	+	+	-	-
Sujeto j	+	-	+	-
S_{ijk}	1	0	0	0
w_{ijk}	1	1	1	0

- En caso de que las variables sean nominales, S_{ijk} es 1 si $x_{ik} = x_{jk}$ ó 0 si $x_{ik} \neq x_{jk}$. Entonces, $S_{ijk} = 1$ si los sujetos i y j , tienen la misma categoría en la variable k , ó 0 si tienen diferente categoría. Y $w_{ijk} = 1$ si ambos casos tienen observaciones (alguna categoría) de la variable k
- Para variables dicotómicas, la medida de similitud, S_{ijk} , de este índice y los pesos w_{ijk} , se definen de acuerdo a la siguiente tabla:

	● valor del atributo			
Sujeto i	+	+	-	-
Sujeto j	+	-	+	-
S_{ijk}	1	0	0	0
w_{ijk}	1	1	1	0

- +, denota que el atributo está presente y - que está ausente

- En caso de que las variables sean nominales, S_{ijk} es 1 si $x_{ik} = x_{jk}$ ó 0 si $x_{ik} \neq x_{jk}$. Entonces, $S_{ijk} = 1$ si los sujetos i y j , tienen la misma categoría en la variable k , ó 0 si tienen diferente categoría. Y $w_{ijk} = 1$ si ambos casos tienen observaciones (alguna categoría) de la variable k
- Para variables dicotómicas, la medida de similitud, S_{ijk} , de este índice y los pesos w_{ijk} , se definen de acuerdo a la siguiente tabla:

	● valor del atributo			
Sujeto i	+	+	-	-
Sujeto j	+	-	+	-
S_{ijk}	1	0	0	0
w_{ijk}	1	1	1	0

- +, denota que el atributo está presente y - que está ausente
- **Nota:** Si todas las variables son binarias, el índice de Gower es equivalente al coeficiente de similaridad de Jaccard

- Métodos jerárquicos

- **Métodos jerárquicos**

- Los métodos jerárquicos para construir clusters no requiere que se pre-especifique el número de clusters. Utilizan las distancias entre los sujetos para irlos agrupando de acuerdo a la similitud entre ellos.

- **Métodos jerárquicos**

- Los métodos jerárquicos para construir clusters no requiere que se pre-especifique el número de clusters. Utilizan las distancias entre los sujetos para irlos agrupando de acuerdo a la similitud entre ellos.
- Los métodos jerárquicos se subdividen en dos tipos dependiendo de la estrategia seguida para crear los grupos

- **Métodos jerárquicos**

- Los métodos jerárquicos para construir clusters no requiere que se pre-especifique el número de clusters. Utilizan las distancias entre los sujetos para irlos agrupando de acuerdo a la similitud entre ellos.
- Los métodos jerárquicos se subdividen en dos tipos dependiendo de la estrategia seguida para crear los grupos
- **Aglomerativos**: el agrupamiento se inicia considerando que cada observación forma un cluster individual. Los clusters se van uniendo hasta formar uno solo.

- **Métodos jerárquicos**

- Los métodos jerárquicos para construir clusters no requiere que se pre-especifique el número de clusters. Utilizan las distancias entre los sujetos para irlos agrupando de acuerdo a la similitud entre ellos.
- Los métodos jerárquicos se subdividen en dos tipos dependiendo de la estrategia seguida para crear los grupos
- **Aglomerativos**: el agrupamiento se inicia considerando que cada observación forma un cluster individual. Los clusters se van uniendo hasta formar uno solo.
- **Divisivos**: Estrategia opuesta al método aglomerativo, que inicia suponiendo que todas las observaciones forman un único cluster y se suceden divisiones hasta que cada observación forma un cluster individual.

- **Algoritmo método aglomerativo**

- **Algoritmo método aglomerativo**
- El proceso se inicia considerando cada una de las observaciones como un cluster individual.

- **Algoritmo método aglomerativo**
- El proceso se inicia considerando cada una de las observaciones como un cluster individual.
- Se inicia un proceso iterativo hasta que todas las observaciones pertenecen a un único cluster:

- **Algoritmo método aglomerativo**

- El proceso se inicia considerando cada una de las observaciones como un cluster individual.
- Se inicia un proceso iterativo hasta que todas las observaciones pertenecen a un único cluster:
 - Se calcula la distancia entre cada posible par de los n clusters. El investigador debe determinar el tipo de medida emplea para cuantificar la similitud entre observaciones o grupos (distancia y liga).

- **Algoritmo método aglomerativo**

- El proceso se inicia considerando cada una de las observaciones como un cluster individual.
- Se inicia un proceso iterativo hasta que todas las observaciones pertenecen a un único cluster:
 - Se calcula la distancia entre cada posible par de los n clusters. El investigador debe determinar el tipo de medida emplea para cuantificar la similitud entre observaciones o grupos (distancia y liga).
 - Los dos clusters más similares se fusionan, de forma que quedan $n-1$ clusters.

- **Algoritmo método aglomerativo**

- El proceso se inicia considerando cada una de las observaciones como un cluster individual.
- Se inicia un proceso iterativo hasta que todas las observaciones pertenecen a un único cluster:
 - Se calcula la distancia entre cada posible par de los n clusters. El investigador debe determinar el tipo de medida emplea para cuantificar la similitud entre observaciones o grupos (distancia y liga).
 - Los dos clusters más similares se fusionan, de forma que quedan $n-1$ clusters.
- Determinar dónde cortar la estructura generada (dendrograma)

- **Métodos divisivos**

- **Métodos divisivos**
- El algoritmo más conocido de los métodos divisivos es **DIANA** (**DI**visive **ANA**lysis Clustering).

- **Métodos divisivos**

- El algoritmo más conocido de los métodos divisivos es **DIANA** (**DI**visive **ANA**lysis Clustering).
- Este algoritmo inicia con un único cluster que contiene todas las observaciones, a continuación, se van sucediendo divisiones hasta que cada observación forma un cluster independiente.

- **Métodos divisivos**

- El algoritmo más conocido de los métodos divisivos es **DIANA** (**DI**visive **ANA**lysis Clustering).
- Este algoritmo inicia con un único cluster que contiene todas las observaciones, a continuación, se van sucediendo divisiones hasta que cada observación forma un cluster independiente.
- En cada iteración se selecciona el cluster con mayor diámetro, entendiendo por diámetro de un cluster la mayor de las diferencias entre dos de sus observaciones.

- **Métodos divisivos**

- El algoritmo más conocido de los métodos divisivos es **DIANA** (**D**ivisive **A**NALysis Clustering).
- Este algoritmo inicia con un único cluster que contiene todas las observaciones, a continuación, se van sucediendo divisiones hasta que cada observación forma un cluster independiente.
- En cada iteración se selecciona el cluster con mayor diámetro, entendiendo por diámetro de un cluster la mayor de las diferencias entre dos de sus observaciones.
- Una vez seleccionado el cluster, se identifica la observación más dispar, que es aquella con mayor distancia promedio respecto al resto de observaciones que forman el cluster, esta observación inicia el nuevo cluster.

- **Métodos divisivos**

- El algoritmo más conocido de los métodos divisivos es **DIANA** (**D**ivisive **A**NALysis Clustering).
- Este algoritmo inicia con un único cluster que contiene todas las observaciones, a continuación, se van sucediendo divisiones hasta que cada observación forma un cluster independiente.
- En cada iteración se selecciona el cluster con mayor diámetro, entendiendo por diámetro de un cluster la mayor de las diferencias entre dos de sus observaciones.
- Una vez seleccionado el cluster, se identifica la observación más dispar, que es aquella con mayor distancia promedio respecto al resto de observaciones que forman el cluster, esta observación inicia el nuevo cluster.
- Se reasignan las observaciones en función de si están más próximas al nuevo cluster o al resto de la partición, dividiendo así el cluster seleccionado en dos nuevos clusters

- **Algoritmo método divisivo**

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.
 - Calcular la distancia media de cada observación respecto a las demás.

- **Algoritmo método divisivo**
- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.
 - Calcular la distancia media de cada observación respecto a las demás.
 - La observación más distante inicia un nuevo cluster

- **Algoritmo método divisivo**

- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.
 - Calcular la distancia media de cada observación respecto a las demás.
 - La observación más distante inicia un nuevo cluster
 - Se reasignan las observaciones restantes al nuevo cluster o al viejo dependiendo de cual está más próximo.

- **Algoritmo método divisivo**

- Todas las n observaciones forman un único cluster.
- Repetir hasta que hayan n clusters:
 - Calcular para cada cluster la mayor de las distancias entre pares de observaciones (diámetro del cluster).
 - Seleccionar el cluster con mayor diámetro.
 - Calcular la distancia media de cada observación respecto a las demás.
 - La observación más distante inicia un nuevo cluster
 - Se reasignan las observaciones restantes al nuevo cluster o al viejo dependiendo de cual está más próximo.
- A diferencia del proceso aglomerativo, en el que hay que elegir un tipo de distancia y la liga, en el proceso divisivo sólo hay que elegir la distancia, no hay liga

- Distancias entre clusters

- **Distancias entre clusters**

- Una vez que se ha definido qué distancia conviene usar para los casos, debemos decidir cómo se habrá de calcular la distancia de un individuo a un conglomerado y la distancia entre los conglomerados.

- **Distancias entre clusters**

- Una vez que se ha definido qué distancia conviene usar para los casos, debemos decidir cómo se habrá de calcular la distancia de un individuo a un conglomerado y la distancia entre los conglomerados.
- Para este fin, se tiene las siguientes medidas, conocidas en la literatura de análisis de conglomerados, como *ligas*.

- **Distancias entre clusters**
- Una vez que se ha definido qué distancia conviene usar para los casos, debemos decidir cómo se habrá de calcular la distancia de un individuo a un conglomerado y la distancia entre los conglomerados.
- Para este fin, se tiene las siguientes medidas, conocidas en la literatura de análisis de conglomerados, como *ligas*.
- Ilustraremos cada una de estas ligas con la matriz de distancia

- **Distancias entre clusters**

- Una vez que se ha definido qué distancia conviene usar para los casos, debemos decidir cómo se habrá de calcular la distancia de un individuo a un conglomerado y la distancia entre los conglomerados.
- Para este fin, se tiene las siguientes medidas, conocidas en la literatura de análisis de conglomerados, como *ligas*.
- Ilustraremos cada una de estas ligas con la matriz de distancia

		Distancias				
		1	2	3	4	5
	1	0	9	3	6	11
●	2	9	0	7	5	10
	3	3	7	0	9	2
	4	6	5	9	0	8
	5	11	10	2	8	0

- Vecinos cercanos o liga simple

- **Vecinos cercanos o liga simple**
- Aquí la distancia entre dos conglomerados es la distancia entre sus sujetos más cercanos.


- **Vecinos cercanos o liga simple**
- Aquí la distancia entre dos conglomerados es la distancia entre sus sujetos más cercanos.
- En términos matemáticos, si tenemos un cluster **R** y otro **S**, entonces la distancia es:

- **Vecinos cercanos o liga simple**
- Aquí la distancia entre dos conglomerados es la distancia entre sus sujetos más cercanos.
- En términos matemáticos, si tenemos un cluster **R** y otro **S**, entonces la distancia es:

$$● d(\mathbf{R}, \mathbf{S}) = \min(d_{ij}, i \in \mathbf{R}, j \in \mathbf{S})$$

- **Vecinos cercanos o liga simple**
- Aquí la distancia entre dos conglomerados es la distancia entre sus sujetos más cercanos.
- En términos matemáticos, si tenemos un cluster **R** y otro **S**, entonces la distancia es:

$$\bullet d(\mathbf{R}, \mathbf{S}) = \min(d_{ij}, i \in \mathbf{R}, j \in \mathbf{S})$$



- Observando las distancias entre todos los sujetos en nuestra matriz de distancias, **D**, observamos que la mínima de éstas es 3 y corresponde a los sujetos (3, 5), por lo que son los primeros en unirse y lo hacen a una *altura*=2.

- Observando las distancias entre todos los sujetos en nuestra matriz de distancias, **D**, observamos que la mínima de éstas es 3 y corresponde a los sujetos (3, 5), por lo que son los primeros en unirse y lo hacen a una *altura*=2.
- Ahora bien, esta unión de sujetos ya constituye un grupo, por lo que hay que calcular las distancias de este grupo al resto de los elementos utilizando la liga simple, es decir, hay que calcular

- Observando las distancias entre todos los sujetos en nuestra matriz de distancias, **D**, observamos que la mínima de éstas es 3 y corresponde a los sujetos (3, 5), por lo que son los primeros en unirse y lo hacen a una *altura*=2.
- Ahora bien, esta unión de sujetos ya constituye un grupo, por lo que hay que calcular las distancias de este grupo al resto de los elementos utilizando la liga simple, es decir, hay que calcular



$$d\{(3, 5), 1\} = \min\{d(3, 1), d(5, 1)\} = \min\{3, 11\} = 3$$

$$d\{(3, 5), 2\} = \min\{d(3, 2), d(5, 2)\} = \min\{7, 10\} = 7$$

$$d\{(3, 5), 4\} = \min\{d(3, 4), d(5, 4)\} = \min\{9, 8\} = 8$$

- Observando las distancias entre todos los sujetos en nuestra matriz de distancias, **D**, observamos que la mínima de éstas es 3 y corresponde a los sujetos (3, 5), por lo que son los primeros en unirse y lo hacen a una *altura*=2.
- Ahora bien, esta unión de sujetos ya constituye un grupo, por lo que hay que calcular las distancias de este grupo al resto de los elementos utilizando la liga simple, es decir, hay que calcular

●

$$d\{(3, 5), 1\} = \min\{d(3, 1), d(5, 1)\} = \min\{3, 11\} = 3$$

$$d\{(3, 5), 2\} = \min\{d(3, 2), d(5, 2)\} = \min\{7, 10\} = 7$$

$$d\{(3, 5), 4\} = \min\{d(3, 4), d(5, 4)\} = \min\{9, 8\} = 8$$

- La nueva matriz de distancias **D**₁, se obtiene considerando estas distancias calculadas con este primer grupo formado. En concreto tenemos



		D_1			
		$(3,5)$	1	2	4
$(3,5)$	0	3	7	8	
1	3	0	9	6	
2	7	9	0	5	
4	8	6	5	0	

		D_1			
		$(3,5)$	1	2	4
●	$(3,5)$	0	3	7	8
	1	3	0	9	6
	2	7	9	0	5
	4	8	6	5	0

- Realizando el mismo proceso inicial, la distancia mínima entre estos grupos es 3 y corresponde a los grupos $(3,5)$ y 1. Entonces, el siguiente agrupamiento genera al grupo $(1,3,5)$. Nuevamente, debemos calcular la distancia de este grupo a cada uno de los otros elementos, a través de la liga simple

		D_1			
		$(3,5)$	1	2	4
•	$(3,5)$	0	3	7	8
	1	3	0	9	6
	2	7	9	0	5
	4	8	6	5	0

- Realizando el mismo proceso inicial, la distancia mínima entre estos grupos es 3 y corresponde a los grupos $(3, 5)$ y 1. Entonces, el siguiente agrupamiento genera al grupo $(1, 3, 5)$. Nuevamente, debemos calcular la distancia de este grupo a cada uno de los otros elementos, a través de la liga simple



$$d\{(1, 3, 5), 2\} = \min \{d(1, 2), d(3, 2), d(5, 2)\} = \min \{9, 7, 10\} = 7$$

$$d\{(1, 3, 5), 4\} = \min \{d(1, 4), d(3, 4), d(5, 4)\} = \min \{6, 9, 8\} = 6$$

		D_1			
		$(3,5)$	1	2	4
●	$(3,5)$	0	3	7	8
	1	3	0	9	6
	2	7	9	0	5
	4	8	6	5	0

- Realizando el mismo proceso inicial, la distancia mínima entre estos grupos es 3 y corresponde a los grupos $(3, 5)$ y 1. Entonces, el siguiente agrupamiento genera al grupo $(1, 3, 5)$. Nuevamente, debemos calcular la distancia de este grupo a cada uno de los otros elementos, a través de la liga simple



$$d\{(1, 3, 5), 2\} = \min\{d(1, 2), d(3, 2), d(5, 2)\} = \min\{9, 7, 10\} = 7$$

$$d\{(1, 3, 5), 4\} = \min\{d(1, 4), d(3, 4), d(5, 4)\} = \min\{6, 9, 8\} = 6$$

- Por lo que nuestra nueva matriz de distancias es

		D_2		
		$(1,3,5)$	2	4
•	$(1,3,5)$	0	7	6
	2	7	0	5
	4	6	5	0

		D_2		
		(1,3,5)	2	4
•	(1,3,5)	0	7	6
	2	7	0	5
	4	6	5	0

- La distancia mínima en esta matriz es 5 y corresponde a la de los sujetos (2, 4), que constituyen el siguiente grupo formado y que, como vemos, es diferente al que ya habíamos constituido. Ahora debemos encontrar la distancia entre estos dos grupos

		D_2		
		(1,3,5)	2	4
•	(1,3,5)	0	7	6
	2	7	0	5
	4	6	5	0

- La distancia mínima en esta matriz es 5 y corresponde a la de los sujetos (2, 4), que constituyen el siguiente grupo formado y que, como vemos, es diferente al que ya habíamos constituido. Ahora debemos encontrar la distancia entre estos dos grupos



$$\begin{aligned}
 d\{(1, 3, 5), (2, 4)\} &= \min \{d(1, 2), d(3, 2), d(5, 2), d(1, 4), d(3, 4), d(5, 4)\} \\
 &= \min \{9, 7, 10, 6, 9, 8\} = 6
 \end{aligned}$$

		D_2		
		(1,3,5)	2	4
•	(1,3,5)	0	7	6
	2	7	0	5
	4	6	5	0

- La distancia mínima en esta matriz es 5 y corresponde a la de los sujetos (2,4), que constituyen el siguiente grupo formado y que, como vemos, es diferente al que ya habíamos constituido. Ahora debemos encontrar la distancia entre estos dos grupos



$$\begin{aligned}
 d\{(1, 3, 5), (2, 4)\} &= \min \{d(1, 2), d(3, 2), d(5, 2), d(1, 4), d(3, 4), d(5, 4)\} \\
 &= \min \{9, 7, 10, 6, 9, 8\} = 6
 \end{aligned}$$

- Y la última de nuestras matrices es

•

	D_3	
	$(1,3,5)$	$(2,4)$
$(1,3,5)$	0	6
$(2,4)$	6	0


	D_3	
	(1,3,5)	(2,4)
(1,3,5)	0	6
(2,4)	6	0

- Esta distancia a la que se unen los dos grupos formados, constituye la distancia máxima a la que se unen *todas las observaciones* y genera un único grupo, como ya sabemos que debe suceder con un algoritmo *aglomerativo*.

•

	D_3	
	(1,3,5)	(2,4)
(1,3,5)	0	6
(2,4)	6	0

- Esta distancia a la que se unen los dos grupos formados, constituye la distancia máxima a la que se unen *todas las observaciones* y genera un único grupo, como ya sabemos que debe suceder con un algoritmo *aglomerativo*.
- Observemos que esta agrupación, así como las distancias (alturas) de unión entre los grupos, coincide totalmente con el *dendrograma* mostrado en la gráfica siguiente.



hclust (*, "single")

- Vecinos lejanos o liga compuesta

- **Vecinos lejanos o liga compuesta**
- Aquí La distancia entre dos conglomerados es la distancia entre sus dos sujetos más lejanos

- **Vecinos lejanos o liga compuesta**
- Aquí La distancia entre dos conglomerados es la distancia entre sus dos sujetos más lejanos
- En términos matemáticos, si tenemos un cluster **R** y otro **S**, entonces la distancia es:


- **Vecinos lejanos o liga compuesta**
- Aquí La distancia entre dos conglomerados es la distancia entre sus dos sujetos más lejanos
- En términos matemáticos, si tenemos un cluster **R** y otro **S**, entonces la distancia es:

$$d(\mathbf{R}, \mathbf{S}) = \max(d_{ij}, i \in \mathbf{R}, j \in \mathbf{S})$$

- **Vecinos lejanos o liga compuesta**
- Aquí La distancia entre dos conglomerados es la distancia entre sus dos sujetos más lejanos
- En términos matemáticos, si tenemos un cluster **R** y otro **S**, entonces la distancia es:

$$d(\mathbf{R}, \mathbf{S}) = \max(d_{ij}, i \in \mathbf{R}, j \in \mathbf{S})$$

Liga Completa



- Para esta liga, el primer conglomerado se hace igual que en la liga simple, y está constituido por $(3, 5)$, y se unen a altura 2. Una vez establecido este grupo, procedemos a encontrar su distancia al resto de los elementos, utilizando la liga completa, de la siguiente forma

- Para esta liga, el primer conglomerado se hace igual que en la liga simple, y está constituido por $(3, 5)$, y se unen a altura 2. Una vez establecido este grupo, procedemos a encontrar su distancia al resto de los elementos, utilizando la liga completa, de la siguiente forma



$$d\{(3, 5), 1\} = \max\{d(3, 1), d(5, 1)\} = \max\{3, 11\} = 11$$

$$d\{(3, 5), 2\} = \max\{d(3, 2), d(5, 2)\} = \max\{7, 10\} = 10$$

$$d\{(3, 5), 4\} = \max\{d(3, 4), d(5, 4)\} = \max\{9, 8\} = 9$$

- Para esta liga, el primer conglomerado se hace igual que en la liga simple, y está constituido por $(3, 5)$, y se unen a altura 2. Una vez establecido este grupo, procedemos a encontrar su distancia al resto de los elementos, utilizando la liga completa, de la siguiente forma



$$d\{(3, 5), 1\} = \max\{d(3, 1), d(5, 1)\} = \max\{3, 11\} = 11$$

$$d\{(3, 5), 2\} = \max\{d(3, 2), d(5, 2)\} = \max\{7, 10\} = 10$$

$$d\{(3, 5), 4\} = \max\{d(3, 4), d(5, 4)\} = \max\{9, 8\} = 9$$

- La nueva matriz de distancias $\mathbf{D}_1$, se obtiene considerando estas distancias calculadas con este primer grupo formado. En concreto tenemos



		D_1			
		$(3,5)$	1	2	4
$(3,5)$	0	11	10	9	
1	11	0	9	6	
2	10	9	0	5	
4	9	6	5	0	

		D_1			
		(3,5)	1	2	4
•	(3,5)	0	11	10	9
	1	11	0	9	6
	2	10	9	0	5
	4	9	6	5	0

- La distancia mínima en esta matriz corresponde a los individuos (2,4), con altura=5, que forman el siguiente grupo. El siguiente paso es calcular la distancia entre estos nuevos grupos, con la liga completa.

		D_1			
		(3,5)	1	2	4
•	(3,5)	0	11	10	9
	1	11	0	9	6
	2	10	9	0	5
	4	9	6	5	0

- La distancia mínima en esta matriz corresponde a los individuos (2, 4), con altura=5, que forman el siguiente grupo. El siguiente paso es calcular la distancia entre estos nuevos grupos, con la liga completa.



$$\begin{aligned}
 d\{(3, 5), (2, 4)\} &= \max\{d(3, 2), d(3, 4), d(5, 2), d(5, 4)\} = \max\{7, 9, 10, 8\} = 10 \\
 d\{(3, 5), 1\} &= \max\{d(3, 1), d(5, 1)\} = \max\{3, 11\} = 11 \\
 d\{(2, 4), 1\} &= \max\{d(2, 1), d(4, 1)\} = \max\{9, 6\} = 9
 \end{aligned}$$

		D_1			
		(3,5)	1	2	4
•	(3,5)	0	11	10	9
	1	11	0	9	6
	2	10	9	0	5
	4	9	6	5	0

- La distancia mínima en esta matriz corresponde a los individuos (2, 4), con altura=5, que forman el siguiente grupo. El siguiente paso es calcular la distancia entre estos nuevos grupos, con la liga completa.



$$\begin{aligned}
 d\{(3, 5), (2, 4)\} &= \max\{d(3, 2), d(3, 4), d(5, 2), d(5, 4)\} = \max\{7, 9, 10, 8\} = 10 \\
 d\{(3, 5), 1\} &= \max\{d(3, 1), d(5, 1)\} = \max\{3, 11\} = 11 \\
 d\{(2, 4), 1\} &= \max\{d(2, 1), d(4, 1)\} = \max\{9, 6\} = 9
 \end{aligned}$$

- Con lo que generamos la siguiente matriz

- | | | D_2 | | |
|-------|--|-------|----|-------|
| | | (3,5) | 1 | (2,4) |
| (3,5) | | 0 | 11 | 10 |
| 1 | | 11 | 0 | 9 |
| (2,4) | | 10 | 9 | 0 |

		D_2		
		$(3,5)$	1	$(2,4)$
•	$(3,5)$	0	11	10
	1	11	0	9
	$(2,4)$	10	9	0

- Observamos que la distancia más pequeña es 9, y corresponde a la unión de los grupos $(2, 4)$ y 1 , que generan el grupo $(1, 2, 4)$. Volvemos a calcular la distancia entre los grupos $(3, 5)$ y $(1, 2, 4)$ a través de la liga completa.

		D_2		
		(3,5)	1	(2,4)
•	(3,5)	0	11	10
	1	11	0	9
	(2,4)	10	9	0

- Observamos que la distancia más pequeña es 9, y corresponde a la unión de los grupos (2, 4) y 1, que generan el grupo (1, 2, 4). Volvemos a calcular la distancia entre los grupos (3, 5) y (1, 2, 4) a través de la liga completa.

•

$$\begin{aligned}
 d\{(3, 5), (1, 2, 4)\} &= \max\{d(3, 1), d(3, 2), d(3, 4), d(5, 1), d(5, 2), d(5, 4)\} \\
 &= \max\{3, 7, 9, 11, 10, 8\} = 11
 \end{aligned}$$

		D_2		
		(3,5)	1	(2,4)
•	(3,5)	0	11	10
	1	11	0	9
	(2,4)	10	9	0

- Observamos que la distancia más pequeña es 9, y corresponde a la unión de los grupos (2, 4) y 1, que generan el grupo (1, 2, 4). Volvemos a calcular la distancia entre los grupos (3, 5) y (1, 2, 4) a través de la liga completa.

•

$$\begin{aligned}
 d\{(3, 5), (1, 2, 4)\} &= \max\{d(3, 1), d(3, 2), d(3, 4), d(5, 1), d(5, 2), d(5, 4)\} \\
 &= \max\{3, 7, 9, 11, 10, 8\} = 11
 \end{aligned}$$

- Y genera la matriz


•

	D_3	
	$(3,5)$	$(1,2,4)$
$(3,5)$	0	11
$(1,2,4)$	11	0



	D_3	
	$(3,5)$	$(1,2,4)$
$(3,5)$	0	11
$(1,2,4)$	11	0

- Esta es la distancia a la que todas las observaciones se unen en un solo grupo. Nuevamente observamos que los grupos formados y las distancias (alturas) que calculamos, coinciden con la gráfica de esta liga.



`hclust(*, "complete")`

- Liga promedio

- **Liga promedio**
- Es la distancia promedio entre todas las posibles distancias intra o inter clusters. Apropiaada, cuando el investigador asume que los grupos son homogéneos.

- **Liga promedio**
- Es la distancia promedio entre todas las posibles distancias intra o inter clusters. Apropiaada, cuando el investigador asume que los grupos son homogéneos.
- En símbolos, si tenemos un cluster **R** con n_R elementos, y otro **S**, con n_S elementos, entonces la distancia es:

- **Liga promedio**
- Es la distancia promedio entre todas las posibles distancias intra o inter clusters. Apropiaada, cuando el investigador asume que los grupos son homogéneos.
- En símbolos, si tenemos un cluster **R** con n_R elementos, y otro **S**, con n_S elementos, entonces la distancia es:


$$\bullet \quad d(\mathbf{R}, \mathbf{S}) = \frac{1}{n_R} \frac{1}{n_S} \sum_{i \in \mathbf{R}} \sum_{j \in \mathbf{S}} d_{ij}$$

- **Liga promedio**

- Es la distancia promedio entre todas las posibles distancias intra o inter clusters. Apropiaada, cuando el investigador asume que los grupos son homogéneos.
- En símbolos, si tenemos un cluster **R** con n_R elementos, y otro **S**, con n_S elementos, entonces la distancia es:

- $$d(\mathbf{R}, \mathbf{S}) = \frac{1}{n_R} \frac{1}{n_S} \sum_{i \in \mathbf{R}} \sum_{j \in \mathbf{S}} d_{ij}$$

Liga Promedio



- Igual que para los dos casos anteriores, las observaciones que se unen inicialmente, son $(3, 5)$, que se unen a altura 2. Una vez que se obtiene este cluster, hay que calcular sus distancia al resto de los elementos, utilizando la liga promedio. Es decir

- Igual que para los dos casos anteriores, las observaciones que se unen inicialmente, son $(3, 5)$, que se unen a altura 2. Una vez que se obtiene este cluster, hay que calcular sus distancia al resto de los elementos, utilizando la liga promedio. Es decir



$$d\{(3, 5), 1\} = \frac{1}{2} \{d(3, 1) + d(5, 1)\} = \frac{1}{2}(3 + 11) = 7$$

$$d\{(3, 5), 2\} = \frac{1}{2} \{d(3, 2) + d(5, 2)\} = \frac{1}{2}(7 + 10) = 8.5$$

$$d\{(3, 5), 4\} = \frac{1}{2} \{d(3, 4) + d(5, 4)\} = \frac{1}{2}(9 + 8) = 8.5$$

- Igual que para los dos casos anteriores, las observaciones que se unen inicialmente, son $(3, 5)$, que se unen a altura 2. Una vez que se obtiene este cluster, hay que calcular sus distancia al resto de los elementos, utilizando la liga promedio. Es decir



$$d\{(3, 5), 1\} = \frac{1}{2} \{d(3, 1) + d(5, 1)\} = \frac{1}{2}(3 + 11) = 7$$

$$d\{(3, 5), 2\} = \frac{1}{2} \{d(3, 2) + d(5, 2)\} = \frac{1}{2}(7 + 10) = 8.5$$

$$d\{(3, 5), 4\} = \frac{1}{2} \{d(3, 4) + d(5, 4)\} = \frac{1}{2}(9 + 8) = 8.5$$

- Y la correspondiente matriz de distancias es ahora

- Igual que para los dos casos anteriores, las observaciones que se unen inicialmente, son (3,5), que se unen a altura 2. Una vez que se obtiene este cluster, hay que calcular sus distancia al resto de los elementos, utilizando la liga promedio. Es decir

$$d\{(3,5), 1\} = \frac{1}{2} \{d(3,1) + d(5,1)\} = \frac{1}{2}(3 + 11) = 7$$

$$d\{(3,5), 2\} = \frac{1}{2} \{d(3,2) + d(5,2)\} = \frac{1}{2}(7 + 10) = 8.5$$

$$d\{(3,5), 4\} = \frac{1}{2} \{d(3,4) + d(5,4)\} = \frac{1}{2}(9 + 8) = 8.5$$

- Y la correspondiente matriz de distancias es ahora

		D₁			
		(3,5)	1	2	4
●	(3,5)	0	7	8.5	8.5
	1	7	0	9	6
	2	8.5	9	0	5
	4	8.5	6	5	0

- La distancia mínima en esta matriz corresponde a las observaciones (2,4), que forman un nuevo grupo, que se une a *altura*=5. Nuevamente debemos calcular la distancia entre estos clusters mediante la liga promedio.

- La distancia mínima en esta matriz corresponde a las observaciones (2, 4), que forman un nuevo grupo, que se une a *altura*=5. Nuevamente debemos calcular la distancia entre estos clusters mediante la liga promedio.



$$d \{(3, 5), (2, 4)\} = \frac{1}{4} \{d(3, 2) + d(5, 4) + d(5, 2) + d(5, 4)\} = \frac{1}{4}(7 + 9 + 10 + 8) = 8.5$$

$$d \{(3, 5), 1\} = \frac{1}{2} \{d(3, 1) + d(5, 1)\} = \frac{1}{2}(3 + 11) = 7$$

$$d \{(2, 4), 1\} = \frac{1}{2} \{d(2, 1) + d(4, 1)\} = \frac{1}{2}(9 + 6) = 7.5$$

- La distancia mínima en esta matriz corresponde a las observaciones (2, 4), que forman un nuevo grupo, que se une a *altura*=5. Nuevamente debemos calcular la distancia entre estos clusters mediante la liga promedio.



$$d \{(3, 5), (2, 4)\} = \frac{1}{4} \{d(3, 2) + d(5, 4) + d(5, 2) + d(5, 4)\} = \frac{1}{4}(7 + 9 + 10 + 8) = 8.5$$

$$d \{(3, 5), 1\} = \frac{1}{2} \{d(3, 1) + d(5, 1)\} = \frac{1}{2}(3 + 11) = 7$$

$$d \{(2, 4), 1\} = \frac{1}{2} \{d(2, 1) + d(4, 1)\} = \frac{1}{2}(9 + 6) = 7.5$$

- Que genera la matriz de distancias

- La distancia mínima en esta matriz corresponde a las observaciones (2, 4), que forman un nuevo grupo, que se une a *altura*=5. Nuevamente debemos calcular la distancia entre estos clusters mediante la liga promedio.



$$d \{(3, 5), (2, 4)\} = \frac{1}{4} \{d(3, 2) + d(5, 4) + d(5, 2) + d(5, 4)\} = \frac{1}{4}(7 + 9 + 10 + 8) = 8.5$$

$$d \{(3, 5), 1\} = \frac{1}{2} \{d(3, 1) + d(5, 1)\} = \frac{1}{2}(3 + 11) = 7$$

$$d \{(2, 4), 1\} = \frac{1}{2} \{d(2, 1) + d(4, 1)\} = \frac{1}{2}(9 + 6) = 7.5$$

- Que genera la matriz de distancias

	D_2			
		(3,5)	1	(2,4)
•	(3,5)	0	7	8.5
	1	7	0	7.5
	(2,4)	8.5	7.5	0

- Cuya distancia mínima es 7 y corresponde a la unión de los grupos $(3, 5)$ y 1 , que originan el grupo $(1, 3, 5)$. La distancia entre estos grupos es

- Cuya distancia mínima es 7 y corresponde a la unión de los grupos (3, 5) y 1, que originan el grupo (1, 3, 5). La distancia entre estos grupos es



$$\begin{aligned}d \{(1, 3, 5), (2, 4)\} &= \frac{1}{6} \{d(1, 2) + d(3, 2) + d(5, 2) + d(1, 4) + d(3, 4) + d(5, 4)\} \\&= \frac{1}{6} (9 + 7 + 9 + 6 + 10 + 8) = 8.166\end{aligned}$$

- Cuya distancia mínima es 7 y corresponde a la unión de los grupos (3, 5) y 1, que originan el grupo (1, 3, 5). La distancia entre estos grupos es



$$\begin{aligned}
 d\{(1, 3, 5), (2, 4)\} &= \frac{1}{6} \{d(1, 2) + d(3, 2) + d(5, 2) + d(1, 4) + d(3, 4) + d(5, 4)\} \\
 &= \frac{1}{6} (9 + 7 + 9 + 6 + 10 + 8) = 8.166
 \end{aligned}$$

- Que genera la matriz

- Cuya distancia mínima es 7 y corresponde a la unión de los grupos (3, 5) y 1, que originan el grupo (1, 3, 5). La distancia entre estos grupos es



$$\begin{aligned}
 d\{(1, 3, 5), (2, 4)\} &= \frac{1}{6} \{d(1, 2) + d(3, 2) + d(5, 2) + d(1, 4) + d(3, 4) + d(5, 4)\} \\
 &= \frac{1}{6} (9 + 7 + 9 + 6 + 10 + 8) = 8.166
 \end{aligned}$$

- Que genera la matriz

	D₃	
	(1,3,5)	(2,4)
(3,5)	0	8.166
(2,4)	8.166	0

- Cuya distancia mínima es 7 y corresponde a la unión de los grupos (3, 5) y 1, que originan el grupo (1, 3, 5). La distancia entre estos grupos es




$$\begin{aligned} d\{(1, 3, 5), (2, 4)\} &= \frac{1}{6} \{d(1, 2) + d(3, 2) + d(5, 2) + d(1, 4) + d(3, 4) + d(5, 4)\} \\ &= \frac{1}{6} (9 + 7 + 9 + 6 + 10 + 8) = 8.166 \end{aligned}$$

- Que genera la matriz

	D_3	
	(1,3,5)	(2,4)
(3,5)	0	8.166
(2,4)	8.166	0

- Entonces, la distancia final a la que se unen todos los grupos es 8.166. Observe que los grupos y las distancias a las que se unen, coinciden con la gráfica correspondiente a esta distancia promedio.

Cluster: Liga promedio



hclust(*, "average")

- Liga del centroide


- **Liga del centroide**


- Se usa generalmente sólo con variables continuas. Para esta liga, la distancia entre dos clusters es la distancia euclídeana entre sus centros (centroides), que son los vectores de medias de las observaciones que pertenecen al grupo.

- **Liga del centroide**

- Se usa generalmente sólo con variables continuas. Para esta liga, la distancia entre dos clusters es la distancia euclídeana entre sus centros (centroides), que son los vectores de medias de las observaciones que pertenecen al grupo.

Liga Centroide





`hclust(*, "centroid")`

- Método de Ward

- **Método de Ward**

- Este método es un proceso diferente a los anteriores, para construir un cluster jerárquico, y fue propuesto por Ward y Wishart.
- A diferencia con los métodos anteriores, aquí se parte de los elementos directamente, sin necesidad de construir la matriz de distancias, y se define una medida global de la heterogeneidad de observaciones aglutinadas en grupos.

- **Método de Ward**

- Este método es un proceso diferente a los anteriores, para construir un cluster jerárquico, y fue propuesto por Ward y Wishart.
- A diferencia con los métodos anteriores, aquí se parte de los elementos directamente, sin necesidad de construir la matriz de distancias, y se define una medida global de la heterogeneidad de observaciones aglutinadas en grupos.
- Dicha medida está dada por la suma de las distancias euclidianas al cuadrado entre cada elemento y la media de su grupo:

- **Método de Ward**

- Este método es un proceso diferente a los anteriores, para construir un cluster jerárquico, y fue propuesto por Ward y Wishart.
- A diferencia con los métodos anteriores, aquí se parte de los elementos directamente, sin necesidad de construir la matriz de distancias, y se define una medida global de la heterogeneidad de observaciones aglutinadas en grupos.
- Dicha medida está dada por la suma de las distancias euclidianas al cuadrado entre cada elemento y la media de su grupo:

$$\mathbf{W} = \sum_g \sum_{i \in g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)' (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)$$

- **Método de Ward**

- Este método es un proceso diferente a los anteriores, para construir un cluster jerárquico, y fue propuesto por Ward y Wishart.
- A diferencia con los métodos anteriores, aquí se parte de los elementos directamente, sin necesidad de construir la matriz de distancias, y se define una medida global de la heterogeneidad de observaciones aglutinadas en grupos.
- Dicha medida está dada por la suma de las distancias euclidianas al cuadrado entre cada elemento y la media de su grupo:

$$\mathbf{W} = \sum_g \sum_{i \in g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)' (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)$$


- Donde $\bar{\mathbf{x}}_g$ es la media del grupo g .

- El proceso de construcción inicia suponiendo que cada elemento forma un grupo, entonces, $g = n$ y por tanto **W** es cero.

- El proceso de construcción inicia suponiendo que cada elemento forma un grupo, entonces, $g = n$ y por tanto **W** es cero.
- En el siguiente paso se unen los elementos que produzcan el incremento mínimo de **W**. Obviamente, esto implica tomar los elementos más cercanos utilizando la distancia euclideana.

- El proceso de construcción inicia suponiendo que cada elemento forma un grupo, entonces, $g = n$ y por tanto **W** es cero.
- En el siguiente paso se unen los elementos que produzcan el incremento mínimo de **W**. Obviamente, esto implica tomar los elementos más cercanos utilizando la distancia euclídeana.
- Una vez concluido este paso, ahora tenemos $n - 1$ grupos; $n - 2$ de ellos de un elemento y uno con dos elementos. Utilizamos el mismo criterio para decidir qué grupos debemos unir ahora para que **W** crezca lo menos posible, con lo que obtenemos $n - 2$ grupos, y así sucesivamente hasta tener un único grupo (proceso aglomerativo).

- El proceso de construcción inicia suponiendo que cada elemento forma un grupo, entonces, $g = n$ y por tanto **W** es cero.
- En el siguiente paso se unen los elementos que produzcan el incremento mínimo de **W**. Obviamente, esto implica tomar los elementos más cercanos utilizando la distancia euclídeana.
- Una vez concluido este paso, ahora tenemos $n - 1$ grupos; $n - 2$ de ellos de un elemento y uno con dos elementos. Utilizamos el mismo criterio para decidir qué grupos debemos unir ahora para que **W** crezca lo menos posible, con lo que obtenemos $n - 2$ grupos, y así sucesivamente hasta tener un único grupo (proceso aglomerativo).
- Los valores de **W** indican el crecimiento del criterio al formar grupos y pueden utilizarse para decidir cuántos grupos contienen nuestros datos, de forma natural.



`hclust("ward")`

- ¿Cuál es el mejor?

- **¿Cuál es el mejor?**
- No existen reglas generales que lleven a la preferencia de una liga o método sobre otro; aunque los más utilizados son los tres últimos.

- **¿Cuál es el mejor?**

- No existen reglas generales que lleven a la preferencia de una liga o método sobre otro; aunque los más utilizados son los tres últimos.
- Una recomendación sensata es tratar de analizar cuál es el criterio más razonable de acuerdo a la naturaleza de los datos por agrupar. De no funcionar esta estrategia, es conveniente probar con algunas ligas y comparar sus resultados

- El dendrograma

- **El dendrograma**
- El *dendrograma*, también conocido como *árbol jerárquico*, es la representación gráfica del proceso de agrupamiento en forma de árbol. Los criterios para definir distancias entre grupos que hemos presentado, tienen la propiedad de que, si consideramos tres grupos, **A**, **B**, **C**, se cumple que

- **El dendrograma**

- El *dendrograma*, también conocido como *árbol jerárquico*, es la representación gráfica del proceso de agrupamiento en forma de árbol. Los criterios para definir distancias entre grupos que hemos presentado, tienen la propiedad de que, si consideramos tres grupos, **A**, **B**, **C**, se cumple que

$$d(\mathbf{A}, \mathbf{C}) \leq \max \{d(\mathbf{A}, \mathbf{B}) + d(\mathbf{B}, \mathbf{C})\}$$

- **El dendrograma**

- El *dendrograma*, también conocido como *árbol jerárquico*, es la representación gráfica del proceso de agrupamiento en forma de árbol. Los criterios para definir distancias entre grupos que hemos presentado, tienen la propiedad de que, si consideramos tres grupos, **A**, **B**, **C**, se cumple que

$$d(\mathbf{A}, \mathbf{C}) \leq \max \{d(\mathbf{A}, \mathbf{B}) + d(\mathbf{B}, \mathbf{C})\}$$

- Una medida de distancia con esta propiedad se denomina *ultramétrica*. Esta propiedad de “desigualdad del triángulo” es más fuerte que la propiedad estándar, ya que una ultramétrica es siempre una métrica.

- **El dendrograma**

- El *dendrograma*, también conocido como *árbol jerárquico*, es la representación gráfica del proceso de agrupamiento en forma de árbol. Los criterios para definir distancias entre grupos que hemos presentado, tienen la propiedad de que, si consideramos tres grupos, **A**, **B**, **C**, se cumple que

$$d(\mathbf{A}, \mathbf{C}) \leq \max \{d(\mathbf{A}, \mathbf{B}) + d(\mathbf{B}, \mathbf{C})\}$$

- Una medida de distancia con esta propiedad se denomina *ultramétrica*. Esta propiedad de “desigualdad del triángulo” es más fuerte que la propiedad estándar, ya que una ultramétrica es siempre una métrica.
- Ya que si $D^2(\mathbf{A}, \mathbf{C})$ es menor o igual a que el máximo de $D^2(\mathbf{A}, \mathbf{B})$ y $D^2(\mathbf{B}, \mathbf{C})$, entonces, necesariamente será menor o igual que su suma: $D^2(\mathbf{A}, \mathbf{B}) + D^2(\mathbf{B}, \mathbf{C})$. Entonces, el dendrograma es la representación gráfica de una ultramétrica, y su construcción es como sigue:

- En la parte inferior de la gráfica aparecen los n individuos u objetos a ser agrupados.

- En la parte inferior de la gráfica aparecen los n individuos u objetos a ser agrupados.
- Las uniones entre elementos están compuestas por tres líneas rectas. Dos verticales originadas en los elementos que se unen, y que son perpendiculares al eje de los elementos y una paralela a este eje que se sitúa al nivel (distancia o altura) a la que se unen.

- En la parte inferior de la gráfica aparecen los n individuos u objetos a ser agrupados.
- Las uniones entre elementos están compuestas por tres líneas rectas. Dos verticales originadas en los elementos que se unen, y que son perpendiculares al eje de los elementos y una paralela a este eje que se sitúa al nivel (distancia o altura) a la que se unen.
- El proceso se repite hasta que todos los elementos estén unidos por líneas rectas.

- En la parte inferior de la gráfica aparecen los n individuos u objetos a ser agrupados.
- Las uniones entre elementos están compuestas por tres líneas rectas. Dos verticales originadas en los elementos que se unen, y que son perpendiculares al eje de los elementos y una paralela a este eje que se sitúa al nivel (distancia o altura) a la que se unen.
- El proceso se repite hasta que todos los elementos estén unidos por líneas rectas.
- Si se corta el dendrograma a un nivel o altura específico, se obtiene una visualización del número de grupos existentes a ese nivel, y los elementos que los conforman. Por supuesto, si se hacen cortes a alturas diferentes en el dendrograma, es posible que se tengan agrupaciones diferentes, por lo que esta decisión es fundamental para este análisis.

- El dendrograma es útil cuando los grupos tienen una clara definición, pero puede ser poco útil si no es así.

- El dendrograma es útil cuando los grupos tienen una clara definición, pero puede ser poco útil si no es así.
- Ya que es necesario un despliegue gráfico, si el número de elementos por clasificar es muy grande, será muy difícil, casi imposible, identificar grupos visualmente bajo este procedimiento.

- **Verificar el dendrograma resultante**

- **Verificar el dendrograma resultante**
- Una vez creado el dendrograma, hay que evaluar hasta qué punto su estructura refleja las distancias originales entre observaciones. Una forma de hacerlo es empleando el coeficiente de correlación entre las distancias *cophenetic* del dendrograma (altura de los nodos) y la matriz de distancias original.

- **Verificar el dendrograma resultante**
- Una vez creado el dendrograma, hay que evaluar hasta qué punto su estructura refleja las distancias originales entre observaciones. Una forma de hacerlo es empleando el coeficiente de correlación entre las distancias *cophenetic* del dendrograma (altura de los nodos) y la matriz de distancias original.
- Cuanto más cercano es el valor a 1, mejor refleja el dendrograma la verdadera similitud entre las observaciones. Valores superiores a 0.75 suelen considerarse como buenos. Esta medida puede emplearse como criterio de ayuda para elegir entre las distintas ligas.

- **Verificar el dendrograma resultante**
- Una vez creado el dendrograma, hay que evaluar hasta qué punto su estructura refleja las distancias originales entre observaciones. Una forma de hacerlo es empleando el coeficiente de correlación entre las distancias *cophenetic* del dendrograma (altura de los nodos) y la matriz de distancias original.
- Cuanto más cercano es el valor a 1, mejor refleja el dendrograma la verdadera similitud entre las observaciones. Valores superiores a 0.75 suelen considerarse como buenos. Esta medida puede emplearse como criterio de ayuda para elegir entre las distintas ligas.
- En **R**, la función *cophenetic()* calcula las distancias cophenetic de un cluster jerárquico

- Cortar el árbol para generar los clusters

- **Cortar el árbol para generar los clusters**
- Además de representar en un dendrograma la similitud entre observaciones, se tiene que poder identificar el número de clusters creados y qué observaciones forman parte de cada uno.

- **Cortar el árbol para generar los clusters**
- Además de representar en un dendrograma la similitud entre observaciones, se tiene que poder identificar el número de clusters creados y qué observaciones forman parte de cada uno.
- Si se realiza un corte horizontal a una determinada altura del dendrograma, el número de ramas que sobrepasan (en sentido ascendente) dicho corte se corresponde con el número de clusters.

- **Cortar el árbol para generar los clusters**
- Además de representar en un dendrograma la similitud entre observaciones, se tiene que poder identificar el número de clusters creados y qué observaciones forman parte de cada uno.
- Si se realiza un corte horizontal a una determinada altura del dendrograma, el número de ramas que sobrepasan (en sentido ascendente) dicho corte se corresponde con el número de clusters.
- Cortes a distintas alturas generan, obviamente, número distinto de clusters.

- **Cortar el árbol para generar los clusters**
- Además de representar en un dendrograma la similitud entre observaciones, se tiene que poder identificar el número de clusters creados y qué observaciones forman parte de cada uno.
- Si se realiza un corte horizontal a una determinada altura del dendrograma, el número de ramas que sobrepasan (en sentido ascendente) dicho corte se corresponde con el número de clusters.
- Cortes a distintas alturas generan, obviamente, número distinto de clusters.
- La altura de corte tiene por lo tanto la misma función que el valor K en el método de K medias: controla el número de clusters obtenidos

- En el dendrograma se dispone de la flexibilidad para generar cualquier número de clusters desde 1 a n . La selección del número óptimo puede valorarse de forma visual, tratando de identificar las ramas principales con base a la altura a la que ocurren las uniones.

- En el dendrograma se dispone de la flexibilidad para generar cualquier número de clusters desde 1 a n . La selección del número óptimo puede valorarse de forma visual, tratando de identificar las ramas principales con base a la altura a la que ocurren las uniones.
- Dado que todos los clusters terminan uniéndose al final, es conveniente considerar el corte en el dendrograma cuando la altura entre las uniones de los clusters parece muy grande, ya que esto implicaría que la distancia entre ellos también lo es.

- En el dendrograma se dispone de la flexibilidad para generar cualquier número de clusters desde 1 a n . La selección del número óptimo puede valorarse de forma visual, tratando de identificar las ramas principales con base a la altura a la que ocurren las uniones.
- Dado que todos los clusters terminan uniéndose al final, es conveniente considerar el corte en el dendrograma cuando la altura entre las uniones de los clusters parece muy grande, ya que esto implicaría que la distancia entre ellos también lo es.
- Como se observa, la elección de una altura para cortar el dendrograma es bastante subjetiva, por lo que, si se tiene alguna idea de los elementos que debieran estar en cada cluster, podríamos cortar a una altura que nos proporcione estos clusters visualizados a priori.