

- **Aprendizaje No supervisado: Componentes principales**

- **Aprendizaje No supervisado: Componentes principales**
- **Técnicas de reducción de dimensión**

- Aprendizaje No supervisado: Componentes principales
- Técnicas de reducción de dimensión
- Introducción

- **Aprendizaje No supervisado: Componentes principales**
- **Técnicas de reducción de dimensión**
- **Introducción**
- El objetivo principal de la mayoría de las técnicas numéricas de análisis multivariado, es reducir la dimensión de nuestros datos. Si esta reducción se puede hacer a 2 ó 3 dimensiones, se tiene la posibilidad de una visión gráfica de los mismos.

- **Aprendizaje No supervisado: Componentes principales**
- **Técnicas de reducción de dimensión**
- **Introducción**
- El objetivo principal de la mayoría de las técnicas numéricas de análisis multivariado, es reducir la dimensión de nuestros datos. Si esta reducción se puede hacer a 2 ó 3 dimensiones, se tiene la posibilidad de una visión gráfica de los mismos.
- Obvio, *siempre* es posible hacer la reducción a este número de dimensiones, pero es importante juzgar si estas pocas dimensiones son suficientes para resumir la información contenida en todas las variables.

- **Aprendizaje No supervisado: Componentes principales**
- **Técnicas de reducción de dimensión**
- **Introducción**
- El objetivo principal de la mayoría de las técnicas numéricas de análisis multivariado, es reducir la dimensión de nuestros datos. Si esta reducción se puede hacer a 2 ó 3 dimensiones, se tiene la posibilidad de una visión gráfica de los mismos.
- Obvio, *siempre* es posible hacer la reducción a este número de dimensiones, pero es importante juzgar si estas pocas dimensiones son suficientes para resumir la información contenida en todas las variables.
- El *análisis de componentes principales* es parte de las técnicas de *Aprendizaje no Supervisado*, porque, como en la mayoría de las técnicas de análisis multivariado, no tenemos una variable de respuesta.

- En esta situación sólo contamos con un número, usualmente muy grande, de variables que nos interesa analizar o estudiar, y de las que queremos extraer información, por ejemplo, sobre la existencia de subgrupos entre las variables u observaciones, valores atípicos, estructura de asociación entre variables, etc.

- En esta situación sólo contamos con un número, usualmente muy grande, de variables que nos interesa analizar o estudiar, y de las que queremos extraer información, por ejemplo, sobre la existencia de subgrupos entre las variables u observaciones, valores atípicos, estructura de asociación entre variables, etc.
- El *análisis de componentes principales* tiene como objetivo: dadas n observaciones de p variables, se analiza si es posible representar adecuadamente esta información con un número menor, $q \ll p$ (reducción de dimensión), de *variables construidas como combinaciones lineales de las originales*, llamadas *componentes principales*.

- En esta situación sólo contamos con un número, usualmente muy grande, de variables que nos interesa analizar o estudiar, y de las que queremos extraer información, por ejemplo, sobre la existencia de subgrupos entre las variables u observaciones, valores atípicos, estructura de asociación entre variables, etc.
- El *análisis de componentes principales* tiene como objetivo: dadas n observaciones de p variables, se analiza si es posible representar adecuadamente esta información con un número menor, $q \ll p$ (reducción de dimensión), de *variables construidas como combinaciones lineales de las originales*, llamadas *componentes principales*.
- Esta técnica se debe a *Hotelling (1933)*, aunque sus orígenes se encuentran en los ajustes ortogonales por mínimos cuadrados introducidos por *K. Pearson (1901)*.

- En concreto, los objetivos del análisis de componentes principales son:

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados
 - Encontrar agrupaciones

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados
 - Encontrar agrupaciones
 - Encontrar datos atípicos

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados
 - Encontrar agrupaciones
 - Encontrar datos atípicos
 - Como auxiliar para combatir la multicolinealidad en los modelos de regresión

- En concreto, los objetivos del análisis de componentes principales son:
 - Reducir la dimensión de los datos ($q \ll p$)
 - Generar nuevas variables: Componentes principales
- ¿Para qué?
 - Explorar, describir, analizar datos multivariados
 - Encontrar agrupaciones
 - Encontrar datos atípicos
 - Como auxiliar para combatir la multicolinealidad en los modelos de regresión
 - Reducir el número de variables a utilizar en la aplicación de alguna técnica de Aprendizaje Supervisado

- ¿Qué hace?

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible
 - Cada componente subsecuente explica la mayor cantidad de la variabilidad restante de los datos, que sea posible

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible
 - Cada componente subsecuente explica la mayor cantidad de la variabilidad restante de los datos, que sea posible
- Las componentes son de la forma:

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible
 - Cada componente subsecuente explica la mayor cantidad de la variabilidad restante de los datos, que sea posible
- Las componentes son de la forma:
-

$$Z_i = a_i'X = a_{i1}X_1 + a_{i2}X_2 + \cdots + a_{ip}X_p \quad i = 1, 2, \dots, p \quad \text{ó}$$

$$Z_i = a_i'(X - \mu) \text{ (centradas)}$$

- ¿Qué hace?
- Forma nuevas variables llamadas *Componentes Principales* (c.p.) con las siguientes características:
 - No están correlacionadas (bajo el supuesto de distribución normal, son independientes)
 - La primera c.p. explica la mayor cantidad de varianza de los datos, que sea posible
 - Cada componente subsecuente explica la mayor cantidad de la variabilidad restante de los datos, que sea posible
- Las componentes son de la forma:
-

$$Z_i = a_i'X = a_{i1}X_1 + a_{i2}X_2 + \cdots + a_{ip}X_p \quad i = 1, 2, \dots, p \quad \text{ó}$$

$$Z_i = a_i'(X - \mu) \text{ (centradas)}$$

- Es decir, son combinaciones lineales de las p variables.

- Para la primer componente, el objetivo es construir esta combinación lineal, de tal manera que la varianza de ella sea máxima. Por supuesto, suena a resolver un problema de maximización.

- Para la primer componente, el objetivo es construir esta combinación lineal, de tal manera que la varianza de ella sea máxima. Por supuesto, suena a resolver un problema de maximización.
- Entonces, el problema consiste en encontrar el vector a_1 , que haga máxima la varianza de esta primer componente. Para garantizar la unicidad de la solución, forzaremos el procedimiento a que a_1 sea de *norma uno* ($\|a_1\| = 1$).

- Para la primer componente, el objetivo es construir esta combinación lineal, de tal manera que la varianza de ella sea máxima. Por supuesto, suena a resolver un problema de maximización.
- Entonces, el problema consiste en encontrar el vector a_1 , que haga máxima la varianza de esta primer componente. Para garantizar la unicidad de la solución, forzaremos el procedimiento a que a_1 sea de *norma uno* ($\|a_1\| = 1$).
- En concreto, debe elegirse a_1 , un vector de norma uno, $\|a_1\| = a_1' a_1 = 1$, de tal manera que:

- Para la primer componente, el objetivo es construir esta combinación lineal, de tal manera que la varianza de ella sea máxima. Por supuesto, suena a resolver un problema de maximización.
- Entonces, el problema consiste en encontrar el vector a_1 , que haga máxima la varianza de esta primer componente. Para garantizar la unicidad de la solución, forzaremos el procedimiento a que a_1 sea de *norma uno* ($\|a_1\| = 1$).
- En concreto, debe elegirse a_1 , un vector de norma uno, $\|a_1\| = a_1' a_1 = 1$, de tal manera que:
-

$$\mathbb{V}(Z_1) = \mathbb{V}(a_1' \mathbf{X}) = a_1' \mathbb{V}(\mathbf{X}) a_1 = a_1' \Sigma a_1 \text{ sea máxima}$$

- Para la primer componente, el objetivo es construir esta combinación lineal, de tal manera que la varianza de ella sea máxima. Por supuesto, suena a resolver un problema de maximización.
- Entonces, el problema consiste en encontrar el vector a_1 , que haga máxima la varianza de esta primer componente. Para garantizar la unicidad de la solución, forzaremos el procedimiento a que a_1 sea de *norma uno* ($\|a_1\| = 1$).
- En concreto, debe elegirse a_1 , un vector de norma uno, $\|a_1\| = a_1' a_1 = 1$, de tal manera que:
-

$$\mathbb{V}(Z_1) = \mathbb{V}(a_1' \mathbf{X}) = a_1' \mathbb{V}(\mathbf{X}) a_1 = a_1' \Sigma a_1 \text{ sea máxima}$$

- Bajo esta restricción, el problema se transforma a encontrar un máximo con restricciones, para lo que utilizaremos la técnica de los *multiplicadores de Lagrange*

- **Deducción de la construcción de la primer componente**

- **Deducción de la construcción de la primer componente**
- El problema se plantea de la siguiente manera. Maximizar

- **Deducción de la construcción de la primer componente**
- El problema se plantea de la siguiente manera. Maximizar

$$F(a) = \mathbb{V}(Z) = \mathbb{V}(a' \mathbf{X}) = a' \mathbb{V}(\mathbf{X}) a = a' \Sigma a$$
$$\text{s.a } \lambda \|a\| = \lambda a' a = 1$$

- **Deducción de la construcción de la primer componente**
- El problema se plantea de la siguiente manera. Maximizar

$$F(a) = \mathbb{V}(Z) = \mathbb{V}(a' \mathbf{X}) = a' \mathbb{V}(\mathbf{X}) a = a' \Sigma a$$

$$\text{s.a } \lambda \|a\| = \lambda a' a = 1$$

- Que genera la función

- **Deducción de la construcción de la primer componente**
- El problema se plantea de la siguiente manera. Maximizar

$$F(a) = \mathbb{V}(Z) = \mathbb{V}(a' \mathbf{X}) = a' \mathbb{V}(\mathbf{X}) a = a' \Sigma a$$

$$\text{s.a } \lambda \|a\| = \lambda a' a = 1$$

- Que genera la función

$$F(a) = a' \Sigma a - (\lambda a' a - 1)$$

- **Deducción de la construcción de la primer componente**
- El problema se plantea de la siguiente manera. Maximizar

$$F(a) = \mathbb{V}(Z) = \mathbb{V}(a' \mathbf{X}) = a' \mathbb{V}(\mathbf{X}) a = a' \Sigma a$$

$$\text{s.a } \lambda \|a\| = \lambda a' a = 1$$

- Que genera la función

$$F(a) = a' \Sigma a - (\lambda a' a - 1)$$

- Derivando respecto al vector a , obtenemos

- **Deducción de la construcción de la primer componente**
- El problema se plantea de la siguiente manera. Maximizar

$$F(a) = \mathbb{V}(Z) = \mathbb{V}\left(a' \mathbf{X}\right) = a' \mathbb{V}(\mathbf{X}) a = a' \Sigma a$$

$$\text{s.a } \lambda \|a\| = \lambda a' a = 1$$

- Que genera la función

$$F(a) = a' \Sigma a - \left(\lambda a' a - 1 \right)$$

- Derivando respecto al vector a , obtenemos

$$\frac{\partial F(a)}{\partial a} = 2\Sigma a - 2\lambda a = 0$$

- **Deducción de la construcción de la primer componente**
- El problema se plantea de la siguiente manera. Maximizar

$$F(a) = \mathbb{V}(Z) = \mathbb{V}(a' \mathbf{X}) = a' \mathbb{V}(\mathbf{X}) a = a' \Sigma a$$

$$\text{s.a } \lambda \|a\| = \lambda a' a = 1$$

- Que genera la función

$$F(a) = a' \Sigma a - (\lambda a' a - 1)$$

- Derivando respecto al vector a , obtenemos

$$\frac{\partial F(a)}{\partial a} = 2\Sigma a - 2\lambda a = 0$$

- Cuya solución está dada por la igualdad

- **Deducción de la construcción de la primer componente**
- El problema se plantea de la siguiente manera. Maximizar

$$F(a) = \mathbb{V}(Z) = \mathbb{V}\left(a' \mathbf{X}\right) = a' \mathbb{V}(\mathbf{X}) a = a' \Sigma a$$

$$\text{s.a } \lambda \|a\| = \lambda a' a = 1$$

- Que genera la función

$$F(a) = a' \Sigma a - \left(\lambda a' a - 1 \right)$$

- Derivando respecto al vector a , obtenemos

$$\frac{\partial F(a)}{\partial a} = 2 \Sigma a - 2 \lambda a = 0$$

- Cuya solución está dada por la igualdad

$$\Sigma a = \lambda a$$

- Que, de acuerdo a sus conocimientos de álgebra lineal, implica que a es un eigenvector de la matriz Σ y λ el eigenvalor correspondiente a este eigenvector.

- Que, de acuerdo a sus conocimientos de álgebra lineal, implica que a es un eigenvector de la matriz Σ y λ el eigenvalor correspondiente a este eigenvector.
- Para determinar cuál valor propio de Σ es el que corresponde a la solución de la ecuación anterior, multipliquemos por la izquierda por a' , dicha ecuación

- Que, de acuerdo a sus conocimientos de álgebra lineal, implica que a es un eigenvector de la matriz Σ y λ el eigenvalor correspondiente a este eigenvector.
- Para determinar cuál valor propio de Σ es el que corresponde a la solución de la ecuación anterior, multipliquemos por la izquierda por a' , dicha ecuación

$$a' \Sigma a = \lambda a' a \Rightarrow a' \Sigma a = \lambda$$

- Que, de acuerdo a sus conocimientos de álgebra lineal, implica que a es un eigenvector de la matriz Σ y λ el eigenvalor correspondiente a este eigenvector.
- Para determinar cuál valor propio de Σ es el que corresponde a la solución de la ecuación anterior, multipliquemos por la izquierda por a' , dicha ecuación

$$a' \Sigma a = \lambda a' a \Rightarrow a' \Sigma a = \lambda$$

- Y observamos, entonces, que $\mathbb{V}(Z) = \lambda$, y como esta cantidad es la que deseamos maximizar, entonces λ es el eigenvalor más grande de la matriz Σ con a el eigenvector asociado a este eigenvalor, llamémoslos λ_1 y a_1 , respectivamente.

- Que, de acuerdo a sus conocimientos de álgebra lineal, implica que a es un eigenvector de la matriz Σ y λ el eigenvalor correspondiente a este eigenvector.
- Para determinar cuál valor propio de Σ es el que corresponde a la solución de la ecuación anterior, multipliquemos por la izquierda por a' , dicha ecuación

$$a' \Sigma a = \lambda a' a \Rightarrow a' \Sigma a = \lambda$$

- Y observamos, entonces, que $\mathbb{V}(Z) = \lambda$, y como esta cantidad es la que deseamos maximizar, entonces λ es el eigenvalor más grande de la matriz Σ con a el eigenvector asociado a este eigenvalor, llamémoslos λ_1 y a_1 , respectivamente.
- La siguiente componente debe cumplir con las condiciones de tener la mayor varianza del remanente, una vez calculada la primera, y no estar correlacionada con ésta.

- Obsérvese que esta última condición se obtiene si los correspondientes vectores, digamos a_1 y a_2 son ortogonales, y como pediremos que a_2 sea también de norma uno, entonces serán ortonormales.

- Obsérvese que esta última condición se obtiene si los correspondientes vectores, digamos a_1 y a_2 son ortogonales, y como pediremos que a_2 sea también de norma uno, entonces serán ortonormales.
- Una manera de garantizar que esta segunda componente es la de mayor varianza posible, después de la primera, es que la suma de estas dos varianzas sea máxima. Entonces el problema se puede plantear de la siguiente manera. Maximizar

$$F(a_1, a_2) = a_1' \Sigma a_1 + a_2' \Sigma a_2$$

s.a $\lambda_1 a_1' a_1 = 1$, $\lambda_2 a_2' a_2 = 1$ y $\mu a_1' a_2 = 0$

- Obsérvese que esta última condición se obtiene si los correspondientes vectores, digamos a_1 y a_2 son ortogonales, y como pediremos que a_2 sea también de norma uno, entonces serán ortonormales.
- Una manera de garantizar que esta segunda componente es la de mayor varianza posible, después de la primera, es que la suma de estas dos varianzas sea máxima. Entonces el problema se puede plantear de la siguiente manera. Maximizar

$$F(a_1, a_2) = a_1' \Sigma a_1 + a_2' \Sigma a_2$$

s.a $\lambda_1 a_1' a_1 = 1$, $\lambda_2 a_2' a_2 = 1$ y $\mu a_1' a_2 = 0$

- Derivando esta función respecto a los vectores a_1 y a_2 , tenemos



$$\frac{\partial F(a_1, a_2)}{\partial a_1} = 2\Sigma a_1 - 2\lambda_1 a_1 + \mu a_2 = 0$$

$$\frac{\partial F(a_1, a_2)}{\partial a_2} = 2\Sigma a_2 - 2\lambda_2 a_2 + \mu a_1 = 0$$



$$\frac{\partial F(a_1, a_2)}{\partial a_1} = 2\Sigma a_1 - 2\lambda_1 a_1 + \mu a_2 = 0$$

$$\frac{\partial F(a_1, a_2)}{\partial a_2} = 2\Sigma a_2 - 2\lambda_2 a_2 + \mu a_1 = 0$$

- Multiplicando la parcial respecto a a_1 por a_1' por la izquierda y recordando que $a_1' a_2 = 0$, porque son ortonormales, tenemos



$$\frac{\partial F(a_1, a_2)}{\partial a_1} = 2\Sigma a_1 - 2\lambda_1 a_1 + \mu a_2 = 0$$

$$\frac{\partial F(a_1, a_2)}{\partial a_2} = 2\Sigma a_2 - 2\lambda_2 a_2 + \mu a_1 = 0$$

- Multiplicando la parcial respecto a a_1 por a_1' por la izquierda y recordando que $a_1' a_2 = 0$, porque son ortonormales, tenemos

$$a_1' \Sigma a_1 = \lambda_1 \Rightarrow a_1 a_1' \Sigma a_1 = \lambda_1 a_1 \Rightarrow \Sigma a_1 = \lambda_1 a_1$$



$$\frac{\partial F(a_1, a_2)}{\partial a_1} = 2\Sigma a_1 - 2\lambda_1 a_1 + \mu a_2 = 0$$

$$\frac{\partial F(a_1, a_2)}{\partial a_2} = 2\Sigma a_2 - 2\lambda_2 a_2 + \mu a_1 = 0$$

- Multiplicando la parcial respecto a a_1 por a_1' por la izquierda y recordando que $a_1' a_2 = 0$, porque son ortonormales, tenemos

$$a_1' \Sigma a_1 = \lambda_1 \Rightarrow a_1 a_1' \Sigma a_1 = \lambda_1 a_1 \Rightarrow \Sigma a_1 = \lambda_1 a_1$$

- De manera similar, multiplicando la parcial respecto a a_2 por a_2' por la izquierda y recordando que $a_2' a_1 = 0$, porque son ortonormales, tenemos



$$\frac{\partial F(a_1, a_2)}{\partial a_1} = 2\Sigma a_1 - 2\lambda_1 a_1 + \mu a_2 = 0$$

$$\frac{\partial F(a_1, a_2)}{\partial a_2} = 2\Sigma a_2 - 2\lambda_2 a_2 + \mu a_1 = 0$$

- Multiplicando la parcial respecto a a_1 por a_1' por la izquierda y recordando que $a_1' a_2 = 0$, porque son ortonormales, tenemos

$$a_1' \Sigma a_1 = \lambda_1 \Rightarrow a_1 a_1' \Sigma a_1 = \lambda_1 a_1 \Rightarrow \Sigma a_1 = \lambda_1 a_1$$

- De manera similar, multiplicando la parcial respecto a a_2 por a_2' por la izquierda y recordando que $a_2' a_1 = 0$, porque son ortonormales, tenemos

$$a_2' \Sigma a_2 = \lambda_2 \Rightarrow a_2 a_2' \Sigma a_2 = \lambda_2 a_2 \Rightarrow \Sigma a_2 = \lambda_2 a_2$$



$$\frac{\partial F(a_1, a_2)}{\partial a_1} = 2\Sigma a_1 - 2\lambda_1 a_1 + \mu a_2 = 0$$

$$\frac{\partial F(a_1, a_2)}{\partial a_2} = 2\Sigma a_2 - 2\lambda_2 a_2 + \mu a_1 = 0$$

- Multiplicando la parcial respecto a a_1 por a_1' por la izquierda y recordando que $a_1' a_2 = 0$, porque son ortonormales, tenemos

$$a_1' \Sigma a_1 = \lambda_1 \Rightarrow a_1 a_1' \Sigma a_1 = \lambda_1 a_1 \Rightarrow \Sigma a_1 = \lambda_1 a_1$$

- De manera similar, multiplicando la parcial respecto a a_2 por a_2' por la izquierda y recordando que $a_2' a_1 = 0$, porque son ortonormales, tenemos

$$a_2' \Sigma a_2 = \lambda_2 \Rightarrow a_2 a_2' \Sigma a_2 = \lambda_2 a_2 \Rightarrow \Sigma a_2 = \lambda_2 a_2$$

- Que implica que a_1 y a_2 deben ser eigenvectores de Σ .

- Tomando estos vectores propios de norma uno y sustituyendo en la función objetivo, obtenemos

- Tomando estos vectores propios de norma uno y sustituyendo en la función objetivo, obtenemos

$$\lambda_1 a_1' a_1 + \lambda_2 a_2' a_2 - \lambda_1 (a_1' a_1 - 1) - \lambda_2 (a_2' a_2 - 1) - \mu a_1' a_2 = \lambda_1 + \lambda_2$$

- Por lo que es claro que λ_1 y λ_2 deben ser los dos eigenvalores más grandes de la matriz Σ y a_1 y a_2 sus correspondientes eigenvectores

- Tomando estos vectores propios de norma uno y sustituyendo en la función objetivo, obtenemos

$$\lambda_1 a_1' a_1 + \lambda_2 a_2' a_2 - \lambda_1 (a_1' a_1 - 1) - \lambda_2 (a_2' a_2 - 1) - \mu a_1' a_2 = \lambda_1 + \lambda_2$$

- Por lo que es claro que λ_1 y λ_2 deben ser los dos eigenvalores más grandes de la matriz Σ y a_1 y a_2 sus correspondientes eigenvectores
- De manera general, la j -ésima componente principal será

- Tomando estos vectores propios de norma uno y sustituyendo en la función objetivo, obtenemos

$$\lambda_1 a_1' a_1 + \lambda_2 a_2' a_2 - \lambda_1 (a_1' a_1 - 1) - \lambda_2 (a_2' a_2 - 1) - \mu a_1' a_2 = \lambda_1 + \lambda_2$$

- Por lo que es claro que λ_1 y λ_2 deben ser los dos eigenvalores más grandes de la matriz Σ y a_1 y a_2 sus correspondientes eigenvectores
- De manera general, la j -ésima componente principal será

$$Z_j = a_j' \mathbf{X} \quad j = 1, 2, \dots, p$$

- Con a_j el eigenvector de la matriz Σ asociado al eigenvalor λ_j . Y $\lambda_1 > \lambda_2 > \dots > \lambda_p$

- **Propiedades de las componentes principales**

- **Propiedades de las componentes principales**
- Las componentes principales como variables derivadas de las originales, tienen las siguientes propiedades:

- **Propiedades de las componentes principales**
- Las componentes principales como variables derivadas de las originales, tienen las siguientes propiedades:
 - *Conservan la variabilidad original de los datos:* En el sentido de que la suma de las varianzas de los componentes es igual a la suma de las varianzas de las variables originales.

- **Propiedades de las componentes principales**
- Las componentes principales como variables derivadas de las originales, tienen las siguientes propiedades:
 - *Conservan la variabilidad original de los datos:* En el sentido de que la suma de las varianzas de los componentes es igual a la suma de las varianzas de las variables originales.
 - Por construcción tenemos que

- **Propiedades de las componentes principales**
- Las componentes principales como variables derivadas de las originales, tienen las siguientes propiedades:
 - *Conservan la variabilidad original de los datos:* En el sentido de que la suma de las varianzas de los componentes es igual a la suma de las varianzas de las variables originales.
 - Por construcción tenemos que

$$\mathbb{V}(Z_1) = \lambda_1, \mathbb{V}(Z_2) = \lambda_2, \text{ etc.}$$

- **Propiedades de las componentes principales**
- Las componentes principales como variables derivadas de las originales, tienen las siguientes propiedades:
 - *Conservan la variabilidad original de los datos:* En el sentido de que la suma de las varianzas de los componentes es igual a la suma de las varianzas de las variables originales.
 - Por construcción tenemos que

$$\mathbb{V}(Z_1) = \lambda_1, \mathbb{V}(Z_2) = \lambda_2, \text{ etc.}$$

- y además se tiene también que $\mathbb{Cov}(Z_1, Z_2) = 0$. En general $\mathbb{Cov}(Z_i, Z_j) = 0$ para toda $i \neq j$ $i, j = 1, 2, \dots, p$. Entonces

- **Propiedades de las componentes principales**

- Las componentes principales como variables derivadas de las originales, tienen las siguientes propiedades:
 - *Conservan la variabilidad original de los datos:* En el sentido de que la suma de las varianzas de los componentes es igual a la suma de las varianzas de las variables originales.
 - Por construcción tenemos que

$$\mathbb{V}(Z_1) = \lambda_1, \mathbb{V}(Z_2) = \lambda_2, \text{ etc.}$$

- y además se tiene también que $\mathbb{C}ov(Z_1, Z_2) = 0$. En general $\mathbb{C}ov(Z_i, Z_j) = 0$ para toda $i \neq j$, $i, j = 1, 2, \dots, p$. Entonces

$$\text{traza}(\mathbf{\Sigma}) = \sum_{i=1}^p \mathbb{V}(X_i) = \sum_{i=1}^p \lambda_i = \sum_{i=1}^p \mathbb{V}(Z_i)$$

- **Propiedades de las componentes principales**

- Las componentes principales como variables derivadas de las originales, tienen las siguientes propiedades:
 - *Conservan la variabilidad original de los datos:* En el sentido de que la suma de las varianzas de los componentes es igual a la suma de las varianzas de las variables originales.
 - Por construcción tenemos que

$$\mathbb{V}(Z_1) = \lambda_1, \mathbb{V}(Z_2) = \lambda_2, \text{ etc.}$$

- y además se tiene también que $\text{Cov}(Z_1, Z_2) = 0$. En general $\text{Cov}(Z_i, Z_j) = 0$ para toda $i \neq j$, $i, j = 1, 2, \dots, p$. Entonces

$$\text{traza}(\Sigma) = \sum_{i=1}^p \mathbb{V}(X_i) = \sum_{i=1}^p \lambda_i = \sum_{i=1}^p \mathbb{V}(Z_i)$$

- Las nuevas variables Z_i tienen conjuntamente la misma variabilidad que las variables originales, la suma de varianzas es la misma, pero su estructura o constitución es muy diferente.

- Continúa Propiedades de las componentes...

- **Continúa Propiedades de las componentes...**

- La proporción de la varianza total explicada por una componente, es el cociente entre su varianza (el valor propio asociado al vector propio que la define), y la suma de los valores propios de la matriz. Por esta razón se dice que el i -ésimo componente principal explica una proporción de varianza igual a:

- **Continúa Propiedades de las componentes...**

- La proporción de la varianza total explicada por una componente, es el cociente entre su varianza (el valor propio asociado al vector propio que la define), y la suma de los valores propios de la matriz. Por esta razón se dice que el i -ésimo componente principal explica una proporción de varianza igual a:

$$\frac{\lambda_i}{\sum_{i=1}^p \lambda_i}$$

- **Continúa Propiedades de las componentes...**

- La proporción de la varianza total explicada por una componente, es el cociente entre su varianza (el valor propio asociado al vector propio que la define), y la suma de los valores propios de la matriz. Por esta razón se dice que el i -ésimo componente principal explica una proporción de varianza igual a:

$$\frac{\lambda_i}{\sum_{i=1}^p \lambda_i}$$

- Y los primeros k de ellos

- **Continúa Propiedades de las componentes...**

- La proporción de la varianza total explicada por una componente, es el cociente entre su varianza (el valor propio asociado al vector propio que la define), y la suma de los valores propios de la matriz. Por esta razón se dice que el i -ésimo componente principal explica una proporción de varianza igual a:

$$\frac{\lambda_i}{\sum_{i=1}^p \lambda_i}$$

- Y los primeros k de ellos

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i} \quad k \leq p$$

● Continúa Propiedades de las componentes...

- La proporción de la varianza total explicada por una componente, es el cociente entre su varianza (el valor propio asociado al vector propio que la define), y la suma de los valores propios de la matriz. Por esta razón se dice que el i -ésimo componente principal explica una proporción de varianza igual a:

$$\frac{\lambda_i}{\sum_{i=1}^p \lambda_i}$$

- Y los primeros k de ellos

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i} \quad k \leq p$$

- Las covarianza entre el vector de variables originales $\mathbf{X}$ y la i -ésima componente principal Z_i , $i = 1, 2, \dots, p$, es:

$$\text{Cov}(\mathbf{X}, Z_i) = \text{Cov}(\mathbf{x}, a_i' \mathbf{x}) = a_i' \text{Cov}(\mathbf{x}, \mathbf{x}) = a_i' \Sigma = a_i' \lambda_i = \Sigma a_i = \lambda_i a_i$$

- Es decir

- Es decir

$$\mathbb{C}ov(X, Z_i) = \mathbb{C}ov(X_1, X_2, \dots, X_p, Z_i) = \lambda_i a_i = \lambda_i (a_{i1}, a_{i2}, \dots, a_{ip})$$

- Es decir

$$\mathbb{C}ov(X, Z_i) = \mathbb{C}ov(X_1, X_2, \dots, X_p, Z_i) = \lambda_i a_i = \lambda_i (a_{i1}, a_{i2}, \dots, a_{ip})$$

- Entonces, la covarianza entre la i -ésima componente y la j -ésima variable es:

- Es decir

$$\mathbb{C}ov(X, Z_i) = \mathbb{C}ov(X_1, X_2, \dots, X_p, Z_i) = \lambda_i a_i = \lambda_i (a_{i1}, a_{i2}, \dots, a_{ip})$$

- Entonces, la covarianza entre la i -ésima componente y la j -ésima variable es:

$$\mathbb{C}ov(X_j, Z_i) = \lambda_i a_{ij}$$

- Es decir

$$\mathbb{C}ov(X, Z_i) = \mathbb{C}ov(X_1, X_2, \dots, X_p, Z_i) = \lambda_i a_i = \lambda_i (a_{i1}, a_{i2}, \dots, a_{ip})$$

- Entonces, la covarianza entre la i -ésima componente y la j -ésima variable es:

$$\mathbb{C}ov(X_j, Z_i) = \lambda_i a_{ij}$$

- Como $\mathbb{V}(X_j) = \sigma_{jj}^2$ y $\mathbb{V}(Z_i) = \lambda_i$, entonces tenemos que:

- Es decir

$$\mathbb{C}ov(X, Z_i) = \mathbb{C}ov(X_1, X_2, \dots, X_p, Z_i) = \lambda_i a_i = \lambda_i (a_{i1}, a_{i2}, \dots, a_{ip})$$

- Entonces, la covarianza entre la i -ésima componente y la j -ésima variable es:

$$\mathbb{C}ov(X_j, Z_i) = \lambda_i a_{ij}$$

- Como $\mathbb{V}(X_j) = \sigma_{jj}^2$ y $\mathbb{V}(Z_i) = \lambda_i$, entonces tenemos que:

$$\mathbb{C}or(X_j, Z_i) = \frac{\mathbb{C}ov(X_j, Z_i)}{\sqrt{\mathbb{V}(X_j) \mathbb{V}(Z_i)}} = \frac{\lambda_i a_{ij}}{\sqrt{\sigma_{jj}^2 \lambda_i}} = \frac{\sqrt{\lambda_i} a_{ij}}{\sigma_{jj}}$$

- Es decir

$$\mathbb{C}ov(X, Z_i) = \mathbb{C}ov(X_1, X_2, \dots, X_p, Z_i) = \lambda_i a_i = \lambda_i (a_{i1}, a_{i2}, \dots, a_{ip})$$

- Entonces, la covarianza entre la i -ésima componente y la j -ésima variable es:

$$\mathbb{C}ov(X_j, Z_i) = \lambda_i a_{ij}$$

- Como $\mathbb{V}(X_j) = \sigma_{jj}^2$ y $\mathbb{V}(Z_i) = \lambda_i$, entonces tenemos que:

$$\mathbb{C}or(X_j, Z_i) = \frac{\mathbb{C}ov(X_j, Z_i)}{\sqrt{\mathbb{V}(X_j) \mathbb{V}(Z_i)}} = \frac{\lambda_i a_{ij}}{\sqrt{\sigma_{jj}^2 \lambda_i}} = \frac{\sqrt{\lambda_i} a_{ij}}{\sigma_{jj}}$$

- El peso que tiene la variable j en la componente i , está dado por a_{ij} . El tamaño relativo de las a_{ij} 's reflejan la contribución relativa de cada variable en la componente. Para interpretar, en el contexto de los datos, una componente, debemos analizar el patrón de las a_{ij} de cada componente.

- Si utilizamos la matriz de correlación para realizar el análisis de c.p., como $\sigma_{jj}^2 = 1$, entonces

- Si utilizamos la matriz de correlación para realizar el análisis de c.p., como $\sigma_{jj}^2 = 1$, entonces

$$a_{ij}^* = \sqrt{\lambda_j} a_{ij}$$

- Si utilizamos la matriz de correlación para realizar el análisis de c.p., como $\sigma_{jj}^2 = 1$, entonces

$$a_{ij}^* = \sqrt{\lambda_j} a_{ij}$$

- Se interpreta como el coeficiente de correlación entre la variable j y el componente i . Esta es una de las interpretaciones particularmente más usuales.

- **Análisis de la matriz de componentes principales**

- **Análisis de la matriz de componentes principales**
- Denotemos por $\mathbf{Z}$ a la matriz de componentes principales, entonces

- **Análisis de la matriz de componentes principales**
- Denotemos por **Z** a la matriz de componentes principales, entonces

$$\mathbf{Z} = \mathbf{XA}$$

- **Análisis de la matriz de componentes principales**
- Denotemos por **Z** a la matriz de componentes principales, entonces

$$\mathbf{Z} = \mathbf{XA}$$

- Con

$$\mathbf{A} = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p) = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{p1} \\ a_{12} & a_{22} & \cdots & a_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1p} & a_{2p} & \cdots & a_{pp} \end{pmatrix}$$

- **Análisis de la matriz de componentes principales**
- Denotemos por **Z** a la matriz de componentes principales, entonces

$$\mathbf{Z} = \mathbf{XA}$$

- Con

$$\mathbf{A} = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p) = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{p1} \\ a_{12} & a_{22} & \cdots & a_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1p} & a_{2p} & \cdots & a_{pp} \end{pmatrix}$$

- Propiedades de **A**.

- **Análisis de la matriz de componentes principales**
- Denotemos por **Z** a la matriz de componentes principales, entonces

$$\mathbf{Z} = \mathbf{XA}$$

- Con

$$\mathbf{A} = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p) = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{p1} \\ a_{12} & a_{22} & \cdots & a_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1p} & a_{2p} & \cdots & a_{pp} \end{pmatrix}$$

- Propiedades de **A**.
 - En la matriz **A**, cada columna es un vector propio de Σ

- **Análisis de la matriz de componentes principales**
- Denotemos por **Z** a la matriz de componentes principales, entonces

$$\mathbf{Z} = \mathbf{XA}$$

- Con

$$\mathbf{A} = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p) = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{p1} \\ a_{12} & a_{22} & \cdots & a_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1p} & a_{2p} & \cdots & a_{pp} \end{pmatrix}$$

- Propiedades de **A**.
 - En la matriz **A**, cada columna es un vector propio de Σ
 - $\mathbf{A}'\mathbf{A} = \mathbf{AA}' = \mathbf{I}_p \Rightarrow \mathbf{A}' = \mathbf{A}^{-1} \Rightarrow \mathbf{A}$ es ortogonal

- **Análisis de la matriz de componentes principales**
- Denotemos por **Z** a la matriz de componentes principales, entonces

$$\mathbf{Z} = \mathbf{XA}$$

- Con

$$\mathbf{A} = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p) = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{p1} \\ a_{12} & a_{22} & \cdots & a_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1p} & a_{2p} & \cdots & a_{pp} \end{pmatrix}$$

- Propiedades de **A**.
 - En la matriz **A**, cada columna es un vector propio de Σ
 - $\mathbf{A}'\mathbf{A} = \mathbf{A}\mathbf{A}' = \mathbf{I}_p \Rightarrow \mathbf{A}' = \mathbf{A}^{-1} \Rightarrow \mathbf{A}$ es ortogonal
 - $\Sigma\mathbf{A} = \mathbf{A}\Lambda$ con $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$, $\lambda_1 > \lambda_2 > \cdots > \lambda_p$
(resultado análogo a $\Sigma\mathbf{a}_i = \lambda_i\mathbf{a}_i$)

- Estructura de correlación

- Estructura de correlación



$$\begin{aligned}\mathbb{V}(\mathbf{Z}) &= \mathbb{V}(\mathbf{XA}) = \mathbf{A}' \mathbb{V}(X) \mathbf{A} = \mathbf{A}' \Sigma \mathbf{A} \\ &= \mathbf{A}' \mathbf{A} \Lambda = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p). \text{ Entonces} \\ \text{Cov}(\mathbf{Z}_i, \mathbf{Z}_j) &= 0, \text{ si } i \neq j \text{ y} \\ \mathbb{V}(\mathbf{Z}_i) = \lambda_i &\geq \text{Var}(\mathbf{Z}_j) = \lambda_j \text{ si } i \leq j\end{aligned}$$

- Estructura de correlación



$$\begin{aligned}\mathbb{V}(\mathbf{Z}) &= \mathbb{V}(\mathbf{XA}) = \mathbf{A}' \mathbb{V}(X) \mathbf{A} = \mathbf{A}' \Sigma \mathbf{A} \\ &= \mathbf{A}' \mathbf{A} \Lambda = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p). \text{ Entonces} \\ \text{Cov}(\mathbf{Z}_i, \mathbf{Z}_j) &= 0, \text{ si } i \neq j \text{ y} \\ \mathbb{V}(\mathbf{Z}_i) &= \lambda_i \geq \text{Var}(\mathbf{Z}_j) = \lambda_j \text{ si } i \leq j\end{aligned}$$

- Además

$$\begin{aligned}\text{traza}(\Sigma) &= \text{traza}(\Sigma \mathbf{A} \mathbf{A}') = \text{traza}(\mathbf{A} \Lambda \mathbf{A}') \\ &= \text{traza}(\mathbf{A}' \mathbf{A} \Lambda) = \text{traza}(\Lambda) = \sum_{j=1}^p \lambda_j\end{aligned}$$

- Estructura de correlación



$$\begin{aligned}\mathbb{V}(\mathbf{Z}) &= \mathbb{V}(\mathbf{XA}) = \mathbf{A}' \mathbb{V}(X) \mathbf{A} = \mathbf{A}' \Sigma \mathbf{A} \\ &= \mathbf{A}' \mathbf{A} \Lambda = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p). \text{ Entonces} \\ \text{Cov}(\mathbf{Z}_i, \mathbf{Z}_j) &= 0, \text{ si } i \neq j \text{ y} \\ \mathbb{V}(\mathbf{Z}_i) = \lambda_i &\geq \text{Var}(\mathbf{Z}_j) = \lambda_j \text{ si } i \leq j\end{aligned}$$

- Además

$$\begin{aligned}\text{traza}(\Sigma) &= \text{traza}(\Sigma \mathbf{A} \mathbf{A}') = \text{traza}(\mathbf{A} \Lambda \mathbf{A}') \\ &= \text{traza}(\mathbf{A}' \mathbf{A} \Lambda) = \text{traza}(\Lambda) = \sum_{j=1}^p \lambda_j\end{aligned}$$

- Estructura de correlación



$$\begin{aligned}\mathbb{V}(\mathbf{Z}) &= \mathbb{V}(\mathbf{XA}) = \mathbf{A}' \mathbb{V}(X) \mathbf{A} = \mathbf{A}' \Sigma \mathbf{A} \\ &= \mathbf{A}' \mathbf{A} \Lambda = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p). \text{ Entonces} \\ \text{Cov}(\mathbf{Z}_i, \mathbf{Z}_j) &= 0, \text{ si } i \neq j \text{ y} \\ \mathbb{V}(\mathbf{Z}_i) = \lambda_i &\geq \text{Var}(\mathbf{Z}_j) = \lambda_j \text{ si } i \leq j\end{aligned}$$

- Además

$$\begin{aligned}\text{traza}(\Sigma) &= \text{traza}(\Sigma \mathbf{A} \mathbf{A}') = \text{traza}(\mathbf{A} \Lambda \mathbf{A}') \\ &= \text{traza}(\mathbf{A}' \mathbf{A} \Lambda) = \text{traza}(\Lambda) = \sum_{j=1}^p \lambda_j\end{aligned}$$

- Ya que $\text{traza}(\Sigma) = \sum_{j=1}^p \sigma_{jj}^2$. Entonces $\sum_{j=1}^p \lambda_j$ es una medida de la variación total de los datos (variación total de $\mathbf{X}$)

- Componentes muestrales

- **Componentes muestrales**
- Como sabemos, Σ es desconocida, pero podemos estimarla con **S** la matriz de varianza-covarianza muestral, que es un estimador con muy buenas propiedades estadísticas.

- **Componentes muestrales**

- Como sabemos, Σ es desconocida, pero podemos estimarla con **S** la matriz de varianza-covarianza muestral, que es un estimador con muy buenas propiedades estadísticas.
- Entonces, con datos reales, el análisis de componentes principales se realiza con esta matriz y se obtienen los estimadores

- **Componentes muestrales**

- Como sabemos, Σ es desconocida, pero podemos estimarla con **S** la matriz de varianza-covarianza muestral, que es un estimador con muy buenas propiedades estadísticas.
- Entonces, con datos reales, el análisis de componentes principales se realiza con esta matriz y se obtienen los estimadores

$$\hat{\lambda}_i \quad y \quad \hat{a}_i$$

- **Componentes muestrales**

- Como sabemos, Σ es desconocida, pero podemos estimarla con **S** la matriz de varianza-covarianza muestral, que es un estimador con muy buenas propiedades estadísticas.
- Entonces, con datos reales, el análisis de componentes principales se realiza con esta matriz y se obtienen los estimadores

$$\hat{\lambda}_i \quad y \quad \hat{a}_i$$

- **¿Matriz de varianza-covarianza o de correlación?**

- **Componentes muestrales**

- Como sabemos, Σ es desconocida, pero podemos estimarla con **S** la matriz de varianza-covarianza muestral, que es un estimador con muy buenas propiedades estadísticas.
- Entonces, con datos reales, el análisis de componentes principales se realiza con esta matriz y se obtienen los estimadores

$$\hat{\lambda}_i \quad y \quad \hat{a}_i$$

- **¿Matriz de varianza-covarianza o de correlación?**
- ¿Cuándo una, cuándo otra?

- **Componentes muestrales**

- Como sabemos, Σ es desconocida, pero podemos estimarla con **S** la matriz de varianza-covarianza muestral, que es un estimador con muy buenas propiedades estadísticas.
- Entonces, con datos reales, el análisis de componentes principales se realiza con esta matriz y se obtienen los estimadores

$$\hat{\lambda}_i \quad y \quad \hat{a}_i$$

- **¿Matriz de varianza-covarianza o de correlación?**
- ¿Cuándo una, cuándo otra?
- **Varianza-covarianza**

- **Componentes muestrales**

- Como sabemos, Σ es desconocida, pero podemos estimarla con **S** la matriz de varianza-covarianza muestral, que es un estimador con muy buenas propiedades estadísticas.
- Entonces, con datos reales, el análisis de componentes principales se realiza con esta matriz y se obtienen los estimadores

$$\hat{\lambda}_i \quad y \quad \hat{a}_i$$

- **¿Matriz de varianza-covarianza o de correlación?**

- ¿Cuándo una, cuándo otra?

- **Varianza-covarianza**

- Variables medidas en las mismas unidades o, por lo menos, en unidades comparables

- **Componentes muestrales**

- Como sabemos, Σ es desconocida, pero podemos estimarla con **S** la matriz de varianza-covarianza muestral, que es un estimador con muy buenas propiedades estadísticas.
- Entonces, con datos reales, el análisis de componentes principales se realiza con esta matriz y se obtienen los estimadores

$$\hat{\lambda}_i \quad y \quad \hat{a}_i$$

- **¿Matriz de varianza-covarianza o de correlación?**

- ¿Cuándo una, cuándo otra?

- **Varianza-covarianza**

- Variables medidas en las mismas unidades o, por lo menos, en unidades comparables
- Varianzas de tamaño semejante

- Si las variables no están medidas en las mismas unidades, entonces cualquier cambio en la escala de medición en una o más variables tendrá un efecto sobre las *c.p.*

- Si las variables no están medidas en las mismas unidades, entonces cualquier cambio en la escala de medición en una o más variables tendrá un efecto sobre las *c.p.*
- Por ejemplo, supongamos que una variable que se midió originalmente en pies, se cambió a pulgadas. Esto significa que la varianza de la variable se incrementará en $12^2 = 144$. Ya que *c.p.* se basa en la varianza, esta variable tendría una mayor influencia sobre los *c.p.* cuando se mide en pulgadas que en pies.

- Si las variables no están medidas en las mismas unidades, entonces cualquier cambio en la escala de medición en una o más variables tendrá un efecto sobre las *c.p.*
- Por ejemplo, supongamos que una variable que se midió originalmente en pies, se cambió a pulgadas. Esto significa que la varianza de la variable se incrementará en $12^2 = 144$. Ya que *c.p.* se basa en la varianza, esta variable tendría una mayor influencia sobre los *c.p.* cuando se mide en pulgadas que en pies.
- Si una variable tiene una varianza mucho mayor que las demás, dominará el primer componente principal, sin importar la estructura de covarianza de las variables.

- Si las variables no están medidas en las mismas unidades, entonces cualquier cambio en la escala de medición en una o más variables tendrá un efecto sobre las *c.p.*
- Por ejemplo, supongamos que una variable que se midió originalmente en pies, se cambió a pulgadas. Esto significa que la varianza de la variable se incrementará en $12^2 = 144$. Ya que *c.p.* se basa en la varianza, esta variable tendría una mayor influencia sobre los *c.p.* cuando se mide en pulgadas que en pies.
- Si una variable tiene una varianza mucho mayor que las demás, dominará el primer componente principal, sin importar la estructura de covarianza de las variables.
- Si no se tienen las condiciones para realizar un análisis de *c.p.* con la matriz de varianza-covarianza, se recomienda hacerlo con la matriz de correlación.

- Aplicar análisis de *c.p.* a la matriz de correlación, es equivalente a aplicarlo a datos estandarizados (“puntajes *z*”), en lugar de los datos crudos.

- Aplicar análisis de *c.p.* a la matriz de correlación, es equivalente a aplicarlo a datos estandarizados (“puntajes *z*”), en lugar de los datos crudos.
- Realizar el análisis de *c.p.* con la matriz de correlación, implica intrínsecamente asumir que todas las variables tienen igual importancia dentro del análisis, supuesto que no siempre puede ser cierto.

- Aplicar análisis de *c.p.* a la matriz de correlación, es equivalente a aplicarlo a datos estandarizados (“puntajes *z*”), en lugar de los datos crudos.
- Realizar el análisis de *c.p.* con la matriz de correlación, implica intrínsecamente asumir que todas las variables tienen igual importancia dentro del análisis, supuesto que no siempre puede ser cierto.
- Pueden presentarse situaciones en donde las variables no estén en unidades comparables y en las que el investigador considere que tienen una importancia distinta. Algunos paquetes estadísticos permiten asignar pesos a las variables.

- Aplicar análisis de *c.p.* a la matriz de correlación, es equivalente a aplicarlo a datos estandarizados (“puntajes *z*”), en lugar de los datos crudos.
- Realizar el análisis de *c.p.* con la matriz de correlación, implica intrínsecamente asumir que todas las variables tienen igual importancia dentro del análisis, supuesto que no siempre puede ser cierto.
- Pueden presentarse situaciones en donde las variables no estén en unidades comparables y en las que el investigador considere que tienen una importancia distinta. Algunos paquetes estadísticos permiten asignar pesos a las variables.
- Entonces se procedería a estandarizar las variables y posteriormente asignar pesos mayores a aquéllas que el investigador considere más importantes.

- **Análisis de c.p. con la matriz de correlación**

- **Análisis de c.p. con la matriz de correlación**
- Estandarizar los datos, hacer análisis de c.p. utilizando la matriz de correlación en lugar de la de varianza-covarianza.

- **Análisis de c.p. con la matriz de correlación**
- Estandarizar los datos, hacer análisis de c.p. utilizando la matriz de correlación en lugar de la de varianza-covarianza.
- **Importante:** El análisis de c.p. transforma un conjunto de variables correlacionadas en un nuevo conjunto de variables no correlacionadas. Si las variables originales no están correlacionadas o están muy poco correlacionadas esta técnica no tiene ninguna utilidad y la dimensión real de los datos es la misma que el número de variables medidas.

- **Análisis de c.p. con la matriz de correlación**
- Estandarizar los datos, hacer análisis de c.p. utilizando la matriz de correlación en lugar de la de varianza-covarianza.
- **Importante:** El análisis de c.p. transforma un conjunto de variables correlacionadas en un nuevo conjunto de variables no correlacionadas. Si las variables originales no están correlacionadas o están muy poco correlacionadas esta técnica no tiene ninguna utilidad y la dimensión real de los datos es la misma que el número de variables medidas.
- **¿Cómo decidir cuántas componentes es apropiado considerar?**

- **Análisis de c.p. con la matriz de correlación**
- Estandarizar los datos, hacer análisis de c.p. utilizando la matriz de correlación en lugar de la de varianza-covarianza.
- **Importante:** El análisis de c.p. transforma un conjunto de variables correlacionadas en un nuevo conjunto de variables no correlacionadas. Si las variables originales no están correlacionadas o están muy poco correlacionadas esta técnica no tiene ninguna utilidad y la dimensión real de los datos es la misma que el número de variables medidas.
- **¿Cómo decidir cuántas componentes es apropiado considerar?**
 - Porcentaje de varianza explicada requerido (Matriz de varianza-covarianza)

- **Análisis de c.p. con la matriz de correlación**
- Estandarizar los datos, hacer análisis de c.p. utilizando la matriz de correlación en lugar de la de varianza-covarianza.
- **Importante:** El análisis de c.p. transforma un conjunto de variables correlacionadas en un nuevo conjunto de variables no correlacionadas. Si las variables originales no están correlacionadas o están muy poco correlacionadas esta técnica no tiene ninguna utilidad y la dimensión real de los datos es la misma que el número de variables medidas.
- **¿Cómo decidir cuántas componentes es apropiado considerar?**
 - Porcentaje de varianza explicada requerido (Matriz de varianza-covarianza)
 - Porcentaje requerido $\gamma * 100\%$ de la variabilidad total

- **Análisis de c.p. con la matriz de correlación**
- Estandarizar los datos, hacer análisis de c.p. utilizando la matriz de correlación en lugar de la de varianza-covarianza.
- **Importante:** El análisis de c.p. transforma un conjunto de variables correlacionadas en un nuevo conjunto de variables no correlacionadas. Si las variables originales no están correlacionadas o están muy poco correlacionadas esta técnica no tiene ninguna utilidad y la dimensión real de los datos es la misma que el número de variables medidas.
- **¿Cómo decidir cuántas componentes es apropiado considerar?**
 - Porcentaje de varianza explicada requerido (Matriz de varianza-covarianza)
 - Porcentaje requerido $\gamma * 100\%$ de la variabilidad total
- Encontrar el número de componentes que cubra este requerimiento. Este criterio depende de la población bajo estudio y del investigador.

- **Matriz de correlación**

- **Matriz de correlación**

- Los criterios mostrados para la matriz de varianza-covarianza.

- **Matriz de correlación**

- Los criterios mostrados para la matriz de varianza-covarianza.
- Uno más. Considerar el número de componentes cuyo eigenvalor sea mayor que uno.

- **Matriz de correlación**


- Los criterios mostrados para la matriz de varianza-covarianza.
- Uno más. Considerar el número de componentes cuyo eigenvalor sea mayor que uno.


- **Gráfica de codo (SCREE)**. Cuando los puntos en la gráfica tienden a nivelarse (horizontalmente), los eigenvalores están lo suficientemente cercanos a cero y pueden ignorarse. Entonces, elegir el número de componentes igual al número de eigenvalores antes de que la gráfica se nivele.


- **Matriz de correlación**

- Los criterios mostrados para la matriz de varianza-covarianza.
- Uno más. Considerar el número de componentes cuyo eigenvalor sea mayor que uno.

- **Gráfica de codo (SCREE)**. Cuando los puntos en la gráfica tienden a nivelarse (horizontalmente), los eigenvalores están lo suficientemente cercanos a cero y pueden ignorarse. Entonces, elegir el número de componentes igual al número de eigenvalores antes de que la gráfica se nivele.
- Desafortunadamente, mientras más componentes se requiere, menos útiles resultan cada una.







- **Puntajes**

- **Puntajes**

- Dado que se han generado p componentes principales a partir de las p variables originales, es claro que cada uno de los individuos en nuestra matriz de información, tiene asociados *un valor por cada componente principal*, mismo que se calcula de la siguiente manera

- **Puntajes**

- Dado que se han generado p componentes principales a partir de las p variables originales, es claro que cada uno de los individuos en nuestra matriz de información, tiene asociados *un valor por cada componente principal*, mismo que se calcula de la siguiente manera

$$\mathbf{Z}_i = \mathbf{A}' \mathbf{X}_i, \quad i = 1, 2, \dots, p$$

- **Puntajes**

- Dado que se han generado p componentes principales a partir de las p variables originales, es claro que cada uno de los individuos en nuestra matriz de información, tiene asociados *un valor por cada componente principal*, mismo que se calcula de la siguiente manera

$$\mathbf{Z}_i = \mathbf{A}' \mathbf{X}_i, \quad i = 1, 2, \dots, p$$

- Que proporcionan las coordenadas de la observación $\mathbf{X}_i$ en el nuevo sistema de ejes generado por las c.p.

$$z_{ij} = \mathbf{a}'_j \mathbf{X}_i = \sum_{k=1}^p a_{jk} x_{ik}$$

- **Puntajes**

- Dado que se han generado p componentes principales a partir de las p variables originales, es claro que cada uno de los individuos en nuestra matriz de información, tiene asociados *un valor por cada componente principal*, mismo que se calcula de la siguiente manera

$$\mathbf{Z}_i = \mathbf{A}' \mathbf{X}_i, \quad i = 1, 2, \dots, p$$

- Que proporcionan las coordenadas de la observación $\mathbf{X}_i$ en el nuevo sistema de ejes generado por las c.p.

$$z_{ij} = \mathbf{a}'_j \mathbf{X}_i = \sum_{k=1}^p a_{jk} x_{ik}$$

- Es el valor de la j -ésima componente para el i -ésimo individuo.

- **Puntajes**

- Dado que se han generado p componentes principales a partir de las p variables originales, es claro que cada uno de los individuos en nuestra matriz de información, tiene asociados *un valor por cada componente principal*, mismo que se calcula de la siguiente manera

$$\mathbf{Z}_i = \mathbf{A}' \mathbf{X}_i, \quad i = 1, 2, \dots, p$$

- Que proporcionan las coordenadas de la observación $\mathbf{X}_i$ en el nuevo sistema de ejes generado por las c.p.

$$z_{ij} = \mathbf{a}'_j \mathbf{X}_i = \sum_{k=1}^p a_{jk} x_{ik}$$

- Es el valor de la j -ésima componente para el i -ésimo individuo.
- Entonces, podemos representar un individuo en el plano, mediante la pareja (z_{i1}, z_{i2}) .

- Ya que uno de los usos comunes de esta técnica es identificar individuos similares, es importante tener en cuenta que *las c.p. preservan la distancia entre las observaciones*, como mostraremos en seguida.

- Ya que uno de los usos comunes de esta técnica es identificar individuos similares, es importante tener en cuenta que *las c.p. preservan la distancia entre las observaciones*, como mostraremos en seguida.
- Denotemos por $\mathbf{Z}_i$: Vector de c.p. del individuo $\mathbf{X}_i$ y por $\mathbf{Z}_j$: Vector de c.p. del individuo $\mathbf{X}_j$. Entonces, se trata de mostrar que la distancia entre estas componentes es igual a la distancia entre los vectores originales de los sujetos.

- Ya que uno de los usos comunes de esta técnica es identificar individuos similares, es importante tener en cuenta que *las c.p. preservan la distancia entre las observaciones*, como mostraremos en seguida.
- Denotemos por $\mathbf{Z}_i$: Vector de c.p. del individuo $\mathbf{X}_i$ y por $\mathbf{Z}_j$: Vector de c.p. del individuo $\mathbf{X}_j$. Entonces, se trata de mostrar que la distancia entre estas componentes es igual a la distancia entre los vectores originales de los sujetos.
-

$$\begin{aligned}
 \|\mathbf{Z}_i - \mathbf{Z}_j\|^2 &= (\mathbf{Z}_i - \mathbf{Z}_j)' (\mathbf{Z}_i - \mathbf{Z}_j) \\
 &= (\mathbf{A}' \mathbf{X}_i - \mathbf{A}' \mathbf{X}_j)' (\mathbf{A}' \mathbf{X}_i - \mathbf{A}' \mathbf{X}_j) \\
 &= (\mathbf{A}' (\mathbf{X}_i - \mathbf{X}_j))' (\mathbf{A}' (\mathbf{X}_i - \mathbf{X}_j)) \\
 &= (\mathbf{X}_i - \mathbf{X}_j)' \mathbf{A} \mathbf{A}' (\mathbf{X}_i - \mathbf{X}_j) \\
 &= (\mathbf{X}_i - \mathbf{X}_j)' \mathbf{A} \mathbf{A}^{-1} (\mathbf{X}_i - \mathbf{X}_j) \quad (\mathbf{A} \text{ es ortogonal}) \\
 &= (\mathbf{X}_i - \mathbf{X}_j)' \mathbf{I}_p (\mathbf{X}_i - \mathbf{X}_j) \\
 &= (\mathbf{X}_i - \mathbf{X}_j)' (\mathbf{X}_i - \mathbf{X}_j) \\
 &= \|\mathbf{X}_i - \mathbf{X}_j\|^2
 \end{aligned}$$

- **Observación.** Esta distancia se conserva en el espacio original de los vectores, que es de dimensión p . Si sólo tomamos pocas componentes (2 ó 3) para representar las observaciones, entonces

- **Observación.** Esta distancia se conserva en el espacio original de los vectores, que es de dimensión p . Si sólo tomamos pocas componentes (2 ó 3) para representar las observaciones, entonces

$$\|\mathbf{x}_i - \mathbf{x}_j\|^2 \approx \|\mathbf{z}_i^* - \mathbf{z}_j^*\|^2$$

- **Observación.** Esta distancia se conserva en el espacio original de los vectores, que es de dimensión p . Si sólo tomamos pocas componentes (2 ó 3) para representar las observaciones, entonces

$$\|\mathbf{x}_i - \mathbf{x}_j\|^2 \approx \|\mathbf{z}_i^* - \mathbf{z}_j^*\|^2$$

- Con $\mathbf{Z}^*$ un vector de dimensión 2 ó 3, únicamente. Esta aproximación será adecuada si estas pocas dimensiones explican un alto porcentaje de la varianza total de los datos.

- C.P. con variables medidas en diversas escalas

- **C.P. con variables medidas en diversas escalas**
- El análisis de c.p. se realiza, generalmente, utilizando variables continuas; no obstante, existen aplicaciones donde se presentan diversas escalas de medición en las variables.

- **C.P. con variables medidas en diversas escalas**
- El análisis de c.p. se realiza, generalmente, utilizando variables continuas; no obstante, existen aplicaciones donde se presentan diversas escalas de medición en las variables.
- Una manera generaliza de abordar esta situación, es realizar el análisis ignorando la escala de medición, i.e., suponiendo que todas provienen de una escala de intervalo. En este caso, la correlación entre cualquier par de variables, es la de Pearson.

- **C.P. con variables medidas en diversas escalas**
- El análisis de c.p. se realiza, generalmente, utilizando variables continuas; no obstante, existen aplicaciones donde se presentan diversas escalas de medición en las variables.
- Una manera generaliza de abordar esta situación, es realizar el análisis ignorando la escala de medición, i.e., suponiendo que todas provienen de una escala de intervalo. En este caso, la correlación entre cualquier par de variables, es la de Pearson.
- El hecho de no respetar la escala de cada variable, propicia que las correlaciones sean más pequeñas de lo debido, lo que, para una técnica basada en la asociación entre las variables, resulta poco deseable.

- **C.P. con variables medidas en diversas escalas**
- El análisis de c.p. se realiza, generalmente, utilizando variables continuas; no obstante, existen aplicaciones donde se presentan diversas escalas de medición en las variables.
- Una manera generaliza de abordar esta situación, es realizar el análisis ignorando la escala de medición, i.e., suponiendo que todas provienen de una escala de intervalo. En este caso, la correlación entre cualquier par de variables, es la de Pearson.
- El hecho de no respetar la escala de cada variable, propicia que las correlaciones sean más pequeñas de lo debido, lo que, para una técnica basada en la asociación entre las variables, resulta poco deseable.
- Otra alternativa es construir variables *dummy's* con las variables medidas en escalas nominal y ordinal.

- **C.P. con variables medidas en diversas escalas**
- El análisis de c.p. se realiza, generalmente, utilizando variables continuas; no obstante, existen aplicaciones donde se presentan diversas escalas de medición en las variables.
- Una manera generaliza de abordar esta situación, es realizar el análisis ignorando la escala de medición, i.e., suponiendo que todas provienen de una escala de intervalo. En este caso, la correlación entre cualquier par de variables, es la de Pearson.
- El hecho de no respetar la escala de cada variable, propicia que las correlaciones sean más pequeñas de lo debido, lo que, para una técnica basada en la asociación entre las variables, resulta poco deseable.
- Otra alternativa es construir variables *dummy's* con las variables medidas en escalas nominal y ordinal.
- Este procedimiento tiene la desventaja de incrementar el número de variables dentro del análisis (hay que recordar que si una variable nominal u ordinal tiene k categorías, entonces genera un número igual de variables *dummy's*).

- Este incremento de dimensión repercutirá en el hecho de que tendremos menos posibilidades de poder representar nuestros datos en pocas dimensiones, i.e., tendremos poca varianza explicada por unas cuantas dimensiones.

- Este incremento de dimensión repercutirá en el hecho de que tendremos menos posibilidades de poder representar nuestros datos en pocas dimensiones, i.e., tendremos poca varianza explicada por unas cuantas dimensiones.
- Una forma alternativa de enfrentar este problema, es utilizando la *matriz de correlaciones policóricas*.

- Este incremento de dimensión repercutirá en el hecho de que tendremos menos posibilidades de poder representar nuestros datos en pocas dimensiones, i.e., tendremos poca varianza explicada por unas cuantas dimensiones.
- Una forma alternativa de enfrentar este problema, es utilizando la *matriz de correlaciones policóricas*.
- En esta matriz se utiliza un tipo de correlación de acuerdo a la escala de medición de las dos variables en cuestión. La siguiente tabla muestra las correlaciones que se sugiere calcular.

- Este incremento de dimensión repercutirá en el hecho de que tendremos menos posibilidades de poder representar nuestros datos en pocas dimensiones, i.e., tendremos poca varianza explicada por unas cuantas dimensiones.
- Una forma alternativa de enfrentar este problema, es utilizando la *matriz de correlaciones policóricas*.
- En esta matriz se utiliza un tipo de correlación de acuerdo a la escala de medición de las dos variables en cuestión. La siguiente tabla muestra las correlaciones que se sugiere calcular.

Escala de medición	Continua	Ordinal	Dicotómica
Continua	Pearson	Policórica	Punto biserial
Ordinal		Policórica	Policórica
Dicotómica			Tetracórica

- Este incremento de dimensión repercutirá en el hecho de que tendremos menos posibilidades de poder representar nuestros datos en pocas dimensiones, i.e., tendremos poca varianza explicada por unas cuantas dimensiones.
- Una forma alternativa de enfrentar este problema, es utilizando la *matriz de correlaciones policóricas*.
- En esta matriz se utiliza un tipo de correlación de acuerdo a la escala de medición de las dos variables en cuestión. La siguiente tabla muestra las correlaciones que se sugiere calcular.

Escala de medición	Continua	Ordinal	Dicotómica
Continua	Pearson	Policórica	Punto biserial
Ordinal		Policórica	Policórica
Dicotómica			Tetracórica

- Una vez calculada esta matriz, el análisis de c.p. se lleva a cabo utilizándola para realizar todos los procesos de cálculo.