

- Algoritmo t-SNE

- **Algoritmo t-SNE**

- *t-SNE* (t-Distributed Stochastic Neighbor Embedding) es una herramienta de reducción de dimensión o dimensionalidad que se utiliza para ayudar a visualizar datos de alta dimensión

- **Algoritmo t-SNE**

- *t-SNE* (t-Distributed Stochastic Neighbor Embedding) es una herramienta de reducción de dimensión o dimensionalidad que se utiliza para ayudar a visualizar datos de alta dimensión
- No suele utilizarse como método principal para entrenar un modelo (Machine learning). En cambio, frecuentemente constituye el primer paso para el análisis exploratorio de datos, la visualización y la agrupación en clusters

- **Algoritmo t-SNE**

- *t-SNE* (t-Distributed Stochastic Neighbor Embedding) es una herramienta de reducción de dimensión o dimensionalidad que se utiliza para ayudar a visualizar datos de alta dimensión
- No suele utilizarse como método principal para entrenar un modelo (Machine learning). En cambio, frecuentemente constituye el primer paso para el análisis exploratorio de datos, la visualización y la agrupación en clusters
- t-SNE proporciona una forma intuitiva de comprender datos de alta dimensión al reducir su complejidad, lo que puede guiar la selección y aplicación de técnicas posteriores para un análisis más detallado y centrado

- Mapear datos de alta dimensión en 2D o 3D a través de t-SNE nos permite ver las relaciones existentes entre ellos (si las hay) y, a partir de allí, decidir el mejor algoritmo de aprendizaje automático para aplicar a los datos; como la agrupación en clusteres, la clasificación o el aprendizaje profundo, identificar valores atípicos, es decir, *aprender* esas relaciones observadas en las gráficas

- Mapear datos de alta dimensión en 2D o 3D a través de t-SNE nos permite ver las relaciones existentes entre ellos (si las hay) y, a partir de allí, decidir el mejor algoritmo de aprendizaje automático para aplicar a los datos; como la agrupación en clusters, la clasificación o el aprendizaje profundo, identificar valores atípicos, es decir, *aprender* esas relaciones observadas en las gráficas
- Esto puede ayudar a mejorar el rendimiento de nuestro algoritmo de Machine Learning

- Maperar datos de alta dimensión en 2D o 3D a través de t-SNE nos permite ver las relaciones existentes entre ellos (si las hay) y, a partir de allí, decidir el mejor algoritmo de aprendizaje automático para aplicar a los datos; como la agrupación en clusteres, la clasificación o el aprendizaje profundo, identificar valores atípicos, es decir, *aprender* esas relaciones observadas en las gráficas
- Esto puede ayudar a mejorar el rendimiento de nuestro algoritmo de Machine Learning
- **Datos de alta dimensión**

- Maperar datos de alta dimensión en 2D o 3D a través de t-SNE nos permite ver las relaciones existentes entre ellos (si las hay) y, a partir de allí, decidir el mejor algoritmo de aprendizaje automático para aplicar a los datos; como la agrupación en clusteres, la clasificación o el aprendizaje profundo, identificar valores atípicos, es decir, *aprender* esas relaciones observadas en las gráficas
- Esto puede ayudar a mejorar el rendimiento de nuestro algoritmo de Machine Learning
- **Datos de alta dimensión**
- El algoritmo t-SNE se introdujo debido a la gran cantidad de datos de alta dimensión que los profesionales desean visualizar. Por ejemplo:

- Maperar datos de alta dimensión en 2D o 3D a través de t-SNE nos permite ver las relaciones existentes entre ellos (si las hay) y, a partir de allí, decidir el mejor algoritmo de aprendizaje automático para aplicar a los datos; como la agrupación en clusteres, la clasificación o el aprendizaje profundo, identificar valores atípicos, es decir, *aprender* esas relaciones observadas en las gráficas
- Esto puede ayudar a mejorar el rendimiento de nuestro algoritmo de Machine Learning
- **Datos de alta dimensión**
- El algoritmo t-SNE se introdujo debido a la gran cantidad de datos de alta dimensión que los profesionales desean visualizar. Por ejemplo:
- **Datos financieros:** precios de acciones, volúmenes de transacciones e indicadores económicos, que se pueden representar como conjuntos de datos de alta dimensión

- **Imágenes médicas:** tecnologías como la resonancia magnética y las tomografías computarizadas, generan datos de alta dimensión con valores de intensidad que representan diferentes características

- **Imágenes médicas:** tecnologías como la resonancia magnética y las tomografías computarizadas, generan datos de alta dimensión con valores de intensidad que representan diferentes características
- **Genómica:** las secuencias de ADN de los organismos se representan como conjuntos de datos de alta dimensión, donde cada gen o base de nucleótido representa una dimensión. El genoma humano tiene aproximadamente 3 mil millones de pares de bases, que corresponden a 3 mil millones de características en el ADN

- **Imágenes médicas:** tecnologías como la resonancia magnética y las tomografías computarizadas, generan datos de alta dimensión con valores de intensidad que representan diferentes características
- **Genómica:** las secuencias de ADN de los organismos se representan como conjuntos de datos de alta dimensión, donde cada gen o base de nucleótido representa una dimensión. El genoma humano tiene aproximadamente 3 mil millones de pares de bases, que corresponden a 3 mil millones de características en el ADN
- **Datos de imágenes y videos:** donde cada píxel representa una dimensión

- **Imágenes médicas:** tecnologías como la resonancia magnética y las tomografías computarizadas, generan datos de alta dimensión con valores de intensidad que representan diferentes características
- **Genómica:** las secuencias de ADN de los organismos se representan como conjuntos de datos de alta dimensión, donde cada gen o base de nucleótido representa una dimensión. El genoma humano tiene aproximadamente 3 mil millones de pares de bases, que corresponden a 3 mil millones de características en el ADN
- **Datos de imágenes y videos:** donde cada píxel representa una dimensión
- **Plataformas de redes sociales:** con perfiles de usuarios, publicaciones, me gusta, comentarios y otras interacciones

- **Imágenes médicas:** tecnologías como la resonancia magnética y las tomografías computarizadas, generan datos de alta dimensión con valores de intensidad que representan diferentes características
- **Genómica:** las secuencias de ADN de los organismos se representan como conjuntos de datos de alta dimensión, donde cada gen o base de nucleótido representa una dimensión. El genoma humano tiene aproximadamente 3 mil millones de pares de bases, que corresponden a 3 mil millones de características en el ADN
- **Datos de imágenes y videos:** donde cada píxel representa una dimensión
- **Plataformas de redes sociales:** con perfiles de usuarios, publicaciones, me gusta, comentarios y otras interacciones
- **Los datos de texto:** como artículos de noticias, tweets y reseñas de clientes, se pueden representar con cada palabra o token como una dimensión

- **Robótica:** genera datos con entradas sensoriales de cámaras, micrófonos y otros sensores utilizados en sus sistemas de control

- **Robótica:** genera datos con entradas sensoriales de cámaras, micrófonos y otros sensores utilizados en sus sistemas de control
- Los datos de alta dimensión están en todas partes. Por lo que surge la necesidad de visualizar y explorar estos datos complejos de una manera más intuitiva y comprensible

- **Robótica:** genera datos con entradas sensoriales de cámaras, micrófonos y otros sensores utilizados en sus sistemas de control
- Los datos de alta dimensión están en todas partes. Por lo que surge la necesidad de visualizar y explorar estos datos complejos de una manera más intuitiva y comprensible
- t-SNE sirve como una herramienta poderosa para lograr esto al transformar, de manera efectiva, los datos de alta dimensión en una representación de baja dimensión sin perder información significativa

- **Análisis de componentes principales (PCA)**

- **Análisis de componentes principales (PCA)**
- Una de las primeras y más populares técnicas de reducción de dimensionalidad es el Análisis de componentes principales (PCA), que fue publicado en 1901 por Pearson, Karl et al.

- **Análisis de componentes principales (PCA)**
- Una de las primeras y más populares técnicas de reducción de dimensionalidad es el Análisis de componentes principales (PCA), que fue publicado en 1901 por Pearson, Karl et al.
- Es una técnica *lineal* que encuentra una proyección *lineal*, o una nueva representación, de los puntos de datos originales de alta dimensión en un subespacio de menor dimensión de manera de maximizar la varianza de los datos, es decir, preservar la mayor cantidad de información posible

- **Análisis de componentes principales (PCA)**
- Una de las primeras y más populares técnicas de reducción de dimensionalidad es el Análisis de componentes principales (PCA), que fue publicado en 1901 por Pearson, Karl et al.
- Es una técnica *lineal* que encuentra una proyección *lineal*, o una nueva representación, de los puntos de datos originales de alta dimensión en un subespacio de menor dimensión de manera de maximizar la varianza de los datos, es decir, preservar la mayor cantidad de información posible
- Estos ejes/direcciones proyectados se conocen como los *componentes principales* de los datos

- **Análisis de componentes principales (PCA)**
- Una de las primeras y más populares técnicas de reducción de dimensionalidad es el Análisis de componentes principales (PCA), que fue publicado en 1901 por Pearson, Karl et al.
- Es una técnica *lineal* que encuentra una proyección *lineal*, o una nueva representación, de los puntos de datos originales de alta dimensión en un subespacio de menor dimensión de manera de maximizar la varianza de los datos, es decir, preservar la mayor cantidad de información posible
- Estos ejes/direcciones proyectados se conocen como los *componentes principales* de los datos
- ¿Se puede mejorar esta reducción de dimensión que hace PCA?


- **Análisis de componentes principales (PCA)**
- Una de las primeras y más populares técnicas de reducción de dimensionalidad es el Análisis de componentes principales (PCA), que fue publicado en 1901 por Pearson, Karl et al.
- Es una técnica *lineal* que encuentra una proyección *lineal*, o una nueva representación, de los puntos de datos originales de alta dimensión en un subespacio de menor dimensión de manera de maximizar la varianza de los datos, es decir, preservar la mayor cantidad de información posible
- Estos ejes/direcciones proyectados se conocen como los *componentes principales* de los datos
- ¿Se puede mejorar esta reducción de dimensión que hace PCA?
- **Datos lineales vs. no lineales**

- **Análisis de componentes principales (PCA)**
- Una de las primeras y más populares técnicas de reducción de dimensionalidad es el Análisis de componentes principales (PCA), que fue publicado en 1901 por Pearson, Karl et al.
- Es una técnica *lineal* que encuentra una proyección *lineal*, o una nueva representación, de los puntos de datos originales de alta dimensión en un subespacio de menor dimensión de manera de maximizar la varianza de los datos, es decir, preservar la mayor cantidad de información posible
- Estos ejes/direcciones proyectados se conocen como los *componentes principales* de los datos
- ¿Se puede mejorar esta reducción de dimensión que hace PCA?
- **Datos lineales vs. no lineales**
- PCA es bueno, pero es un algoritmo lineal


- No puede representar relaciones complejas entre características

- No puede representar relaciones complejas entre características
- Se ocupa de preservar grandes distancias en el mapa (para capturar la máxima cantidad de varianza). Pero, ¿son confiables estas distancias?


- No puede representar relaciones complejas entre características
- Se ocupa de preservar grandes distancias en el mapa (para capturar la máxima cantidad de varianza). Pero, ¿son confiables estas distancias?
- Las técnicas lineales se centran en mantener las representaciones de baja dimensión de puntos de datos diferentes muy separados. Pero, ¿es eso lo que queremos en una representación visual? ¿Y qué tan confiable es?




(a) Swiss roll dataset.



(b) Helix dataset.



(c) Twinpeaks dataset.



(d) Broken Swiss roll dataset.

- Si observamos la variedad no lineal del rollo suizo anterior (a), podemos ver que una distancia euclidiana (en línea recta) entre dos puntos en los grupos rojo y azul sugeriría que los puntos de datos están bastante cerca


- Si observamos la variedad no lineal del rollo suizo anterior (a), podemos ver que una distancia euclidiana (en línea recta) entre dos puntos en los grupos rojo y azul sugeriría que los puntos de datos están bastante cerca
- Si consideramos que toda la estructura está representada en un plano 2D (es decir, extendiéndola hasta formar una forma 2D plana), los puntos rojos estarían en realidad en el extremo opuesto a los puntos azules: uno tendría que recorrer toda la longitud del rollo para llegar de un punto al otro

- Si observamos la variedad no lineal del rollo suizo anterior (a), podemos ver que una distancia euclidiana (en línea recta) entre dos puntos en los grupos rojo y azul sugeriría que los puntos de datos están bastante cerca
- Si consideramos que toda la estructura está representada en un plano 2D (es decir, extendiéndola hasta formar una forma 2D plana), los puntos rojos estarían en realidad en el extremo opuesto a los puntos azules: uno tendría que recorrer toda la longitud del rollo para llegar de un punto al otro
- PCA intentaría capturar la varianza a lo largo del eje más largo del rollo, aplanándolo esencialmente. Esto no lograría preservar la estructura espiral inherente a los datos del rollo suizo, donde los puntos que están cerca entre sí en la espiral (y, por lo tanto, deberían estar cerca entre sí en una buena representación 2D) terminan ubicados muy separados

- Así que podemos ver que el PCA no funciona muy bien para la visualización de datos no lineales porque conserva estas grandes distancias y no solo necesitamos considerar la distancia en línea recta, sino también la estructura circundante de cada punto de datos

- Así que podemos ver que el PCA no funciona muy bien para la visualización de datos no lineales porque conserva estas grandes distancias y no solo necesitamos considerar la distancia en línea recta, sino también la estructura circundante de cada punto de datos
- **Introducción a t-SNE**

- Así que podemos ver que el PCA no funciona muy bien para la visualización de datos no lineales porque conserva estas grandes distancias y no solo necesitamos considerar la distancia en línea recta, sino también la estructura circundante de cada punto de datos
- **Introducción a t-SNE**
- *Stochastic Neighbor Embedding* fue desarrollado y publicado por primera vez en 2002 por Hinton et al., y luego fue modificada en 2008 hasta convertirse en lo que tenemos hoy: t-SNE (t-Distributed Stochastic Neighbor Embedding)




$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}$$

- En un espacio de alta dimensión (izquierda) medimos similitudes entre puntos. Lo hacemos de manera que sólo observamos similitudes locales, es decir, puntos cercanos

- En un espacio de alta dimensión (izquierda) medimos similitudes entre puntos. Lo hacemos de manera que sólo observamos similitudes locales, es decir, puntos cercanos
- El punto rojo en el espacio de alta dimensión es x_i . Primero centramos una gaussiana sobre este punto (círculo violeta) y luego medimos la densidad de todos los demás puntos bajo esta gaussiana (por ejemplo, x_j)

- En un espacio de alta dimensión (izquierda) medimos similitudes entre puntos. Lo hacemos de manera que sólo observamos similitudes locales, es decir, puntos cercanos
- El punto rojo en el espacio de alta dimensión es x_i . Primero centramos una gaussiana sobre este punto (círculo violeta) y luego medimos la densidad de todos los demás puntos bajo esta gaussiana (por ejemplo, x_j)
- Luego renormalizamos todos los pares de puntos que involucran al punto x_i (el denominador/parte inferior de la fracción). Esto nos da la probabilidad condicional $p_{j|i}$, que básicamente mide la similitud entre pares de puntos i, j

- En un espacio de alta dimensión (izquierda) medimos similitudes entre puntos. Lo hacemos de manera que sólo observamos similitudes locales, es decir, puntos cercanos
- El punto rojo en el espacio de alta dimensión es x_i . Primero centramos una gaussiana sobre este punto (círculo violeta) y luego medimos la densidad de todos los demás puntos bajo esta gaussiana (por ejemplo, x_j)
- Luego renormalizamos todos los pares de puntos que involucran al punto x_i (el denominador/parte inferior de la fracción). Esto nos da la probabilidad condicional $p_{j|i}$, que básicamente mide la similitud entre pares de puntos i, j
- Podemos pensar esto como una distribución de probabilidad sobre pares de puntos, donde la probabilidad de elegir un par particular de puntos es proporcional a su similitud (distancia)



- Esto se puede visualizar de la siguiente manera. Si dos puntos están cerca uno del otro en el espacio de alta dimensión original, vamos a tener un valor grande para $p_{j|i}$. Si dos puntos son diferentes (están muy separados) en el espacio de alta dimensión, obtendremos un $p_{j|i}$ pequeño


- Esto se puede visualizar de la siguiente manera. Si dos puntos están cerca uno del otro en el espacio de alta dimensión original, vamos a tener un valor grande para $p_{j|i}$. Si dos puntos son diferentes (están muy separados) en el espacio de alta dimensión, obtendremos un $p_{j|i}$ pequeño
- **Perplexity**

- Esto se puede visualizar de la siguiente manera. Si dos puntos están cerca uno del otro en el espacio de alta dimensión original, vamos a tener un valor grande para $p_{j|i}$. Si dos puntos son diferentes (están muy separados) en el espacio de alta dimensión, obtendremos un $p_{j|i}$ pequeño
- **Perplexity**
- Si observamos la misma ecuación, la perplexity nos indica la densidad de puntos en relación con un punto en particular.

- Esto se puede visualizar de la siguiente manera. Si dos puntos están cerca uno del otro en el espacio de alta dimensión original, vamos a tener un valor grande para $p_{j|i}$. Si dos puntos son diferentes (están muy separados) en el espacio de alta dimensión, obtendremos un $p_{j|i}$ pequeño
- **Perplexity**
- Si observamos la misma ecuación, la perplexity nos indica la densidad de puntos en relación con un punto en particular.
- Si se agrupan 4 puntos de características similares, tendrán una perplexity mayor que los que no están agrupados.

- Esto se puede visualizar de la siguiente manera. Si dos puntos están cerca uno del otro en el espacio de alta dimensión original, vamos a tener un valor grande para $p_{j|i}$. Si dos puntos son diferentes (están muy separados) en el espacio de alta dimensión, obtendremos un $p_{j|i}$ pequeño
- **Perplexity**
- Si observamos la misma ecuación, la perplexity nos indica la densidad de puntos en relación con un punto en particular.
- Si se agrupan 4 puntos de características similares, tendrán una perplexity mayor que los que no están agrupados.
- Ahora bien, los puntos con menos densidad a su alrededor tienen curvas normales más planas en comparación con las curvas con más densidad. En la figura siguiente, los puntos morados son dispersos

$$p_{j|i} = \frac{\exp(-||x_i - x_j||^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-||x_i - x_k||^2 / 2\sigma_i^2)}$$



- Calculamos la distribución condicional entre puntos, ya que esto nos permite establecer un ancho de banda diferente (σ_i^2) para cada punto, de modo que la distribución condicional tenga una perplexity fija.

- Calculamos la distribución condicional entre puntos, ya que esto nos permite establecer un ancho de banda diferente (σ_i^2) para cada punto, de modo que la distribución condicional tenga una perplexity fija.
- Esto consiste básicamente en escalar el ancho de banda de la gaussiana de tal manera que una cantidad fija de puntos caiga en el rango de esta gaussiana

- Calculamos la distribución condicional entre puntos, ya que esto nos permite establecer un ancho de banda diferente (σ_i^2) para cada punto, de modo que la distribución condicional tenga una perplexity fija.
- Esto consiste básicamente en escalar el ancho de banda de la gaussiana de tal manera que una cantidad fija de puntos caiga en el rango de esta gaussiana
- Hacemos esto porque diferentes partes del espacio pueden tener diferentes densidades, y este truco nos permite adaptarnos a esas diferentes densidades

- Calculamos la distribución condicional entre puntos, ya que esto nos permite establecer un ancho de banda diferente (σ_i^2) para cada punto, de modo que la distribución condicional tenga una perplexity fija.
- Esto consiste básicamente en escalar el ancho de banda de la gaussiana de tal manera que una cantidad fija de puntos caiga en el rango de esta gaussiana
- Hacemos esto porque diferentes partes del espacio pueden tener diferentes densidades, y este truco nos permite adaptarnos a esas diferentes densidades
- **Maapeo en el espacio de menor dimensión**

- Calculamos la distribución condicional entre puntos, ya que esto nos permite establecer un ancho de banda diferente (σ_i^2) para cada punto, de modo que la distribución condicional tenga una perplexity fija.
- Esto consiste básicamente en escalar el ancho de banda de la gaussiana de tal manera que una cantidad fija de puntos caiga en el rango de esta gaussiana
- Hacemos esto porque diferentes partes del espacio pueden tener diferentes densidades, y este truco nos permite adaptarnos a esas diferentes densidades
- **Mapeo en el espacio de menor dimensión**
- A continuación, veremos el espacio de menor dimensión que será nuestro mapa final

- Calculamos la distribución condicional entre puntos, ya que esto nos permite establecer un ancho de banda diferente (σ_i^2) para cada punto, de modo que la distribución condicional tenga una perplexity fija.
- Esto consiste básicamente en escalar el ancho de banda de la gaussiana de tal manera que una cantidad fija de puntos caiga en el rango de esta gaussiana
- Hacemos esto porque diferentes partes del espacio pueden tener diferentes densidades, y este truco nos permite adaptarnos a esas diferentes densidades
- **Mapeo en el espacio de menor dimensión**
- A continuación, veremos el espacio de menor dimensión que será nuestro mapa final
- Comenzamos colocando los puntos al azar en este mapa. Cada objeto de mayor dimensión estará representado por un punto aquí

- Luego repetimos el mismo proceso anterior: centramos un núcleo sobre el punto y_i y medimos la densidad de todos los demás puntos y_j bajo esa distribución. Posteriormente renormalizamos dividiendo sobre todos los pares de puntos. Esto nos da una probabilidad $q_{j|i}$, que mide la similitud de dos puntos en el mapa de menor dimensión

- Luego repetimos el mismo proceso anterior: centramos un núcleo sobre el punto y_i y medimos la densidad de todos los demás puntos y_j bajo esa distribución. Posteriormente renormalizamos dividiendo sobre todos los pares de puntos. Esto nos da una probabilidad $q_{j|i}$, que mide la similitud de dos puntos en el mapa de menor dimensión
- Ahora, queremos que estas probabilidades en $q_{j|i}$ reflejen las similitudes $p_{j|i}$ que calculamos en el espacio de alta dimensión, lo más fielmente posible. Si los $q_{j|i}$ son idénticos a los $p_{j|i}$, entonces aparentemente la estructura del mapa es muy similar a la estructura de los datos en el espacio de alta dimensión original

- Luego repetimos el mismo proceso anterior: centramos un núcleo sobre el punto y_i y medimos la densidad de todos los demás puntos y_j bajo esa distribución. Posteriormente renormalizamos dividiendo sobre todos los pares de puntos. Esto nos da una probabilidad $q_{j|i}$, que mide la similitud de dos puntos en el mapa de menor dimensión
- Ahora, queremos que estas probabilidades en $q_{j|i}$ reflejen las similitudes $p_{j|i}$ que calculamos en el espacio de alta dimensión, lo más fielmente posible. Si los $q_{j|i}$ son idénticos a los $p_{j|i}$, entonces aparentemente la estructura del mapa es muy similar a la estructura de los datos en el espacio de alta dimensión original
- Mediremos la diferencia entre estos valores $p_{j|i}$ en el espacio de alta dimensión y los valores $q_{j|i}$ en el mapa de baja dimensión utilizando la divergencia de *Kullback-Leibler*

- **Stochastic Neighbor Embedding**

- **Stochastic Neighbor Embedding**
- La *divergencia KL* es la medida estándar de la distancia entre distribuciones de probabilidad/o similitud.

- **Stochastic Neighbor Embedding**

- La *divergencia KL* es la medida estándar de la distancia entre distribuciones de probabilidad/o similitud.
- Mostramos a continuación en la función de costo como la suma de todos los pares de puntos de $p_{j|i}$ por $\log(q_{j|i})$ sobre $q_{j|i}$.

- **Stochastic Neighbor Embedding**

- La *divergencia KL* es la medida estándar de la distancia entre distribuciones de probabilidad/o similitud.
- Mostramos a continuación en la función de costo como la suma de todos los pares de puntos de $p_{j|i}$ por $\log(q_{j|i})$ sobre $q_{j|i}$.
- Similitud de puntos de datos en alta dimensión

- **Stochastic Neighbor Embedding**

- La *divergencia KL* es la medida estándar de la distancia entre distribuciones de probabilidad/o similitud.
- Mostramos a continuación en la función de costo como la suma de todos los pares de puntos de $p_{j|i}$ por $\log(q_{j|i})$ sobre $q_{j|i}$.
- Similitud de puntos de datos en alta dimensión

- $$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2/2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2/2\sigma_i^2)}$$

- **Stochastic Neighbor Embedding**

- La *divergencia KL* es la medida estándar de la distancia entre distribuciones de probabilidad/o similitud.
- Mostramos a continuación en la función de costo como la suma de todos los pares de puntos de $p_{j|i}$ por $\log(q_{j|i})$ sobre $q_{j|i}$.
- Similitud de puntos de datos en alta dimensión

- $$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2/2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2/2\sigma_i^2)}$$

- Similitud de puntos de datos en baja dimensión

- **Stochastic Neighbor Embedding**

- La *divergencia KL* es la medida estándar de la distancia entre distribuciones de probabilidad/o similitud.
- Mostramos a continuación en la función de costo como la suma de todos los pares de puntos de $p_{j|i}$ por $\log(q_{j|i})$ sobre $q_{j|i}$.
- Similitud de puntos de datos en alta dimensión

- $$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2/2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2/2\sigma_i^2)}$$

- Similitud de puntos de datos en baja dimensión

- $$q_{j|i} = \frac{\exp(-\|y_i - y_j\|^2/2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|y_i - y_k\|^2/2\sigma_i^2)}$$

- Función de costo

- Función de costo

- $\mathbf{C} = \sum_i KL(P_i|Q_i) = \sum_j \sum_i p_{j|i} \log \frac{p_{j|i}}{q_{j|i}}$

- Función de costo

- $\mathbf{C} = \sum_i KL(P_i|Q_i) = \sum_j \sum_i p_{j|i} \log \frac{p_{j|i}}{q_{j|i}}$

- Nuestro objetivo ahora es disponer los *puntos en el espacio de baja dimensión* de modo que la divergencia KL se minimice, es decir, que sea lo más similar posible a *los valores de alta dimensión*

- Función de costo

- $\mathbf{C} = \sum_i KL(P_i|Q_i) = \sum_j \sum_i p_{j|i} \log \frac{p_{j|i}}{q_{j|i}}$

- Nuestro objetivo ahora es disponer los *puntos en el espacio de baja dimensión* de modo que la divergencia KL se minimice, es decir, que sea lo más similar posible a *los valores de alta dimensión*
- Para ello, vamos a realizar básicamente un descenso de gradiente (algoritmo) en esta divergencia KL, que consiste esencialmente en mover los puntos de tal manera que la divergencia KL se vuelva pequeña

- **Algoritmo t-SNE**

- **Algoritmo t-SNE**

- 1. Calcular las similitudes por pares (probabilidades condicionales) en el espacio de alta dimensión, utilizando una distribución gaussiana. El parámetro de perplexity define el número efectivo de vecinos que tiene cada punto y ayuda a equilibrar el enfoque en los aspectos locales y globales de los datos

- **Algoritmo t-SNE**

- 1. Calcular las similitudes por pares (probabilidades condicionales) en el espacio de alta dimensión, utilizando una distribución gaussiana. El parámetro de perplexity define el número efectivo de vecinos que tiene cada punto y ayuda a equilibrar el enfoque en los aspectos locales y globales de los datos
- Simetrizar las probabilidades. Esto significa que cada punto considera al otro punto como su vecino, y se logra tomando el promedio de las probabilidades condicionales para cada par de puntos. Luego, normalizar dividiendo por el número total de puntos

- **Algoritmo t-SNE**

- 1. Calcular las similitudes por pares (probabilidades condicionales) en el espacio de alta dimensión, utilizando una distribución gaussiana. El parámetro de perplexity define el número efectivo de vecinos que tiene cada punto y ayuda a equilibrar el enfoque en los aspectos locales y globales de los datos
- Simetrizar las probabilidades. Esto significa que cada punto considera al otro punto como su vecino, y se logra tomando el promedio de las probabilidades condicionales para cada par de puntos. Luego, normalizar dividiendo por el número total de puntos
- Inicializar aleatoriamente la posición de cada punto de datos en el espacio de baja dimensión, generalmente extrayendo de una distribución normal con media 0 y varianza pequeña

- Iniciar un ciclo que iterará una cantidad fija de veces T . Cada iteración actualiza la posición de los puntos:

- Iniciar un ciclo que iterará una cantidad fija de veces T . Cada iteración actualiza la posición de los puntos:
 - Calcular las similaridades por pares en el espacio de baja dimensión utilizando una distribución t-Student

- Iniciar un ciclo que iterará una cantidad fija de veces T . Cada iteración actualiza la posición de los puntos:
 - Calcular las similaridades por pares en el espacio de baja dimensión utilizando una distribución t-Student
 - Calcular el gradiente de la función de costo con respecto a la posición de los puntos. La función de costo es usualmente la divergencia de Kullback-Leibler entre las distribuciones de alta y baja dimensión

- Iniciar un ciclo que iterará una cantidad fija de veces T . Cada iteración actualiza la posición de los puntos:
 - Calcular las similitudes por pares en el espacio de baja dimensión utilizando una distribución t-Student
 - Calcular el gradiente de la función de costo con respecto a la posición de los puntos. La función de costo es usualmente la divergencia de Kullback-Leibler entre las distribuciones de alta y baja dimensión
 - Actualizar la posición de los puntos en el espacio de baja dimensión. Este paso de actualización se compone de tres partes: la posición anterior $Y_{(t-1)}$, un término proporcional al gradiente que ayuda a minimizar la función de costo y un término de momento que ayuda a acelerar la convergencia y evitar mínimos locales

- Iniciar un ciclo que iterará una cantidad fija de veces T . Cada iteración actualiza la posición de los puntos:
 - Calcular las similitudes por pares en el espacio de baja dimensión utilizando una distribución t-Student
 - Calcular el gradiente de la función de costo con respecto a la posición de los puntos. La función de costo es usualmente la divergencia de Kullback-Leibler entre las distribuciones de alta y baja dimensión
 - Actualizar la posición de los puntos en el espacio de baja dimensión. Este paso de actualización se compone de tres partes: la posición anterior $Y_{(t-1)}$, un término proporcional al gradiente que ayuda a minimizar la función de costo y un término de momento que ayuda a acelerar la convergencia y evitar mínimos locales
- Fin del algoritmo t-SNE. Las posiciones finales de los puntos en el espacio de baja dimensión ahora deberían proporcionar una visualización útil de los datos de alta dimensión

- Algunos puntos clave para la implementación e interpretación de los resultados obtenidos por el método t-SNE

- Algunos puntos clave para la implementación e interpretación de los resultados obtenidos por el método t-SNE
- El valor de perplexity debe de ser menor que el número de observaciones del conjunto de datos. Por lo general se recomienda trabajar dentro del rango 5-50

- Algunos puntos clave para la implementación e interpretación de los resultados obtenidos por el método t-SNE
- El valor de perplexity debe de ser menor que el número de observaciones del conjunto de datos. Por lo general se recomienda trabajar dentro del rango 5-50
- Dependiendo del valor de perplexity empleado, tanto la distancia entre clusters como su forma puede variar en gran medida

- Algunos puntos clave para la implementación e interpretación de los resultados obtenidos por el método t-SNE
- El valor de perplexity debe de ser menor que el número de observaciones del conjunto de datos. Por lo general se recomienda trabajar dentro del rango 5-50
- Dependiendo del valor de perplexity empleado, tanto la distancia entre clusters como su forma puede variar en gran medida
- El proceso no es determinista, puede ocurrir que, ejecutando el mismo algoritmo, con los mismos parámetros, en los mismos datos, se obtengan resultados ligeramente distintos

- Algunos puntos clave para la implementación e interpretación de los resultados obtenidos por el método t-SNE
- El valor de perplexity debe de ser menor que el número de observaciones del conjunto de datos. Por lo general se recomienda trabajar dentro del rango 5-50
- Dependiendo del valor de perplexity empleado, tanto la distancia entre clusters como su forma puede variar en gran medida
- El proceso no es determinista, puede ocurrir que, ejecutando el mismo algoritmo, con los mismos parámetros, en los mismos datos, se obtengan resultados ligeramente distintos
- Idealmente, al representar los resultados de un t-SNE, se observa un patrón de agrupaciones. Sin embargo, su interpretación no debe hacerse de la misma forma que en un proceso de clustering

- En t-SNE, ni el tamaño de los clusters, ni su densidad, ni su separación deben entenderse como indicadores de dispersión u otras características de la población con la que se está trabajando

- En t-SNE, ni el tamaño de los clusters, ni su densidad, ni su separación deben entenderse como indicadores de dispersión u otras características de la población con la que se está trabajando
- El algoritmo de t-SNE actúa de tal forma que puede expandir clusters densos y compactar clusters dispersos, de ahí lo buenas que suelen ser sus visualizaciones

- En t-SNE, ni el tamaño de los clusters, ni su densidad, ni su separación deben entenderse como indicadores de dispersión u otras características de la población con la que se está trabajando
- El algoritmo de t-SNE actúa de tal forma que puede expandir clusters densos y compactar clusters dispersos, de ahí lo buenas que suelen ser sus visualizaciones
- **Limitaciones y desventajas**

- En t-SNE, ni el tamaño de los clusters, ni su densidad, ni su separación deben entenderse como indicadores de dispersión u otras características de la población con la que se está trabajando
- El algoritmo de t-SNE actúa de tal forma que puede expandir clusters densos y compactar clusters dispersos, de ahí lo buenas que suelen ser sus visualizaciones
- **Limitaciones y desventajas**
- La reducción de dimensionalidad que consigue el t-SNE está basada en el concepto matemático de manifold. Un manifold se define como una superficie d -dimensional que reside dentro de un espacio D -dimensional, siendo $d < D$. Un ejemplo en 3 dimensiones sería el siguiente: una hoja de papel tiene dos dimensiones, pero, si se arruga en forma de pelota, ahora pasa a un espacio de 3 dimensiones.

- En t-SNE, ni el tamaño de los clusters, ni su densidad, ni su separación deben entenderse como indicadores de dispersión u otras características de la población con la que se está trabajando
- El algoritmo de t-SNE actúa de tal forma que puede expandir clusters densos y compactar clusters dispersos, de ahí lo buenas que suelen ser sus visualizaciones
- **Limitaciones y desventajas**
- La reducción de dimensionalidad que consigue el t-SNE está basada en el concepto matemático de manifold. Un manifold se define como una superficie d -dimensional que reside dentro de un espacio D -dimensional, siendo $d < D$. Un ejemplo en 3 dimensiones sería el siguiente: una hoja de papel tiene dos dimensiones, pero, si se arruga en forma de pelota, ahora pasa a un espacio de 3 dimensiones.
- Por mucho que se moldee, es posible desplegarla recuperando la estructura original de dos dimensiones

- La hoja de papel representa un manifold 2D en un espacio 3D. Si en lugar de una hoja, se tratase de un hilo enredado formando de ovillo, sería un manifold 1D en un espacio 3D.

- La hoja de papel representa un manifold 2D en un espacio 3D. Si en lugar de una hoja, se tratase de un hilo enredado formando de ovillo, sería un manifold 1D en un espacio 3D.
- En aquellos casos en los que se cumple la hipótesis o asunción de manifold (los datos forman un manifold de menor dimensión que el espacio en el que se están observando), entonces, el t-SNE es capaz de proyectar correctamente los datos en esa dimensionalidad inferior.

- La hoja de papel representa un manifold 2D en un espacio 3D. Si en lugar de una hoja, se tratase de un hilo enredado formando de ovillo, sería un manifold 1D en un espacio 3D.
- En aquellos casos en los que se cumple la hipótesis o asunción de manifold (los datos forman un manifold de menor dimensión que el espacio en el que se están observando), entonces, el t-SNE es capaz de proyectar correctamente los datos en esa dimensionalidad inferior.
- En la realidad, el supuesto de manifold no puede cumplirse siempre, de hecho, si así fuese, cualquier conjunto de datos con N -dimensiones, podría considerarse como un manifold de dimensión M , con $M < N$

- La hoja de papel representa un manifold 2D en un espacio 3D. Si en lugar de una hoja, se tratase de un hilo enredado formando de ovillo, sería un manifold 1D en un espacio 3D.
- En aquellos casos en los que se cumple la hipótesis o asunción de manifold (los datos forman un manifold de menor dimensión que el espacio en el que se están observando), entonces, el t-SNE es capaz de proyectar correctamente los datos en esa dimensionalidad inferior.
- En la realidad, el supuesto de manifold no puede cumplirse siempre, de hecho, si así fuese, cualquier conjunto de datos con N -dimensiones, podría considerarse como un manifold de dimensión M , con $M < N$
- Una vez proyectados los datos en ese espacio M -dimensional, se podría repetir el proceso sucesivamente hasta concluir que los datos originales de dimensión N pertenecen a un manifold de dimensión 1

- Dado que esto no es cierto para todos los conjuntos de datos, el supuesto de manifold no siempre se cumple. Es en estos casos, en los que t-SNE no resulta útil reduciendo la dimensionalidad

- Dado que esto no es cierto para todos los conjuntos de datos, el supuesto de manifold no siempre se cumple. Es en estos casos, en los que t-SNE no resulta útil reduciendo la dimensionalidad
- En cuanto a las desventajas del t-SNE, pueden destacarse:

- Dado que esto no es cierto para todos los conjuntos de datos, el supuesto de manifold no siempre se cumple. Es en estos casos, en los que t-SNE no resulta útil reduciendo la dimensionalidad
- En cuanto a las desventajas del t-SNE, pueden destacarse:
 - Está diseñado para reducir los datos a 2 o 3 dimensiones. No debe aplicarse si la reducción de dimensionalidad se hace a espacios $d > 3$

- Dado que esto no es cierto para todos los conjuntos de datos, el supuesto de manifold no siempre se cumple. Es en estos casos, en los que t-SNE no resulta útil reduciendo la dimensionalidad
- En cuanto a las desventajas del t-SNE, pueden destacarse:
 - Está diseñado para reducir los datos a 2 o 3 dimensiones. No debe aplicarse si la reducción de dimensionalidad se hace a espacios $d > 3$
 - La baja interpretación de su algoritmo (black box), permite visualizar muy bien datos, pero no genera, por ejemplo, una serie de ecuaciones fácilmente interpretables como hace el PCA

- Dado que esto no es cierto para todos los conjuntos de datos, el supuesto de manifold no siempre se cumple. Es en estos casos, en los que t-SNE no resulta útil reduciendo la dimensionalidad
- En cuanto a las desventajas del t-SNE, pueden destacarse:
 - Está diseñado para reducir los datos a 2 o 3 dimensiones. No debe aplicarse si la reducción de dimensionalidad se hace a espacios $d > 3$
 - La baja interpretación de su algoritmo (black box), permite visualizar muy bien datos, pero no genera, por ejemplo, una serie de ecuaciones fácilmente interpretables como hace el PCA
 - No es un proceso totalmente determinista, por lo que, a pesar de emplear los mismos datos, los resultados pueden variar

- Dado que esto no es cierto para todos los conjuntos de datos, el supuesto de manifold no siempre se cumple. Es en estos casos, en los que t-SNE no resulta útil reduciendo la dimensionalidad
- En cuanto a las desventajas del t-SNE, pueden destacarse:
 - Está diseñado para reducir los datos a 2 o 3 dimensiones. No debe aplicarse si la reducción de dimensionalidad se hace a espacios $d > 3$
 - La baja interpretación de su algoritmo (black box), permite visualizar muy bien datos, pero no genera, por ejemplo, una serie de ecuaciones fácilmente interpretables como hace el PCA
 - No es un proceso totalmente determinista, por lo que, a pesar de emplear los mismos datos, los resultados pueden variar
 - Su algoritmo no es incremental, en otras palabras, no puede aplicarse sobre un conjunto de datos y después actualizarlo con unas pocas observaciones nuevas. Se tiene que ejecutar de nuevo todo el algoritmo incluyendo todas las observaciones (las viejas y las nuevas)

- **Parámetros a controlar en t-SNE**

- **Parámetros a controlar en t-SNE**
- **Iteraciones:** Número máximo de iteraciones que ejecutará el algoritmo. Se puede especificar un valor de 200 a 2000

- **Parámetros a controlar en t-SNE**
- **Iteraciones:** Número máximo de iteraciones que ejecutará el algoritmo. Se puede especificar un valor de 200 a 2000
- **Perplexity:** Probablemente, el parámetro más importante en este algoritmo. Perplexity está relacionado con la cantidad de vecinos más cercanos que se utilizan en los algoritmos de aprendizaje. En t-SNE, perplexity puede verse como un argumento que establece la cantidad de vecinos más cercanos efectivos. El valor más apropiado depende de la densidad de los datos. En general, un conjunto de datos más grande o más denso requiere una perplejidad mayor. Se puede especificar un valor de 5 a 30

- **Parámetros a controlar en t-SNE**
- **Iteraciones:** Número máximo de iteraciones que ejecutará el algoritmo. Se puede especificar un valor de 200 a 2000
- **Perplexity:** Probablemente, el parámetro más importante en este algoritmo. Perplexity está relacionado con la cantidad de vecinos más cercanos que se utilizan en los algoritmos de aprendizaje. En t-SNE, perplexity puede verse como un argumento que establece la cantidad de vecinos más cercanos efectivos. El valor más apropiado depende de la densidad de los datos. En general, un conjunto de datos más grande o más denso requiere una perplejidad mayor. Se puede especificar un valor de 5 a 30
- **eta (tasa de aprendizaje):** la tasa de aprendizaje (eta), que controla cuánto se ajustan los pesos en cada actualización. En t-SNE, es un tamaño de paso de actualización de descenso de gradiente para obtener una diferencia de probabilidad mínima. Se puede especificar un valor de 2 a 200

- **Algoritmo KNN:** establece el algoritmo de *k vecinos más cercanos*. Uno de los pasos iniciales en t-SNE es calcular la *distancia o similitud* entre pares de datos, utilizando los valores de intensidad de todos los parámetros seleccionados. Hay dos opciones, un árbol de puntos de vista que es un método exacto que calcula todas las distancias entre todas las datos y las compara con un umbral para ver si son vecinas, o el algoritmo ANNOY, que es una aproximación que no necesariamente requiere todos los vecinos más cercanos, por lo que acelera significativamente este cálculo