

- **UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction**

- **UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction**
- La reducción de dimensionalidad es una herramienta poderosa para que los profesionales del aprendizaje automatizado visualicen y comprendan conjuntos de datos grandes y de alta dimensión

- **UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction**
- La reducción de dimensionalidad es una herramienta poderosa para que los profesionales del aprendizaje automatizado visualicen y comprendan conjuntos de datos grandes y de alta dimensión
- Una de las técnicas más utilizadas para la visualización es t-SNE, pero su rendimiento se ve afectado con conjuntos de datos grandes y su uso correcto puede resultar complicado

- **UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction**
- La reducción de dimensionalidad es una herramienta poderosa para que los profesionales del aprendizaje automatizado visualicen y comprendan conjuntos de datos grandes y de alta dimensión
- Una de las técnicas más utilizadas para la visualización es t-SNE, pero su rendimiento se ve afectado con conjuntos de datos grandes y su uso correcto puede resultar complicado
- **UMAP** es una nueva técnica de McInnes et al. que ofrece una serie de ventajas sobre t-SNE: una mayor velocidad y una mejor conservación de la estructura global de los datos

- **UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction**
- La reducción de dimensionalidad es una herramienta poderosa para que los profesionales del aprendizaje automatizado visualicen y comprendan conjuntos de datos grandes y de alta dimensión
- Una de las técnicas más utilizadas para la visualización es t-SNE, pero su rendimiento se ve afectado con conjuntos de datos grandes y su uso correcto puede resultar complicado
- **UMAP** es una nueva técnica de McInnes et al. que ofrece una serie de ventajas sobre t-SNE: una mayor velocidad y una mejor conservación de la estructura global de los datos
- ¿Qué aporta UMAP? UMAP es rápido y se escala bien en términos de tamaño y dimensionalidad del conjunto de datos

- **UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction**

- La reducción de dimensionalidad es una herramienta poderosa para que los profesionales del aprendizaje automatizado visualicen y comprendan conjuntos de datos grandes y de alta dimensión
- Una de las técnicas más utilizadas para la visualización es t-SNE, pero su rendimiento se ve afectado con conjuntos de datos grandes y su uso correcto puede resultar complicado
- **UMAP** es una nueva técnica de McInnes et al. que ofrece una serie de ventajas sobre t-SNE: una mayor velocidad y una mejor conservación de la estructura global de los datos
- ¿Qué aporta UMAP? UMAP es rápido y se escala bien en términos de tamaño y dimensionalidad del conjunto de datos
- Por ejemplo, UMAP puede proyectar el conjunto de datos MNIST de 784 dimensiones y 70000 puntos en menos de 3 minutos, en comparación con los 45 minutos que requiere la implementación t-SNE de scikit-learn (Python)

- Además, UMAP tiende a preservar mejor la estructura global de los datos. Esto se puede atribuir a las sólidas bases teóricas (matemáticas) de UMAP, que permiten que el algoritmo logre un mejor equilibrio entre el énfasis en la estructura local y la global

- Además, UMAP tiende a preservar mejor la estructura global de los datos. Esto se puede atribuir a las sólidas bases teóricas (matemáticas) de UMAP, que permiten que el algoritmo logre un mejor equilibrio entre el énfasis en la estructura local y la global
- **Un clavado a la teoría UMAP**

- Además, UMAP tiende a preservar mejor la estructura global de los datos. Esto se puede atribuir a las sólidas bases teóricas (matemáticas) de UMAP, que permiten que el algoritmo logre un mejor equilibrio entre el énfasis en la estructura local y la global
- **Un clavado a la teoría UMAP**
- UMAP, en esencia, funciona de manera muy similar a t-SNE: ambos utilizan algoritmos de diseño de gráficos para organizar los datos en un espacio de baja dimensión

- Además, UMAP tiende a preservar mejor la estructura global de los datos. Esto se puede atribuir a las sólidas bases teóricas (matemáticas) de UMAP, que permiten que el algoritmo logre un mejor equilibrio entre el énfasis en la estructura local y la global
- **Un clavado a la teoría UMAP**
- UMAP, en esencia, funciona de manera muy similar a t-SNE: ambos utilizan algoritmos de diseño de gráficos para organizar los datos en un espacio de baja dimensión
- En el sentido más simple, UMAP construye una representación gráfica de alta dimensión de los datos y luego optimiza un gráfico de baja dimensión para que sea estructuralmente lo más similar posible

- Además, UMAP tiende a preservar mejor la estructura global de los datos. Esto se puede atribuir a las sólidas bases teóricas (matemáticas) de UMAP, que permiten que el algoritmo logre un mejor equilibrio entre el énfasis en la estructura local y la global
- **Un clavado a la teoría UMAP**
- UMAP, en esencia, funciona de manera muy similar a t-SNE: ambos utilizan algoritmos de diseño de gráficos para organizar los datos en un espacio de baja dimensión
- En el sentido más simple, UMAP construye una representación gráfica de alta dimensión de los datos y luego optimiza un gráfico de baja dimensión para que sea estructuralmente lo más similar posible
- Si bien las matemáticas que utiliza UMAP para construir el gráfico de alta dimensión son avanzadas, la intuición detrás de ellas es notablemente simple

- Para construir el gráfico de alta dimensión inicial, UMAP construye algo llamado un complejo simplicial “difuso”. Esto es simplemente una representación de un gráfico ponderado, con pesos de borde que representan la probabilidad de que dos puntos estén conectados.

- Para construir el gráfico de alta dimensión inicial, UMAP construye algo llamado un complejo simplicial “difuso”. Esto es simplemente una representación de un gráfico ponderado, con pesos de borde que representan la probabilidad de que dos puntos estén conectados.
- Para determinar la conectividad, UMAP extiende un radio hacia afuera desde cada punto, conectando puntos cuando esos radios se superponen

- Para construir el gráfico de alta dimensión inicial, UMAP construye algo llamado un complejo simplicial “difuso”. Esto es simplemente una representación de un gráfico ponderado, con pesos de borde que representan la probabilidad de que dos puntos estén conectados.
- Para determinar la conectividad, UMAP extiende un radio hacia afuera desde cada punto, conectando puntos cuando esos radios se superponen
- La elección de este radio es fundamental: una elección demasiado pequeña dará lugar a grupos pequeños y aislados, mientras que una elección demasiado grande conectará todo entre sí

- Para construir el gráfico de alta dimensión inicial, UMAP construye algo llamado un complejo simplicial “difuso”. Esto es simplemente una representación de un gráfico ponderado, con pesos de borde que representan la probabilidad de que dos puntos estén conectados.
- Para determinar la conectividad, UMAP extiende un radio hacia afuera desde cada punto, conectando puntos cuando esos radios se superponen
- La elección de este radio es fundamental: una elección demasiado pequeña dará lugar a grupos pequeños y aislados, mientras que una elección demasiado grande conectará todo entre sí
- UMAP supera este desafío eligiendo un radio localmente, en función de la distancia al vecino n -ésimo más cercano de cada punto.

- Para construir el gráfico de alta dimensión inicial, UMAP construye algo llamado un complejo simplicial “difuso”. Esto es simplemente una representación de un gráfico ponderado, con pesos de borde que representan la probabilidad de que dos puntos estén conectados.
- Para determinar la conectividad, UMAP extiende un radio hacia afuera desde cada punto, conectando puntos cuando esos radios se superponen
- La elección de este radio es fundamental: una elección demasiado pequeña dará lugar a grupos pequeños y aislados, mientras que una elección demasiado grande conectará todo entre sí
- UMAP supera este desafío eligiendo un radio localmente, en función de la distancia al vecino n -ésimo más cercano de cada punto.
- Luego, UMAP hace que el gráfico sea “difuso” al disminuir la probabilidad de conexión a medida que aumenta el radio

- Finalmente, al estipular que cada punto debe estar conectado al menos a su vecino más cercano, UMAP garantiza que la estructura local se preserve en equilibrio con la estructura global

- Finalmente, al estipular que cada punto debe estar conectado al menos a su vecino más cercano, UMAP garantiza que la estructura local se preserve en equilibrio con la estructura global
- Una vez que se construye el gráfico de alta dimensión, UMAP optimiza el diseño de un análogo de baja dimensión para que sea lo más similar posible. Este proceso es esencialmente el mismo que en t-SNE, pero utiliza algunos trucos inteligentes para acelerar el proceso

- Finalmente, al estipular que cada punto debe estar conectado al menos a su vecino más cercano, UMAP garantiza que la estructura local se preserve en equilibrio con la estructura global
- Una vez que se construye el gráfico de alta dimensión, UMAP optimiza el diseño de un análogo de baja dimensión para que sea lo más similar posible. Este proceso es esencialmente el mismo que en t-SNE, pero utiliza algunos trucos inteligentes para acelerar el proceso
- La clave para utilizar UMAP de manera eficaz radica en comprender la construcción del gráfico inicial de alta dimensión

- Finalmente, al estipular que cada punto debe estar conectado al menos a su vecino más cercano, UMAP garantiza que la estructura local se preserve en equilibrio con la estructura global
- Una vez que se construye el gráfico de alta dimensión, UMAP optimiza el diseño de un análogo de baja dimensión para que sea lo más similar posible. Este proceso es esencialmente el mismo que en t-SNE, pero utiliza algunos trucos inteligentes para acelerar el proceso
- La clave para utilizar UMAP de manera eficaz radica en comprender la construcción del gráfico inicial de alta dimensión
- Aunque las ideas detrás del proceso son muy intuitivas, el algoritmo se basa en algunas matemáticas avanzadas para brindar garantías teóricas sólidas sobre qué tan bien este gráfico representa realmente los datos

- **Parámetros de UMAP**

- **Parámetros de UMAP**
- Para comprender la teoría detrás de UMAP, resulta mucho más fácil entender los parámetros del algoritmo, especialmente en comparación con el parámetro de perplejidad en t-SNE

- **Parámetros de UMAP**

- Para comprender la teoría detrás de UMAP, resulta mucho más fácil entender los parámetros del algoritmo, especialmente en comparación con el parámetro de perplejidad en t-SNE
- Consideraremos los dos parámetros más utilizados:
n_neighbors y *min_dist*, que se utilizan de manera efectiva para controlar el equilibrio entre la estructura local y global en la proyección final

- **Parámetros de UMAP**

- Para comprender la teoría detrás de UMAP, resulta mucho más fácil entender los parámetros del algoritmo, especialmente en comparación con el parámetro de perplejidad en t-SNE
- Consideraremos los dos parámetros más utilizados: *n_neighbors* y *min_dist*, que se utilizan de manera efectiva para controlar el equilibrio entre la estructura local y global en la proyección final
- El parámetro más importante es *n_neighbors*: la cantidad de vecinos más cercanos aproximados utilizados para construir el gráfico inicial de alta dimensión

- **Parámetros de UMAP**

- Para comprender la teoría detrás de UMAP, resulta mucho más fácil entender los parámetros del algoritmo, especialmente en comparación con el parámetro de perplejidad en t-SNE
- Consideraremos los dos parámetros más utilizados: *n_neighbors* y *min_dist*, que se utilizan de manera efectiva para controlar el equilibrio entre la estructura local y global en la proyección final
- El parámetro más importante es *n_neighbors*: la cantidad de vecinos más cercanos aproximados utilizados para construir el gráfico inicial de alta dimensión
- Controla de manera efectiva cómo UMAP equilibra la estructura local frente a la global: los valores bajos impulsarán a UMAP a centrarse más en la estructura local al restringir la cantidad de puntos vecinos considerados al analizar los datos en altas dimensiones, mientras que los valores altos impulsarán a UMAP a representar la estructura general mientras pierde detalles finos

- El segundo parámetro que investigaremos es *min_dist*, o la distancia mínima entre puntos en el espacio de baja dimensión

- El segundo parámetro que investigaremos es *min_dist*, o la distancia mínima entre puntos en el espacio de baja dimensión
- Este parámetro controla la densidad con la que UMAP agrupa los puntos. Los valores bajos dan lugar a incrustaciones más compactas

- El segundo parámetro que investigaremos es *min_dist*, o la distancia mínima entre puntos en el espacio de baja dimensión
- Este parámetro controla la densidad con la que UMAP agrupa los puntos. Los valores bajos dan lugar a incrustaciones más compactas
- Los valores más altos de *min_dist* harán que UMAP agrupe los puntos de forma más flexible, centrándose en cambio en la conservación de la estructura topológica general

- El segundo parámetro que investigaremos es *min_dist*, o la distancia mínima entre puntos en el espacio de baja dimensión
- Este parámetro controla la densidad con la que UMAP agrupa los puntos. Los valores bajos dan lugar a incrustaciones más compactas
- Los valores más altos de *min_dist* harán que UMAP agrupe los puntos de forma más flexible, centrándose en cambio en la conservación de la estructura topológica general
- Si bien la mayoría de las aplicaciones de UMAP implican la proyección de datos de alta dimensión, la proyección de datos 3D sirve como una analogía útil para comprender cómo UMAP prioriza la estructura global frente a la local según sus parámetros

- El segundo parámetro que investigaremos es *min_dist*, o la distancia mínima entre puntos en el espacio de baja dimensión
- Este parámetro controla la densidad con la que UMAP agrupa los puntos. Los valores bajos dan lugar a incrustaciones más compactas
- Los valores más altos de *min_dist* harán que UMAP agrupe los puntos de forma más flexible, centrándose en cambio en la conservación de la estructura topológica general
- Si bien la mayoría de las aplicaciones de UMAP implican la proyección de datos de alta dimensión, la proyección de datos 3D sirve como una analogía útil para comprender cómo UMAP prioriza la estructura global frente a la local según sus parámetros
- A medida que *n_neighbors* aumenta, UMAP conecta cada vez más puntos vecinos al construir la representación gráfica de los datos de alta dimensión, lo que conduce a una proyección que refleja con mayor precisión la estructura global de los datos

- Con valores muy bajos, se pierde casi por completo cualquier noción de estructura global.

- Con valores muy bajos, se pierde casi por completo cualquier noción de estructura global.
- A medida que aumenta el parámetro *min_dist*, UMAP tiende a “dispersar” los puntos proyectados, lo que conduce a una menor agrupación de los datos y a un menor énfasis en la estructura global

- Con valores muy bajos, se pierde casi por completo cualquier noción de estructura global.
- A medida que aumenta el parámetro *min_dist*, UMAP tiende a “dispersar” los puntos proyectados, lo que conduce a una menor agrupación de los datos y a un menor énfasis en la estructura global
- **UMAP vs t-SNE**

- Con valores muy bajos, se pierde casi por completo cualquier noción de estructura global.
- A medida que aumenta el parámetro *min_dist*, UMAP tiende a “dispersar” los puntos proyectados, lo que conduce a una menor agrupación de los datos y a un menor énfasis en la estructura global
- **UMAP vs t-SNE**
- La mayor diferencia entre el resultado de UMAP en comparación con t-SNE es este equilibrio entre la estructura local y global: UMAP suele ser mejor para preservar la estructura global en la proyección final

- Con valores muy bajos, se pierde casi por completo cualquier noción de estructura global.
- A medida que aumenta el parámetro *min_dist*, UMAP tiende a “dispersar” los puntos proyectados, lo que conduce a una menor agrupación de los datos y a un menor énfasis en la estructura global
- **UMAP vs t-SNE**
- La mayor diferencia entre el resultado de UMAP en comparación con t-SNE es este equilibrio entre la estructura local y global: UMAP suele ser mejor para preservar la estructura global en la proyección final
- Esto significa que las relaciones entre clusteres son potencialmente más significativas que en t-SNE

- Sin embargo, es importante tener en cuenta que, debido a que tanto UMAP como t-SNE necesariamente deforman la forma de alta dimensión de los datos cuando se proyectan a dimensiones inferiores, cualquier eje o distancia dado en dimensiones inferiores todavía no es directamente interpretable mediante técnicas como PCA

- Sin embargo, es importante tener en cuenta que, debido a que tanto UMAP como t-SNE necesariamente deforman la forma de alta dimensión de los datos cuando se proyectan a dimensiones inferiores, cualquier eje o distancia dado en dimensiones inferiores todavía no es directamente interpretable mediante técnicas como PCA
- **Comentarios finales**

- Sin embargo, es importante tener en cuenta que, debido a que tanto UMAP como t-SNE necesariamente deforman la forma de alta dimensión de los datos cuando se proyectan a dimensiones inferiores, cualquier eje o distancia dado en dimensiones inferiores todavía no es directamente interpretable mediante técnicas como PCA
- **Comentarios finales**
- Algunas grandes diferencias entre los resultados de los dos algoritmos

- Sin embargo, es importante tener en cuenta que, debido a que tanto UMAP como t-SNE necesariamente deforman la forma de alta dimensión de los datos cuando se proyectan a dimensiones inferiores, cualquier eje o distancia dado en dimensiones inferiores todavía no es directamente interpretable mediante técnicas como PCA
- **Comentarios finales**
- Algunas grandes diferencias entre los resultados de los dos algoritmos
- Para valores más bajos del parámetro perplexity, t-SNE tiende a "dispersar" los datos proyectados con muy poca preservación de la estructura global. En contraste, UMAP tiende a agrupar piezas adyacentes de la estructura de dimensiones superiores en dimensiones bajas, lo que refleja una mayor preservación de la estructura global

- Tomemos en cuenta que, utilizando t-SNE, se necesita una perplejidad extremadamente alta (~ 1000) para comenzar a ver emerger la estructura global, y con valores de perplejidad tan altos, el tiempo de cálculo es drásticamente más largo

- Tomemos en cuenta que, utilizando t-SNE, se necesita una perplejidad extremadamente alta (~ 1000) para comenzar a ver emerger la estructura global, y con valores de perplejidad tan altos, el tiempo de cálculo es drásticamente más largo
- También es notable que las proyecciones de t-SNE varían ampliamente de una ejecución a otra, con diferentes piezas de los datos de dimensiones superiores proyectadas a diferentes ubicaciones

- Tomemos en cuenta que, utilizando t-SNE, se necesita una perplejidad extremadamente alta (~ 1000) para comenzar a ver emerger la estructura global, y con valores de perplejidad tan altos, el tiempo de cálculo es drásticamente más largo
- También es notable que las proyecciones de t-SNE varían ampliamente de una ejecución a otra, con diferentes piezas de los datos de dimensiones superiores proyectadas a diferentes ubicaciones
- Si bien UMAP también es un algoritmo estocástico, es sorprendente cuán similares son las proyecciones resultantes de una ejecución a otra y con diferentes parámetros. Esto se debe, nuevamente, al mayor énfasis de UMAP en la estructura global en comparación con t-SNE

- Tomemos en cuenta que, utilizando t-SNE, se necesita una perplejidad extremadamente alta (~ 1000) para comenzar a ver emerger la estructura global, y con valores de perplejidad tan altos, el tiempo de cálculo es drásticamente más largo
- También es notable que las proyecciones de t-SNE varían ampliamente de una ejecución a otra, con diferentes piezas de los datos de dimensiones superiores proyectadas a diferentes ubicaciones
- Si bien UMAP también es un algoritmo estocástico, es sorprendente cuán similares son las proyecciones resultantes de una ejecución a otra y con diferentes parámetros. Esto se debe, nuevamente, al mayor énfasis de UMAP en la estructura global en comparación con t-SNE
- **Cómo (mal)leer UMAP**

- Tomemos en cuenta que, utilizando t-SNE, se necesita una perplejidad extremadamente alta (~ 1000) para comenzar a ver emerger la estructura global, y con valores de perplejidad tan altos, el tiempo de cálculo es drásticamente más largo
- También es notable que las proyecciones de t-SNE varían ampliamente de una ejecución a otra, con diferentes piezas de los datos de dimensiones superiores proyectadas a diferentes ubicaciones
- Si bien UMAP también es un algoritmo estocástico, es sorprendente cuán similares son las proyecciones resultantes de una ejecución a otra y con diferentes parámetros. Esto se debe, nuevamente, al mayor énfasis de UMAP en la estructura global en comparación con t-SNE
- **Cómo (mal)leer UMAP**
- Si bien UMAP ofrece una serie de ventajas sobre t-SNE, no es en absoluto una solución milagrosa, y leer y comprender sus resultados requiere cierto cuidado

- Vale la pena recordar las anotaciones finales en el documento de t-SNE, ya que muchas de esas conclusiones se aplican a UMAP:

- Vale la pena recordar las anotaciones finales en el documento de t-SNE, ya que muchas de esas conclusiones se aplican a UMAP:
 - **Los hiperparámetros son muy importantes.** Elegir buenos valores no es fácil y depende tanto de los datos como de los objetivos (por ejemplo, qué tan compacta debe ser la proyección). Aquí es donde la velocidad de UMAP es una gran ventaja: al ejecutar UMAP varias veces con una variedad de hiperparámetros, se puede tener una mejor idea de cómo la proyección se ve afectada por sus parámetros

- Vale la pena recordar las anotaciones finales en el documento de t-SNE, ya que muchas de esas conclusiones se aplican a UMAP:
 - **Los hiperparámetros son muy importantes.** Elegir buenos valores no es fácil y depende tanto de los datos como de los objetivos (por ejemplo, qué tan compacta debe ser la proyección). Aquí es donde la velocidad de UMAP es una gran ventaja: al ejecutar UMAP varias veces con una variedad de hiperparámetros, se puede tener una mejor idea de cómo la proyección se ve afectada por sus parámetros
 - **Los tamaños de los clústeres en un gráfico de UMAP no significan nada.** Al igual que en t-SNE, el tamaño de los clústeres en relación con los demás es esencialmente insignificante. Esto se debe a que UMAP utiliza nociones locales de distancia para construir su representación gráfica de alta dimensión

- **Las distancias entre clústeres pueden no significar nada.**

De la misma manera, es probable que las distancias entre clústeres no tengan sentido. Si bien es cierto que las posiciones globales de los clústeres se conservan mejor en UMAP, las distancias entre ellos no son significativas. Nuevamente, esto se debe al uso de distancias locales al construir el gráfico

- **Las distancias entre clústeres pueden no significar nada.**
De la misma manera, es probable que las distancias entre clústeres no tengan sentido. Si bien es cierto que las posiciones globales de los clústeres se conservan mejor en UMAP, las distancias entre ellos no son significativas. Nuevamente, esto se debe al uso de distancias locales al construir el gráfico
- **El ruido aleatorio no siempre parece aleatorio.**
Especialmente con valores bajos de $n_neighbors$, se puede observar una agrupación espuria

- **Las distancias entre clústeres pueden no significar nada.**
De la misma manera, es probable que las distancias entre clústeres no tengan sentido. Si bien es cierto que las posiciones globales de los clústeres se conservan mejor en UMAP, las distancias entre ellos no son significativas. Nuevamente, esto se debe al uso de distancias locales al construir el gráfico
- **El ruido aleatorio no siempre parece aleatorio.**
Especialmente con valores bajos de $n_neighbors$, se puede observar una agrupación espuria
- **Es posible que necesite más de un gráfico.** Dado que el algoritmo UMAP es estocástico, diferentes ejecuciones con los mismos hiperparámetros pueden arrojar resultados diferentes. Además, dado que la elección de los hiperparámetros es tan importante, puede ser muy útil ejecutar la proyección varias veces con varios hiperparámetros

- **Conclusión**

- **Conclusión**
- UMAP es una herramienta increíblemente poderosa en el arsenal del científico de datos y ofrece una serie de ventajas sobre t-SNE

● **Conclusión**

- UMAP es una herramienta increíblemente poderosa en el arsenal del científico de datos y ofrece una serie de ventajas sobre t-SNE
- Si bien tanto UMAP como t-SNE producen resultados similares, la mayor velocidad, la mejor conservación de la estructura global y los parámetros más comprensibles hacen de UMAP una herramienta más eficaz para visualizar datos de alta dimensión

Por último, es importante recordar que ninguna técnica de reducción de dimensionalidad es perfecta (necesariamente, distorsionamos los datos para que encajen en dimensiones inferiores) y UMAP no es una excepción

- **Conclusión**

- UMAP es una herramienta increíblemente poderosa en el arsenal del científico de datos y ofrece una serie de ventajas sobre t-SNE
- Si bien tanto UMAP como t-SNE producen resultados similares, la mayor velocidad, la mejor conservación de la estructura global y los parámetros más comprensibles hacen de UMAP una herramienta más eficaz para visualizar datos de alta dimensión

Por último, es importante recordar que ninguna técnica de reducción de dimensionalidad es perfecta (necesariamente, distorsionamos los datos para que encajen en dimensiones inferiores) y UMAP no es una excepción

- Sin embargo, al desarrollar una comprensión intuitiva de cómo funciona el algoritmo y comprender cómo ajustar sus parámetros, podemos utilizar esta poderosa herramienta de manera más eficaz para visualizar y comprender conjuntos de datos grandes y de alta dimensión